

# XXXII Congresso Brasileiro de Ciência do Solo

## “Mapeamento de Áreas Cafeeiras da Região de Guaxupé por Classificação Automática Utilizando Redes Neurais Artificiais”

**TATIANA GROSSI CHQUILOFF VIEIRA**<sup>(1)</sup>; **WILIAN SOARES LACERDA**<sup>(2)</sup>; **HELENA MARIA RAMOS ALVES**<sup>(3)</sup>; **MARGARETE MARIN LORDELO VOLPATO**<sup>(4)</sup>; **LÍVIA NAIARA DE ANDRADE**<sup>(5)</sup>; **RICARDO CÉSAR ARSILLO BRAGA**<sup>(6)</sup>; **VANESSA CRISTINA OLIVEIRA DE SOUZA**<sup>(7)</sup>

**RESUMO** - A cultura cafeeira tem o padrão espectral muito próximo ao da mata, dificultando a classificação automática dessas classes de uso da terra. A aplicação de Redes Neurais Artificiais (RNAs) na classificação de dados de Sensoriamento Remoto tem se mostrado uma abordagem promissora na discriminação de classes de maior complexidade. No presente trabalho foram utilizadas três bandas espectrais da imagem do satélite HRV/SPOT 5 da região de Guaxupé, MG com o *software* de processamento de imagens IDRISI. Para validação dos mapas obtidos pela classificação, realizou-se o cruzamento do mapa de uso e ocupação da terra por classificação visual com o gerado pela RNA. Em relação ao mapa de referência, o índice Kappa (k) do mapa classificado pela RNA ficou em 71,85%, o que é considerado um índice bom. A metodologia de redes neurais artificiais multilayer perceptron (MLP) apresentou um bom resultado, porém é necessário que se acrescente outros dados de entrada para melhorar a classificação.

**Palavras-Chave:** (sensoriamento remoto, redes neurais artificiais, cafeicultura, classificação automática, imagem SPOT, Guaxupé-MG)

### Introdução

Minas Gerais é o maior produtor brasileiro de café e a região Sul de Minas contribui com mais de 50% da produção mineira. Atualmente o café corresponde a 70% da renda das propriedades rurais do Sul de Minas. A região produz café arábica e a altitude média é de aproximadamente 950 metros. As variedades mais cultivadas são o Catuaí e o Mundo Novo. Porém, também existem as variedades Icatu, Obatã e Catuaí Rubi. A região Sul de Minas é conhecida por ter bebidas finas. A média do Sul de Minas é de quatro mil cafeeiros por hectare, o que representa o sistema de cultivo semi-adensado [1].

O município de Guaxupé tem sua economia baseada na atividade agrícola, possuindo mais de 200 propriedades rurais, com sistemas de produção de

médio e alto nível tecnológico, sendo o café seu principal produto de cultivo, com produção de bebidas finas. Fato este que justifica a existência da Cooperativa de Cafeicultores (Cooxupé) na região, que é considerada a maior do mundo devido à estrutura que possui para atender o setor. Devido a importância que a cultura do café representa à região cafeeira de Guaxupé, utilizou-se a classificação automática por Redes Neurais Artificiais para o mapeamento das áreas cafeeiras.

A utilização de modelos de Redes Neurais Artificiais (RNAs) em classificação possibilita a incorporação não apenas de dados multiespectrais, mas de dados adquiridos por outras fontes, mesmo que não apresentem natureza espectral. Nessas situações, as RNAs parecem desempenhar a tarefa de classificação de imagens tão bem, ou melhor, que as técnicas estatísticas, uma vez que não requerem que a natureza paramétrica dos dados as serem classificados seja explicitada [2].

As RNAs têm sido aplicadas com sucesso nas áreas de processamento de imagens e reconhecimento de padrões. Os trabalhos de Hepner [3] e Benediktsson *et al.*[4] fizeram uso de RNA na classificação de imagens de sensoriamento remoto e para resolver o problema de classificação, utilizaram uma rede de perceptrons multicamadas (MLP), que caracteriza-se por assumir regiões de decisão semelhantes às aquelas formadas por um classificador estatístico, porém com entradas não correlacionadas e distribuições diferentes para os dados [5].

Este trabalho tem como objetivo definir um procedimento de classificação automática utilizando Redes Neurais Artificiais para identificação de áreas cafeeiras em imagens de satélite de alta resolução espacial, HRV/SPOT 5. Foi aplicada uma RNA treinada para discriminar classes de uso da terra em Guaxupé, MG.

### Material e Métodos

A área de estudo encontra-se na Região Sul do estado de Minas Gerais, localizada no Planalto de Poços de Caldas, no município de Guaxupé. Posiciona-se geograficamente entre as coordenadas 21° 5' 42.46" a 21°

<sup>(1)</sup> Pesquisadora, M. Sc. em Solos e Nutrição de Plantas, EPAMIG, Bolsista FAPEMIG, Lavras-MG, tatiana@epamig.ufla.br

<sup>(2)</sup> Professor, D. Sc. em Engenharia da Computação, Universidade Federal de Lavras, Departamento de Ciência da Computação, lacerda@dcc.ufla.br

<sup>(3)</sup> Pesquisadora, D. Sc. em Soil Science And Land Evaluation, EMBRAPA CAFÉ, Lavras-MG, helena@epamig.ufla.br

<sup>(4)</sup> Pesquisadora, D. Sc. em Engenharia Agrícola, EPAMIG, Bolsista FAPEMIG, Lavras-MG, margarete@epamig.ufla.br

<sup>(5)</sup> Bolsista, Tecnóloga em Análise e Desenvolvimento de Sistemas, EMBRAPA CAFÉ - CBP&D/CAFÉ, Lavras-MG lívia@epamig.ufla.br

<sup>(6)</sup> Bolsista, Iniciação Científica Agronomia, Universidade Federal de Lavras FAPEMIG, arsillo@agronomia.ufla.br

<sup>(7)</sup> Bolsista, M. Sc. em Sensoriamento Remoto, EPAMIG CBP&D, Lavras-MG, vanessa@epamig.ufla.br

Apoio financeiro: FAPEMIG e CBP&D/CAFÉ

17° 10.85'' de latitude sul e 46° 36' 59.12'' a 46° 51' 30.28'' de longitude oeste.

Neste trabalho foram utilizadas imagens multiespectrais para classificação automática com RNA, que se referem às bandas 1, 2 e 3 do satélite SPOT, sensor HRV, com resolução espacial de 2,5m, com datas de passagem de 28/05/2005, sendo estas as bandas mais empregadas no mapeamento da cobertura do solo. O mapa de uso da terra em Guaxupé-MG [6] foi classificado visualmente e foram utilizados os sistemas de informações geográficas SPRING [7], versão 4.3.3 e o IDRISI [8].

#### *Pré-processamentos*

Para a realização do treinamento da RNA, os dados de sensoriamento remoto e o mapa de classificação visual foram submetidos a um pré-processamento. Foi criada uma máscara em cada uma das três bandas utilizadas, agregando à classe “outros usos” do mapa classificado visualmente: água, solo exposto e café em formação.

As imagens de sensoriamento remoto do satélite SPOT sensor HRV possuem melhor resolução espacial se comparadas a imagens de outros satélites. Considerando as características dos sensores remotos orbitais, quanto à sua resolução espacial e espectral e os mecanismos de interação da radiação eletromagnética com a cultura do café, percebe-se uma variabilidade espectral bem tênue com áreas de mata, de modo que os estudos envolvendo o mapeamento de áreas cafezeiras por meio de Sensoriamento Remoto têm sido desenvolvidos por Vieira *et al.* [9]. Devido ao fato de ocorrer esta ambigüidade espectral entre áreas de mata e café foi criada uma máscara sobre as três bandas da imagem HRV/SPOT, na qual a máscara deixava visível para a RNA apenas as classes café, mata e outros usos (classes agregadas). Para o desenvolvimento desta máscara, foi utilizada a Linguagem Espacial para Geoprocessamento Algebrico (LEGAL), do SPRING.

#### *Definição da arquitetura e treinamento da RNA*

A obtenção de áreas de treinamento e validação da RNA foi realizada por meio da extração de áreas em formato de polígonos da imagem para cada classe a ser classificada. Para auxílio na definição das amostras de treinamento foi utilizado um mapa temático de uso da terra da região selecionada classificada visualmente, sendo que, foram selecionados entre 5 e 8 polígonos de tamanhos variados e espaçados ao acaso para cada classe, compostas da seguinte forma: 1 - **café em produção**: lavouras com idade superior a três anos; 2 - **mata**: formações florestais densas e florestas de galeria às margens dos córregos; 3 - **outros usos**: água, áreas com café em formação (menor que três anos), áreas com culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação. Normalmente, as abordagens de

classificação supervisionada baseiam-se no uso de amostras para estimar os parâmetros estatísticos para cada classe. Essas amostras são chamadas de padrões de treinamento, sendo que a totalidade das amostras define o conjunto de treinamento [10].

Após a obtenção das áreas de treinamento, foi utilizado o módulo *Makesig* do IDRISI para realizar a assinatura espectral do conjunto de amostras. Em seguida foram indicadas as três bandas da imagem que poderão ser utilizadas na classificação. Para a definição da arquitetura da RNA para classificação da imagem, foi executado o módulo de classificação por Redes Neurais do tipo *Multi-layer Perceptron*, do *software* IDRISI. O número de elementos da camada de saída foi definido com base no número de classes a serem classificadas na imagem, sendo três nós com valores identificados na criação das amostras.

Foram realizados diversos testes para definição da arquitetura ideal para a classificação, sendo adotado um modelo de rede neural com estrutura de múltiplas camadas, da abordagem supervisionada. A RNA foi treinada com algoritmo *backpropagation*, realizando as seguintes alterações na arquitetura da RNA: número de camadas; número de neurônios nas camadas; número do conjunto de pixels para o conjunto de treinamento e teste; fator de *momentum* e taxa de aprendizado (Tabela 1).

#### *Processamentos pós-classificação*

A metodologia realizada para obter a classificação e a validação dos dados pela RNA está representada na Figura 1. Para validação da classificação realizada pela RNA, foi realizado um cruzamento entre o mapa classificado visualmente da área de estudo com o classificado pela Rede Neural Artificial utilizando a Linguagem Espacial para Geoprocessamento Algebrico (LEGAL). A análise do desempenho da RNA foi avaliada em três classes, sendo elas: **Áreas classificadas corretamente**: pixels de áreas de café classificadas igualmente pela RNA e pelo método visual; **Áreas classificadas incorretamente**: pixels que a RNA classificou como café, porém não eram; e **Áreas não classificadas**: pixels que a RNA deixou de classificar como café, classificando como outra classe.

#### **Resultados e discussão**

Foram realizadas modificações nos parâmetros de aprendizado da RNA, fator de *momentum* e o número de iterações, na tentativa de obter um índice melhor para esta arquitetura. No entanto, não foi observado melhoria no resultado, pelo contrário, foi observada uma queda nos resultados dos testes (Tabela 1). A arquitetura da RNA que apresentou melhor resultado de treinamento foi uma rede neural com 14 neurônios em uma única camada escondida e 3 neurônios na saída. Outros parâmetros definidos foram: um conjunto de 55 pixels por categoria para o conjunto de teste e treinamento, taxa de aprendizado da RNA de 0,02; fator de *momentum* de 0,5 para agilizar na convergência da rede; e constante de sigmóide de 1. Como critério de parada do treinamento da RNA foi estabelecido 10.000 iterações ou erro médio quadrático (EQM) de 0,0001. A parada do treinamento da RNA aconteceu pelo número de

iterações do algoritmo *backpropagation*, resultando em um valor de EQM de 0,006641 para os dados de treinamento, e 0,00779 para os dados de teste. As configurações utilizadas para teste na tentativa de obter a rede que melhor classificasse a imagem está demonstrada na Tabela 1.

A Figura 2 mostra o mapa de uso da terra obtido por classificação visual e pré-processado, criando o mapa de uso da terra classificado visualmente com máscara. Esse mapa foi utilizado como referência para avaliar a classificação feita pela RNA. O mapa classificado pela Rede Neural treinada é apresentada na Figura 3.

Em relação ao mapa de referência, o índice de acurácia Kappa do mapa classificado pela RNA foi de 71,85%, que segundo Galparsoro e Fernández [11] é considerado um índice bom. O erro na classificação realizada pela rede neural é influenciado pela ambigüidade existente entre o padrão espectral da cultura do café com as matas. A matriz de confusão entre os mapas é apresentada na Tabela 2, onde da área total de café em produção classificada pela RNA, 78,72% foram classificados corretamente. Em relação ao total da área de mata do mapa de referência, a classificação correta pela rede foi de 55,65%. O total da área classificada como outros usos pela RNA apresentou uma porcentagem de acerto de 97,01%.

O mapa de referência classificado visualmente com a máscara e o gerado pela classificação da RNA foram cruzados no SPRING, utilizando a Linguagem Espacial para Geoprocessamento Algebrico (LEGAL). Deste cruzamento obteve-se o mapa apresentado na Figura 4. O mapa apresenta o desempenho da RNA na área de café classificada corretamente pela RNA, que totaliza 80,9%, o que equivale a 88,27 km<sup>2</sup>. A área que a RNA classificou erroneamente como café totalizou 44,09 km<sup>2</sup>.

### Considerações Finais

A classificação de imagens espectrais por RNA pode ser considerada como uma excelente alternativa aos classificadores atualmente utilizados, mas deve ser melhor investigada. A utilização de parâmetros incorporados na estrutura da rede, que levem em conta o aspecto da distribuição espacial dos padrões e parâmetros de relevo deve ser analisada. No caso do mapeamento de áreas cafeeiras onde existe similaridade espectral entre café/mata, sugere-se criar uma máscara ao longo da rede de drenagem, onde existem pequenas áreas de matas ciliares. Outra possível alternativa para a melhoria da classificação pela RNA seria a inserção de parâmetros de entrada para o treinamento da RNA, como dados de relevo (altitude, orientação de vertente e declive). No Sul de Minas Gerais, onde o café é cultivado em áreas de altitudes mais elevadas, acima de 700m, a altitude pode ser um parâmetro discriminador a ser incorporado à rede, eliminando a possibilidade da RNA se confundir.

Um processamento que poderá ser utilizado para melhorar o acerto da classificação pela RNA, também é descrito por Souza [12]. Este trabalho fez uso do classificador textural do *software* Texture utilizando as medidas *cluster shade* e variância do vetor soma, com quantização de 256 níveis de cinza e janela de 3x3 *pixels*, para realização de testes sobre imagens do satélite Landsat 5, sensor TM, bandas 3 e 4. Este procedimento resultou em um índice Kappa de 86%, evidenciando que medidas de textura podem ser usadas satisfatoriamente para o mapeamento automático de áreas cafeeiras.

### Agradecimentos

Os autores agradecem ao apoio da Fundação de Amparo à Pesquisa de Minas Gerais - FAPEMIG e ao Consórcio Brasileiro de Pesquisa e Desenvolvimento do Café - CBPD/Café pelos recursos financeiros para o desenvolvimento do projeto e bolsas.

### Referências

- [1] COFFEE BREAK, O. C. Sul de Minas: café representa 70% da renda agrícola. 2008. Disponível em: <<http://www.coffeebreak.com.br/ocafezal.asp?SE=6&ID=38>>. Acesso em: 02.set.2008.
- [2] GALO, M. L. B. T. et al. 2002. Uso do Sensoriamento Remoto Orbital no Monitoramento da Dispersão de Macrófitas nos Reservatórios do Complexo Tiete. Plantas Daninhas, Viçosa, v.20, Edição Especial, p. 7-20.
- [3] HEPNER, G. F. Artificial Neural Networks Classification using a Minimal Training Set: Comparison to Conventional Supervised Classification. **Photogrammetric Engineering and Remote Sensing**, v. 56, n. 4, p. 469-473, 1990.
- [4] BENEDIKTSSON, J. A., SWAIN, P. H., ERSOY, O. K. Neural Network Approaches Versus Statistical Methods in Classification of Multisource Remote Sensing Data. **IEEE Transactions on Geoscience and Remote Sensing**, v. 28, n. 4, p. 540-552, 1990.
- [5] LIPPMANN, R. P.. An introduction to computing with neural nets. **IEEE ASSP Magazine**, v.4, p. 4-22, 1987.
- [6] EPAMIG. Centro Tecnológico do Sul de Minas. Laboratório de Geoprocessamento. **Geosolos**. Lavras, 2009. Disponível em: <[www.epamig.br/geosolos/](http://www.epamig.br/geosolos/)>. Acesso em: 18 abr 2009.
- [7] CÂMARA, G., R. C. M. SOUZA, U. M. FREITAS e J. GARRIDO. SPRING: Integrating remote sensing and GIS by object-oriented data modelling. **Computers & Graphics**, v.20, n.3, May/June 1996, p.395-403. 1996.
- [8] Clark Labs, IDRISI Andes, v.15.00, Clark University, Worcester, 2006.
- [9] VIEIRA, T. G. C.; ALVES, H. M. R.; LACERDA, M. P. C.; VEIGA, R. D.; EPIPHANIO, J. C. N. Crop parameters and spectral response of coffee (*Coffea arabica* L.) areas within the state of Minas Gerais, Brazil. **Coffee Science**, v.1, n.2, p.111-118, 2006.
- [10] GONZALES, R.C.; WOODS, R.E. **Processamento de Imagens Digitais**. São Paulo: Edgard Blücher Ltda, 2000.527p.
- [11] GALPARSORO, L. U. FERNÁNDEZ, S. P. **Medidas de concordância: el índice Kappa**. 2001. Disponível em: <<http://www.fisterra.com/mbe/investiga/kappa/kappa.htm>>. Acesso em: 10 mar. 2009.
- [12] SOUZA, V.C.O. **Análise e classificação textural de áreas de mata e café na região de Machado – MG**. 2009. In: Simpósio Brasileiro de Sensoriamento Remoto. Disponível em: <<http://sbsr.dpi.inpe.br/col/dpi.inpe.br/sbsr/80/2008/11.12.17.23/doc/7925-7932.pdf>> Acesso em: 08 mai. 2009.

Tabela 1. Configurações utilizadas para realização dos testes.

Configuração	Pixel <sup>1</sup>	Camadas escondidas	Neurônios		Taxa de aprendizado	Momentum	Iterações	EMQ	
			1ª Camada	2ª Camada				Trein.	Teste
1	60	1	10	-	0,02	0,53	10000	0,007076	0,008265
2	55	1	14	-	<b>0,02</b>	<b>0,50</b>	<b>10000</b>	<b>0,006641</b>	<b>0,00779</b>
3	65	1	8	-	0,02	0,53	10000	0,006891	0,007366
4	55	1	16	-	0,02	0,50	10000	0,006284	0,008308
5	60	2	10	8	0,02	0,53	10000	0,008646	0,007089

<sup>1</sup> Número de pixels selecionados para o conjunto de treinamento e teste

Tabela 2. Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %).

Mapa Classificado Visualmente	Mapa Classificado pela RNA			
	Café em produção	Mata	Outros usos	TOTAL
Café em produção	78,72%	16,46%	4,82%	100,00%
Mata	33,48%	55,65%	10,87%	100,00%
Outros usos	1,94%	1,05%	97,01%	100,00%

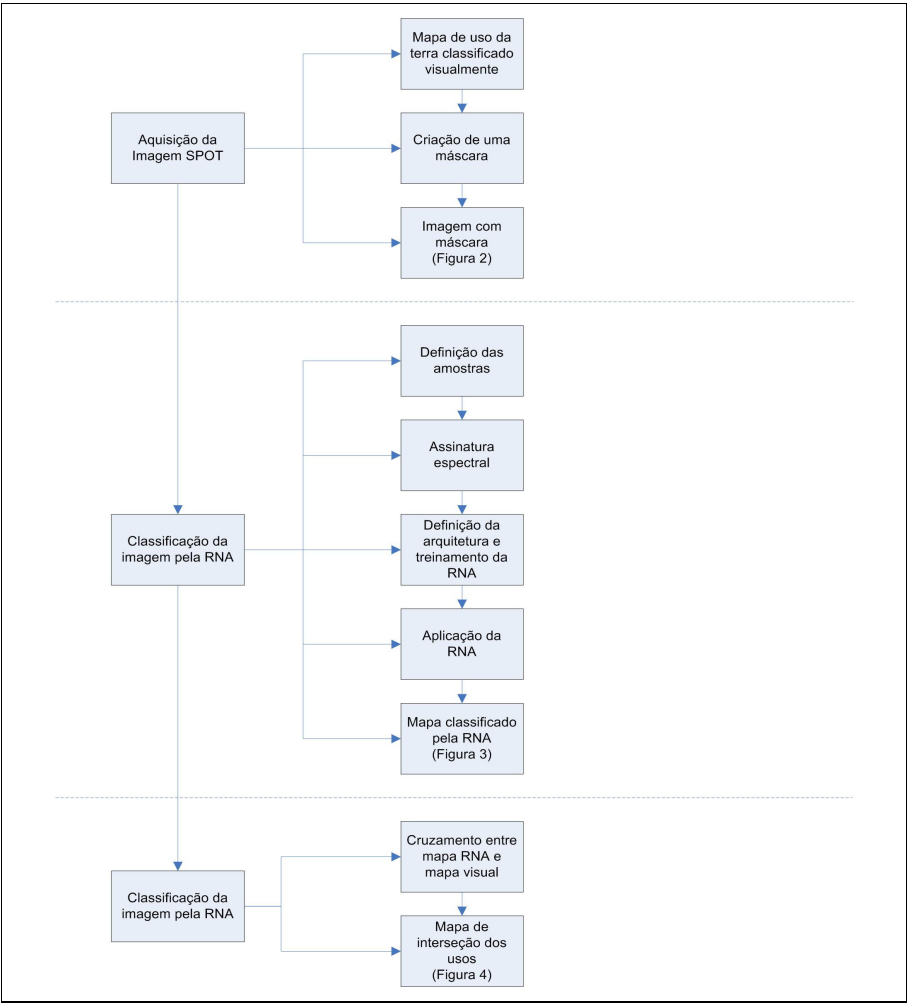
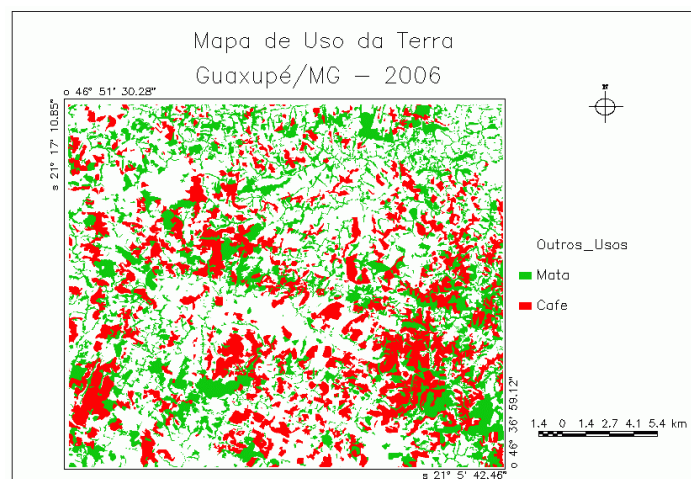
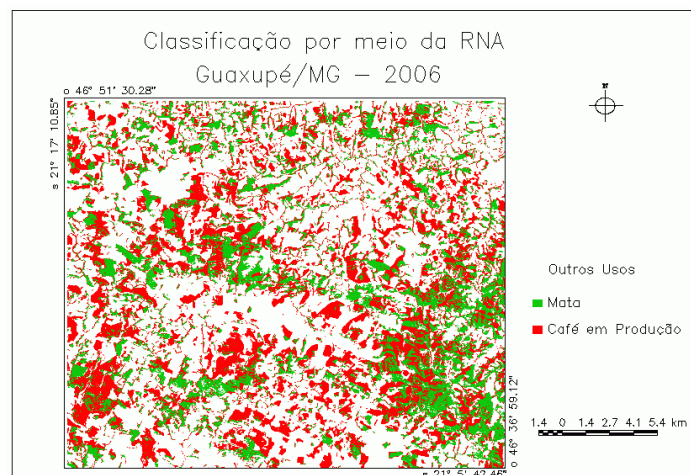


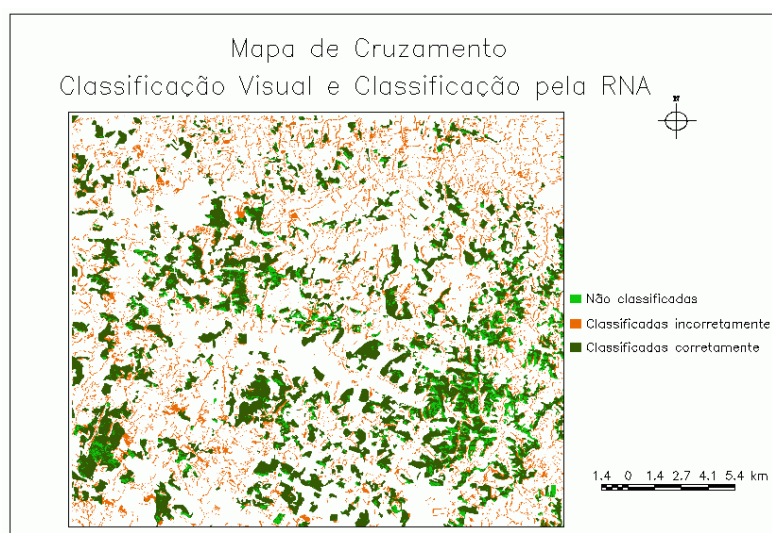
Figura 1. Metodologia realizada para realização da classificação e validação dos dados.



**Figura 2.** Mapa de uso da terra classificado visualmente com a máscara.



**Figura 3.** Mapa de uso da terra classificado pela RNA.



**Figura 4.** Mapa de cruzamento entre o mapa de referência e o classificado pela RNA.