



**LILIANY APARECIDA DOS ANJOS PEREIRA**

**Classificação automática de áreas cafeeiras em  
imagens de satélite, utilizando Redes Neurais  
Artificiais**

**LAVRAS – MG**

**2011**

**LILIANY APARECIDA DOS ANJOS PEREIRA**

**CLASSIFICAÇÃO AUTOMÁTICA DE ÁREAS CAFEEIRAS EM  
IMAGENS DE SATÉLITE, UTILIZANDO REDES NEURAIAS  
ARTIFICIAIS**

**Monografia apresentada ao  
Colegiado de Curso de Ciência da  
Computação, para obtenção do  
título de Bacharel em Ciência da  
Computação.**

**Orientador**

**Wilian Soares Lacerda**

**Co-orientadora**

**Tatiana G. C. Vieira**

**LAVRAS – MG**

**2011**

## RESUMO

A classificação digital de imagens de satélite tem ganhado, nas últimas décadas, reconhecimento como técnica para suprir a escassez dos mapeamentos temáticos. Para classificar dados de diferentes origens as Redes Neurais Artificiais (RNAs) são atualmente uma opção emergente. Minas Gerais é o estado que se destaca entre os demais estados brasileiros em área plantada e quantidade produzida de café. O conhecimento do ambiente em que o café está inserido permite um melhor planejamento da produção, visando o desenvolvimento sustentável e a obtenção de produtos com qualidade, uma vez que os fatores ambientais exercem grande influência sobre a qualidade da bebida. Assim o objetivo deste trabalho é a implementação de um software de classificação de áreas cafeeiras em imagens de satélite utilizando RNAs, para identificar e mapear o uso e ocupação das terras, com ênfase na identificação de áreas cafeeiras na região de Três Pontas localizada no sul de Minas Gerais. Para implementação será utilizado o software MATLAB e o toolbox de Redes Neurais deste. Serão utilizadas RNAs convolutivas que é um Perceptron de múltiplas camadas projetado especificamente para reconhecer formas bidimensionais. Será utilizado também o algoritmo backpropagation para o treinamento da rede neural. Para o desenvolvimento deste trabalho serão necessárias diversas etapas: definição do problema; coleta dos dados de treinamento e de teste; pré e pós-processamento dos dados; projeto da estrutura da rede; treinamento; teste e validação. Espera-se no final deste trabalho a implementação de um sistema que classifique automaticamente áreas de café e que obtenha resultados acima dos encontrados na literatura.

Palavras-chave: Classificação automática. Redes Neurais Artificiais. Imagens de satélite. Café.

## **ABSTRACT**

Digital satellite imagery classification in recent decades has been increasingly recognized as a technique for breaching the shortages of thematic mapping. Artificial Neural Networks (ANN) are currently an emerging option for sorting data from different sources. Minas Gerais state stands out from other Brazilian states in terms of planted area and quantity of coffee produced. As environmental factors have a great influence on the quality of the drink, an understanding of the environment in which the coffee is inserted allows for better production planning, aiming at sustainable development, and the achievement of quality products. Thus, the objective of this work is the implementation of a software to classify coffee areas in satellite images using ANNs to identify and map land use and occupation, with emphasis on the region of Três Pontas, located in southern Minas Gerais. To implement and utilize the MatlabNeural Networks Toolbox software we use convolutional ANNs, that is, a multilayer perceptron specifically designed to recognize two-dimensional shapes. We also use the backpropagation algorithm for neural network training. The project will be carried out in various stages: problem definition, data collection training and testing, pre and post-processing of data, network structure design, training, testing and validation. The expected result is the implementation of a system that automatically classifies coffee areas, providing better results than those found in the literature.

Keywords: Automatic classification, artificial neural networks, satellite images, coffee.

## LISTA DE FIGURAS

|                   |   |           |
|-------------------|---|-----------|
| <b>Figura 2.1</b> | <b>Modelo de um neurônio biológico.....</b>         | <b>15</b> |
| <b>Figura 2.2</b> | <b>Modelo matemático de um neurônio.....</b>        | <b>16</b> |
| <b>Figura 2.3</b> | <b>Rede de múltiplas camadas .....</b>              | <b>17</b> |
| <b>Figura 0.4</b> | <b>Exemplo de rede neural convolutiva.....</b>      | <b>20</b> |
| <b>Figura 2.5</b> | <b>Modelo Graphical User Interface.....</b>         | <b>26</b> |
| <b>Figura 2.6</b> | <b>Representação de uma imagem digital.....</b>     | <b>30</b> |
| <b>Figura 2.7</b> | <b>Representação de uma imagem digital.....</b>     | <b>35</b> |
| <b>Figura 3.1</b> | <b>Imagem a ser utilizada na classificação.....</b> | <b>37</b> |
| <b>Figura 3.2</b> | <b>Pré-processamento da imagem .....</b>            | <b>38</b> |

## **LISTA DE SIGLAS**

|        |                                       |
|--------|---------------------------------------|
| RNAs   | Redes Neurais Artificiais             |
| CONAB  | Companhia Nacional de Abastecimento   |
| CONAMA | Conselho Nacional do Meio Ambiente    |
| IGAM   | Instituto Mineiro de Gestão das Águas |
| GUI    | Graphical User Interface              |
| SIG    | Sistemas de Informação Geográfica     |
| MLP    | Multi-Layer Perceptron                |
| MATLAB | MATrix LABoratory                     |

## SUMÁRIO

|  |           |
|--|-----------|
| <b>1 INTRODUÇÃO.....</b>   | <b>9</b>  |
| <b>1.2 Objetivos.....</b>  | <b>11</b> |
| <b>1.2.1 Objetivos Específicos.....</b>                          | <b>11</b> |
| <b>1.3 Organização da monografia.....</b>                        | <b>12</b> |
| <b>2 REVISÃO BIBLIOGRÁFICA.....</b>                              | <b>13</b> |
| <b>2.1 Redes Neurais Artificiais.....</b>                        | <b>13</b> |
| <b>2.1.1 O cérebro e o neurônio biológico .....</b>              | <b>14</b> |
| <b>2.1.2 Neurônio artificial .....</b>                           | <b>15</b> |
| <b>2.1.2 Arquitetura das Redes Neurais Artificiais.....</b>      | <b>17</b> |
| <b>2.1.1 Multi-Layer Perceptron .....</b>                        | <b>18</b> |
| <b>2.1.2 Redes Neurais Artificiais convolutivas.....</b>         | <b>20</b> |
| <b>2.1.3 Aprendizado .....</b>                                   | <b>21</b> |
| <b>2.1.4 Backpropagation .....</b>                               | <b>22</b> |
| <b>2.2 Matlab.....</b>   | <b>24</b> |
| <b>2.2.1 Toolbox de RNA .....</b>                                | <b>25</b> |
| <b>2.3 Sensoriamento remoto.....</b>                             | <b>26</b> |
| <b>2.2.2 Produtos do sensoriamento remoto.....</b>               | <b>29</b> |
| <b>2.2.3 Bandas.....</b>   | <b>31</b> |
| <b>2.3 Classificação de imagens de satélite .....</b>            | <b>33</b> |
| <b>2.3.1 O problema da identificação automática de café.....</b> | <b>34</b> |
| <b>3 MATERIAIS E METODOS .....</b>                               | <b>36</b> |
| <b>3.1 Área de estudo .....</b>                                  | <b>36</b> |
| <b>3.1 Pré-processamento da imagem .....</b>                     | <b>37</b> |
| <b>3.3 Definição da arquitetura da RNA.....</b>                  | <b>39</b> |
| <b>3.4 Treinamento e validação .....</b>                         | <b>39</b> |

|                                      |           |
|--------------------------------------|-----------|
| <b>4 RESULTADOS .....</b>            | <b>41</b> |
| <b>4.1 Resultados Esperados.....</b> | <b>41</b> |
| <b>5 CONCLUSÃO .....</b>             | <b>42</b> |
| <b>Referências .....</b>             | <b>44</b> |



## 1 INTRODUÇÃO

A classificação digital de imagens de satélite tem ganhado, nas últimas décadas, reconhecimento como técnica para suprir a escassez dos mapeamentos temáticos. Com uma realidade geográfica cada vez mais complexa, novos sensores, com maior resolução espacial, encontram-se disponíveis no mercado, aumentando potencialmente seu uso, tornando necessária a existência de ferramentas que auxiliem a análise espacial dos fenômenos que envolvam uma grande massa de dados e que tenham relação com o espaço de acontecimento dos mesmos. Estas novas imagens demandam novas técnicas de análise, pois oferecem um maior grau de detalhe, o que possibilita a identificação de áreas em função de suas propriedades espectrais e espaciais.

Nos últimos anos, com o aumento de satélites em órbita da Terra, o volume de dados coletados tornou-se muito grande e praticamente impossível de ser tratado por métodos convencionais de interpretação visual (Moreira, 2003). Isso, sem dúvida, foi o grande estímulo para que pesquisas relacionadas à classificação automática de imagens fossem intensificadas.

As informações contidas em imagens de satélite podem ser extraídas através da classificação digital destas imagens. Existem vários métodos de classificação, que buscam identificar a informação de cada pixel da imagem, classificando-o em categorias de acordo com sua informação espectral.

Para classificar dados de diferentes origens as Redes Neurais Artificiais (RNAs) são atualmente uma opção emergente. A utilização RNAs surge como uma alternativa vantajosa aos classificadores de imagens baseados em conceitos estatísticos, como o Máxima Verossimilhança.

As Redes Neurais Artificiais (RNAs) funcionam conceitualmente de forma similar ao cérebro humano, tentando reconhecer regularidades e padrões.

As RNAs são capazes de aprender com a experiência e fazer generalizações baseadas no seu conhecimento previamente acumulado.

O mapeamento da ocupação da terra constitui uma das mais importantes atividades de geração de informações para gerenciamento e monitoramento de ambientes agrícolas. E quando se tem como alvo lavouras de café é preciso ter em conta que estas estão inseridas num contexto ambiental, havendo, portanto, interferências múltiplas, tanto dos objetos adjacentes, quanto das variações de suas próprias características.

Minas Gerais é o estado que se destaca entre os demais estados brasileiros em área plantada e quantidade produzida de café. Mas apesar de ser o estado de maior relevância para a produção do País com uma participação de 50,99% do total produzido no país (CONAB, 2008), Minas ainda não dispõe de dados precisos sobre a extensão e distribuição das áreas cafeeiras, dificultando o subsídio das atividades de planejamento de sua cafeicultura e garantia de sustentabilidade econômica, social e ambiental.

O conhecimento do ambiente em que o café está inserido permite um melhor planejamento da produção, visando o desenvolvimento sustentável e a obtenção de produtos com qualidade, uma vez que os fatores ambientais exercem grande influência sobre a qualidade da bebida. Os produtos gerados a partir de um Sistema de Informação Geográfica (SIG) possibilitam aos pesquisadores e produtores rurais uma visualização e interpretação da atividade cafeeira, a obtenção de estimativas de produção e produtividade e uma melhor avaliação das influências ambientais.

Nos grandes projetos de mapeamento, a técnica de interpretação visual é ainda muito utilizada, mesmo com diversos algoritmos de classificação de imagens já desenvolvidos. Este processo feito pelo homem é muito eficaz, porém sujeito às falhas ocasionadas pelo cansaço, fadiga e etc. Outro fator importante no processo, é que nem sempre profissionais com a mesma

competência possuem a mesma opinião sobre a imagem. Portanto, há uma tendência de utilização cada vez maior da classificação computacional, pela rapidez e facilidade em obter resultados (COSTA, 1999).

Os classificadores de imagens convencionais utilizados pelos Sistemas de Informação Geográfica (SIG) são de difícil parametrização e em muitos casos são inadequados para as necessidades de alta acurácia exigida pelos usuários (INPE, 2002). A fim de se conseguir melhores resultados e facilitar a parametrização dessas ferramentas, optou-se por criar um classificador de imagens baseado em Redes Neurais Artificiais.

## **1.2 Objetivos**

O objetivo deste trabalho é a implementação de um software de classificação de áreas cafeeiras em imagens de satélite utilizando RNAs, estimando a porcentagem de cobertura do solo.

### **1.2.1 Objetivos Específicos**

Como objetivos específicos têm-se:

- Implementar um software que utilize as RNAs para a classificação da imagem, com variação das camadas intermediárias, taxas de aprendizado, momentum;
- Avaliar o potencial das RNAs na classificação;
- Avaliar o método proposto na identificação de áreas cafeeiras, corpos d'água, área urbana e outros usos;
- Comparar esta metodologia com outras abordagens e diferentes tipos de classificação.

### **1.3 Organização da monografia**

O seguinte trabalho encontra-se dividido em 5 capítulos. O capítulo 1 é uma introdução ao tema abordado. O capítulo 2 trata-se de uma revisão bibliográfica onde encontra-se um resumo de todo conteúdo e conhecimento utilizado neste trabalho, dividido em subseções a saber: a seção 2.1 Redes Neurais Artificiais aborda os assuntos pertinentes as RNAs como: o neurônio biológico e o artificial, arquitetura das RNAs, Multi-Layer Perceptron, Redes Neurais Artificiais convolutivas, aprendizado, backpropagation, a seção 2.2 fala sobre o software Matlab e o toolbox de RNAs que será utilizado neste trabalho, a seção 2.3 Sensoriamento remoto aborda os aspectos teóricos do sensoriamento remoto, os produtos gerados que são as imagens de satélite, a classificação destas imagens e o problema da classificação automática do café. O capítulo 3 é destinado aos Materiais e Métodos que é a metodologia proposta para a realização do trabalho, neste capítulo estão: a origem dos dados que serão utilizados, o pré-processamento da imagem, a definição da arquitetura, o treinamento da rede neural e a validação dos resultados. No capítulo 4 estão os resultados esperados. E por fim, no capítulo 5 temos a conclusão do trabalho.

## **2 REVISÃO BIBLIOGRÁFICA**

Este capítulo apresenta informações sobre os principais temas abordados para o desenvolvimento deste trabalho, assim como os principais conceitos utilizados.

### **2.1 Redes Neurais Artificiais**

Redes Neurais Artificiais (RNAs) constituem um campo da Ciência da Computação ligado à Inteligência Artificial, que implementa modelos matemáticos que se assemelhem à capacidade de se adaptar através da interação com o meio externo. Tem como propriedade mais importante a capacidade de aprender por intermédio de exemplos (treinamento) e fazer inferências sobre o que aprendeu, melhorando gradativamente o seu desempenho.

São estruturas computacionais construídas com base no funcionamento do cérebro e seus neurônios, com o objetivo de simular nos computadores a capacidade de aprender do cérebro humano. Esta estrutura é composta de ligações entre neurônios, sendo que estas ligações formam diversos tipos de topologias, que trabalham em paralelo para classificar e generalizar dados de entrada em classes de saída. Os pesos entre as unidades são modificados até que a rede esteja apta a operar resultados desejados. O aprendizado da rede é determinado por um processo repetitivo que tenta adequar os pesos a uma saída esperada para cada amostra de treinamento. Este ajustamento nas ligações entre os neurônios durante o processo de aprendizado é uma das mais importantes características das redes neurais artificiais. Tais redes usam o treinamento supervisionado realizado por um algoritmo chamado de retro-propagação do erro (Error Backpropagation), o qual é baseado na regra de aprendizagem que “corrige” o erro durante o treinamento (BOCANEGRA, 2002).

Diversas pesquisas têm sido realizadas utilizando Redes Neurais Artificiais (RNA) como instrumento de classificação de imagens digitais, como por exemplo, na detecção de focos de incêndio (TORINO E BARRETO, 2002); na classificação de áreas agrícolas, na separação de culturas (VIEIRA, 2000); na medicina para a detecção de câncer em Mamogramas Digitalizados (KINOSHITA, MARQUES E FRERE, 2000); no desenvolvimento de métodos para a detecção de movimentos de objetos, através de sequência de imagens digitais (FERNANDEZ – CABALLERO E AL, 2003) entre outras.

A utilização de modelos de RNAs em classificação possibilita a incorporação não apenas de dados multiespectrais, mas de dados adquiridos por outras fontes, mesmo que não apresentem natureza espectral. Nessas situações, as RNAs parecem desempenhar a tarefa de classificação de imagens tão bem, ou melhor, que as técnicas estatísticas, uma vez que não requerem que a natureza paramétrica dos dados a serem classificados seja explicitada (GALO et al., 2000).

Através de um processo de treinamento, as redes neurais passam a ser capazes de reconhecer padrões, mesmo que os dados utilizados nesse treinamento sejam não-lineares, incompletos ou até mesmo contraditórios.

### **2.1.1 O cérebro e o neurônio biológico**

De acordo com Haykin (2001), o cérebro é um sistema de processamento de informação altamente complexo, não-linear e paralelo. Ele tem a capacidade de organizar seus constituintes estruturais, conhecidos por neurônios, de forma a realizar certos processamentos (p. ex., reconhecimento de padrões, percepção e controle motor) muito mais rápido que o mais ágil computador hoje existente. Sua capacidade de manipular dados, e a maneira que permite constituir imagens mentais de pessoas, lugares e eventos baseado em

fragmentos de informação, como sons ou cheiros familiares, ou simplesmente a lembrança de uma data de calendário, através da organização estrutural de seus neurônios. Esta organização estrutural (espécie de rede) estimula pesquisadores a tentar imitar o comportamento do cérebro.

Um neurônio é uma célula formada por três seções com funções específicas e complementares: corpo, dendritos e axônio. Os dendritos captam os estímulos recebidos em um determinado período de tempo e os transmitem ao corpo do neurônio, onde são processados. Quando tais estímulos atingirem determinado limite, o corpo da célula envia novo impulso que se propaga pelo axônio e é transmitido às células vizinhas por meio de sinapses. Este processo pode se repetir em várias camadas de neurônios. Como resultado, a informação de entrada é processada, podendo levar o cérebro a comandar reações físicas. A Figura 2.1 ilustra de forma simplificada as partes de um neurônio.




Figura 2.1 Modelo de um neurônio biológico

### 2.1.2 Neurônio artificial

A busca por um modelo computacional que simule o funcionamento das células do cérebro data dos anos 40, com o trabalho de McCulloch e Pitts em 1943. Em 1958 Rosenblatt propôs um método inovador de aprendizagem para as

redes neurais artificiais denominado Perceptron. No final dos anos 80, o entusiasmo ressurgiu graças a avanços metodológicos importantes e ao aumento dos recursos computacionais disponíveis.

O modelo matemático de neurônio artificial da FIGURA é uma simplificação do modelo apresentado por Haykin (2001).

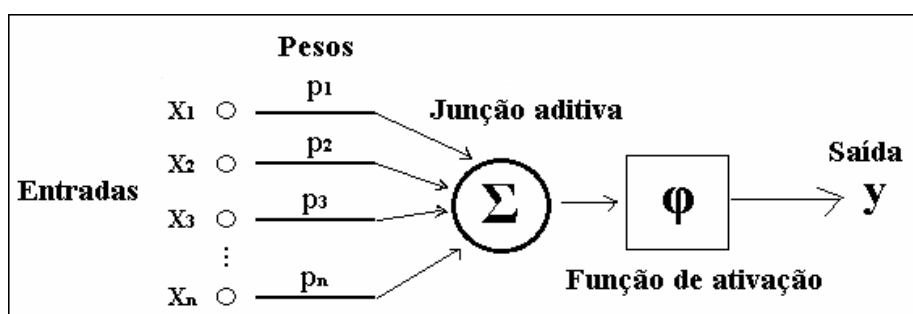


Figura 2.2 Modelo matemático de um neurônio

Fonte: HAYKIN, 2001.

Este modelo é composto por três elementos básicos:

- Um conjunto de  $n$  conexões de entrada ( $x_1, x_2, \dots, x_n$ ), caracterizadas por pesos ( $p_1, p_2, \dots, p_n$ );
- Um somador ( $\Sigma$ ) para acumular os sinais de entrada;
- Uma função de ativação ( $\phi$ ) que limita o intervalo permissível de amplitude do sinal de saída ( $y$ ) a um valor fixo.

As redes neurais artificiais são organizadas em camadas que compõem sua topologia ou arquitetura. Existem redes neurais de camada simples (perceptron) constituídas por um grupo de neurônios arranjados em apenas uma camada, e as redes de múltiplas camadas, conhecidas com MLP (Multilayer Perceptron), formadas por várias camadas intermediárias ou pela combinação de várias redes de camadas simples como mostra a Figura 2.3.






Figura 2.3 Rede de múltiplas camadas

Fonte: [www.abdelrahmanogail.wordpress.com/2010/05/10/multlayer-perceptron](http://www.abdelrahmanogail.wordpress.com/2010/05/10/multlayer-perceptron)

### 2.1.2 Arquitetura das Redes Neurais Artificiais

A arquitetura de uma rede refere-se à maneira como os elementos de processamento, neurônios e suas camadas, são organizados, o que afeta o desempenho da rede, uma vez que sua estrutura está intimamente ligada ao algoritmo de aprendizado usado na fase de treinamento da rede.

A camada de entrada de uma rede neural é aquela na qual os padrões são apresentados à rede. Esta camada se comunica com as demais por meio de um sistema de conexões ponderadas; as camadas intermediárias (ou ocultas) são responsáveis por grande parte do processamento, podendo ser consideradas como extratoras de características; e a camada de saída é aquela onde o resultado final é concluído e apresentado.

A arquitetura de uma rede neural é definida pelo número de camadas (camada única ou múltiplas camadas), pelo número de nós em cada camada, pelo tipo de conexão entre os nós e por sua topologia (HAYKIN, 2001).

Segundo Haykin (2001), adicionando-se uma ou mais camadas ocultas, tornamos a rede capaz de extrair estatísticas de ordem elevada. Os neurônios da camada de entrada da rede fornecem os respectivos elementos do padrão de ativação (sinais de entrada), que constituem os sinais de entrada aplicados aos neurônios na segunda camada (camada oculta). Os sinais de saída da segunda camada são utilizados como entradas para a terceira camada, e assim por diante. O conjunto de sinais de saída dos neurônios da camada de saída da rede constitui a resposta global da rede para o padrão de ativação fornecido pelos nós de fonte da camada de entrada.

### **2.1.1 Multi-Layer Perceptron**

Tipo de rede neural conhecida na literatura como rede de múltiplas camadas. Este tipo de rede neural permite a execução de tarefas como a simulação de séries temporais, reconhecimento de padrões, entre outras aplicações. Sua arquitetura está baseada em camadas de neurônios, que se interligam através de conexões sinápticas. Cada neurônio de uma camada conecta-se com a totalidade de neurônios de suas camadas adjacentes. Estas conexões também denominadas pesos sinápticos, transformam o sinal de entrada da rede ativando os neurônios pelas camadas internas até a camada de saída, onde obtém-se a resposta desejada (MEDEIROS, 2003).

No caso particular de aplicações em classificação de imagens de sensoriamento remoto, diversos trabalhos (HEPNER, 1990; BENEDIKTSSON et al., 1990; LIU et al., 1991) fizeram uso de RNA, aplicando uma rede de multicamadas para resolver o problema de classificação. Este tipo de rede caracteriza-se por assumir regiões de decisão semelhantes àsquelas formadas por um classificador estatístico, porém com entradas não correlacionadas e distribuições diferentes para os dados (LIPPMANN, 1987).

As redes do tipo MLP têm sido utilizadas com sucesso para a solução de vários problemas envolvendo altos graus de não-linearidade. O algoritmo de aprendizado mais utilizado para o treinamento destas redes é o algoritmo retro-propagação (backpropagation) (PICOLI, 2006). Seu treinamento é do tipo supervisionado e é baseado numa regra de aprendizagem que “corrige” o erro durante o treinamento (BOCANEGRA, 2002).

Devido a grande maioria dos problemas práticos serem não linearmente separáveis, a rede perceptron multicamadas gerou muito interesse pela habilidade em aprender a reconhecer padrões desta natureza, tendo assim uso generalizado.

De acordo com VIEIRA (2000 p.250), as principais características, desta rede, são:

- Adequado para problemas não linearmente separáveis.
- Rede neural com, no mínimo, três camadas, sendo: camada de entrada, camada(s) intermediária(s) ou escondida(s), camada de saída. Sendo que um neurônio interliga vários outros neurônios de outra camada.
- Vários neurônios podem ser combinados para computar problemas mais complexos.
- Possui um algoritmo de aprendizado, podendo assim melhorar seu desempenho.
- O algoritmo de aprendizado deste modelo funciona por ciclos. Em cada ciclo, um conjunto de padrões é apresentado à rede neural, e calculado o erro em relação ao resultado esperado. O erro é usado para atualizar os pesos, e então um novo ciclo é aplicado.
- Possuem entradas e saídas binárias que assumem os valores +1 ou -1;
- A função de ativação é a função sigmóide;

### 2.1.2 Redes Neurais Artificiais convolutivas

Uma rede convolutiva é um Perceptron de múltiplas camadas projetado especificamente para reconhecer formas bidimensionais, por exemplo, uma imagem com um alto grau de invariância quanto à translação, escalonamento, inclinação e outras formas de distorção (HAYKIN, 2001).

A figura ilustra um exemplo de rede neural convolutiva.




Figura 0.4 Exemplo de rede neural convolutiva

Fonte: <http://www1.i2r.a-star.edu.sg/~irkhan/conn2.html>

Por exemplo, a convolução de uma imagem ( $N \times N$ ) com um *kernel* ( $K \times K$ ) pode ser entendido por uma janela deslizante ( $K \times K$ ) sobre a imagem de entrada iterativamente. Para cada posição da janela, um *pixel* de saída é gerado tomando a média do *kernel* com a entrada de *pixels*. Uma rede convolutiva possui diversas camadas e cada uma com diversos mapas. A primeira camada tem apenas um mapa característico que é a imagem de entrada em si. Nas camadas seguintes, cada mapa característico mantém um certo número de

*kernels* igual ao número dos mapas na camada anterior. O tamanho de cada *kernel* em um mapa é um parâmetro de projeto. Os valores de *pixel* em um mapa são obtidos por convolução do *kernel* com os mapas correspondentes da camada anterior. O número de mapas de recurso na última camada é igual ao número de opções de saída, ou seja, resultados desejados.

### **2.1.3 Aprendizado**

Existem diversos tipos de RNA e diferentes maneiras de classificá-las. Talvez a mais importante seja quanto à forma de aprendizado que pode ser supervisionada e não-supervisionada.

Segundo Haykin (2001, p.75), uma rede neural aprende acerca do seu ambiente através de um processo iterativo de ajustes aplicados a seus pesos sinápticos. Haykin (2001) define que a aprendizagem é um processo pelo qual os parâmetros livres de uma rede neural são adaptados através de um processo de estimulação pelo ambiente no qual a rede está inserida.

A rede neural pode ser treinada para resolver problemas de classificação multiespectral. Segundo RIBEIRO e CENTENO (2002, p.57) treinar uma rede neural significa ajustar a sua matriz de pesos, de forma que o vetor de saída coincida com um certo valor desejado para cada vetor de entrada, de forma supervisionada ou não.

No aprendizado supervisionado considera-se que o analista possui o conhecimento sobre o ambiente, é capaz de representá-lo por um conjunto de amostras, são sucessivamente apresentadas à rede conjuntos de padrões de entrada e seus correspondentes padrões de saída, já que o ambiente é desconhecido pela rede neural. A rede realiza um ajustamento dos pesos das conexões entre os elementos de processamento, segundo uma determinada lei de aprendizagem, até que o erro entre os padrões de saída gerados pela rede

alcancem um valor mínimo desejado. Por exemplo, *perceptron*, *adaline* e *madaline*, *backpropagation*, são algumas dentre as dezenas de leis de aprendizagem supervisionada. Desta forma o conhecimento do ambiente disponível ao analista é transferido à rede neural através do treinamento (HAYKIN, 2001).

No aprendizado não-supervisionado não há um crítico para supervisionar o processo de aprendizagem e nem exemplo da função a ser aprendida pela rede. A própria rede “analisa” os conjuntos de dados apresentados a ela, determina algumas propriedades dos conjuntos de dados e “aprende” a refletir estas propriedades na sua saída. Uma vez ajustada à rede as regularidades estatísticas dos dados de entrada, ela desenvolve a habilidade de formar representações internas para codificar as características da entrada e assim criar automaticamente novas classes (HAYKIN, 2001; MURION, 1996).

Os exemplos mais conhecidos de algoritmos para aprendizado supervisionado são a regra delta e a sua generalização para redes de múltiplas camadas, o algoritmo backpropagation, esse algoritmo, derivado da Regra Delta Generalizada (HAYKIN, 1994), permite um ajuste de pesos em cada uma das camadas da rede e é projetado para minimizar a soma do erro médio quadrático entre a saída calculada por uma arquitetura de múltiplas camadas e a saída desejada.

#### **2.1.4 Backpropagation**

O algoritmo de treinamento “backpropagation” (retro-propagação) utilizado para treinar redes Perceptron Multicamadas permite um ajuste de pesos em cada uma das camadas da rede e é projetado para minimizar o erro médio quadrático entre a saída calculada por uma arquitetura multicamadas e a saída desejada. A parte principal do algoritmo de *backpropagation* é a maneira

interativa pela qual os erros utilizados para adaptar os pesos são propagados para trás, isto é, a partir da camada de saída para as camadas anteriores.

O algoritmo utiliza técnicas de gradiente descendente iterativo para minimizar uma função de custo igual a diferença média quadrada entre a saída desejada e a saída real da RNA.

Galo (2000) resume o processo de treinamento em duas fases distintas, começando com a definição de um conjunto arbitrário de pesos para as conexões da rede. Na primeira, um vetor de treinamento, com a respectiva saída desejada é apresentado à rede e propagado através de suas camadas para computar uma saída para cada elemento de processamento. As saídas dos nós da última camada são, então, comparadas com as saídas desejadas e a partir disso são calculados os termos de erro. A segunda fase envolve um retrocesso, ou seja, uma passagem de volta através da rede a partir da última camada, durante a qual, o erro é repassado para cada elemento de processamento e os pesos correspondentes são convenientemente alterados. Em um treinamento bem sucedido, este erro diminui com o aumento do número de iterações e o procedimento converge para um conjunto estável de pesos.

De acordo com VIEIRA (2000, p.264-265), apesar do grande sucesso do modelo de retro-propagação, existem alguns problemas que se deve citar, como o longo período de treinamento, principalmente para problemas complexos e mínimos locais. Podendo ocorrer também os pesos serem justados para valores muito grandes, levando a paralisar a rede.

Devido os problemas citados acima foi proposta por RUMELHART, HINTON E WILLIAMS em 1986 uma alternativa chamada de “momentum”, para diminuir o tempo de treinamento, assegurando um maior grau de estabilidade para a rede, mostrando-se eficiente em alguns casos. O termo momentum especifica a quantidade que será acrescentada da variação do velho para o novo peso.

## 2.2 Matlab

MATLAB é um sistema interativo de matrizes, de alta performance, que pode ser usado tanto para o ensino de matemática fundamental quanto para cálculos complexos de engenharia. O nome é uma abreviação de MATrix LABoratory (MATLAB) e foi originalmente desenvolvido com a intenção de facilitar o acesso a matrizes. Foi desenvolvido por “The Mathworks, Inc” no final da década de 70, contendo constantes atualizações e aperfeiçoamentos.

É um software fácil de ser usado onde os problemas e soluções são expressos quase que da mesma forma que no papel. Seus elementos básicos são matrizes que não requerem dimensionamento. Ele permite implementar e resolver problemas matemáticos muito mais rápida e eficientemente. .

Baseia-se no conceito que os dados podem ser representados como matrizes e, desse modo, a maioria das operações de análise numérica podem ser realizadas usando álgebra linear. Evita-se, assim, o uso excessivo de algoritmos de loops, pois as rotinas são feitas considerando as propriedades matemáticas das operações com matrizes, vetores e escalares.

O software MATLAB contém uma série de comandos versáteis para operações matemáticas, estatísticas e produção de gráficos de alta qualidade. Assim, ameniza-se os problemas que comumente são encontrados ao se efetuar até as mais simples análise de dados em programas (MIDDLETON, 2000).

O MATLAB ainda possui uma família de aplicativos específicos, os toolboxes, que são caixas de ferramentas, que permitem a criação de funções usadas para resolver determinados problemas tais como: otimização, manipulação algébrica, redes neurais, processamento de sinais, simulação de sistemas dinâmicos, entre outros, que estendem sua funcionalidade. O conjunto de toolboxes, que podem ser organizados conforme necessidades específicas, tornam o MATLAB uma poderosa ferramenta de análise de dados.



### 2.2.1 Toolbox de RNA

Neural Network Toolbox é uma ferramenta para elaboração, execução, visualização e simulação de redes neurais contida no software Matlab. A ferramenta fornece suporte completo para projetar e gerenciar redes neurais, além de simplificar a criação de funções e redes neurais personalizadas.

O toolbox de Redes Neurais do MATLAB possui ampla versatilidade e flexibilidade, haja visto que o seu uso possibilita a aplicação dos mais variados tipos de redes neurais além de permitir a modificação de redes já existentes, como alterações no número de camadas ou mesmo algoritmos de treinamento com uma facilidade particular de inserção.

Para a criação de uma RNA no software MATLAB faz-se uso da função `newff`. Os parâmetros de entrada necessários são: algoritmo de treinamento, função transferência, número máximo de iterações, número de camadas escondidas e o valor erro mínimo desejado. Para o treinamento da RNA utiliza-se a função `train` e para a classificação a função `sim`.

A versão da toolbox de redes neurais utilizada, disponibiliza uma ferramenta muito útil, o Graphical User Interface (GUI). Nesta janela, pode ser visualizada toda a atividade da rede na fase de treino, incluindo um esquema gráfico da arquitetura, o nome dos algoritmos utilizados, o n.º de iterações efetuadas, o tempo, a performance, o gradiente, e a visualização de gráficos. A Figura 2.5 mostra a janela parcial deste GUI, para a rede criada.

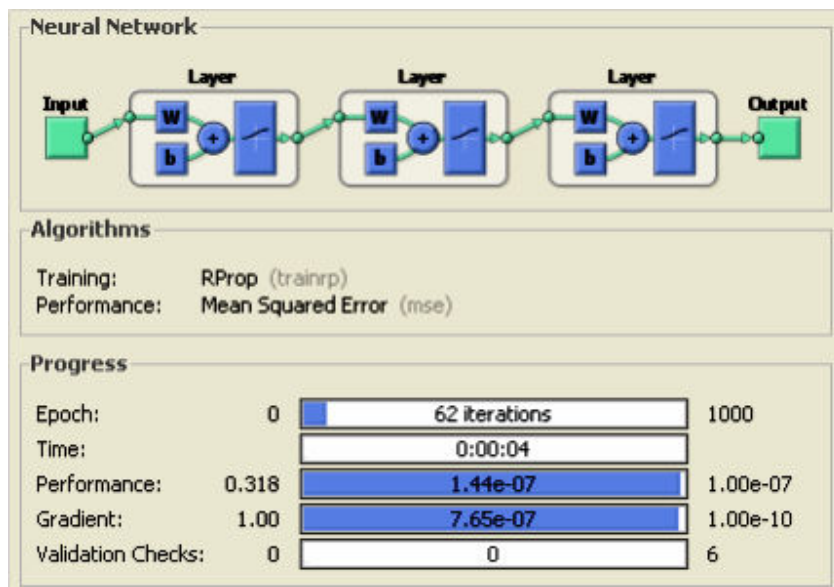


Figura 2.5 Modelo Graphical User Interface  
Fonte: MATLAB.

### 2.3 Sensoriamento remoto

O rápido desenvolvimento de novas tecnologias para coleta de informações geográficas, junto com o crescimento da demanda pela manipulação e análise interativa dessas informações, acarretou uma evolução sem precedentes da cartografia, que deu seu maior salto a partir da inovação propiciada pelos sensores remotos e, posteriormente, pela sua associação aos satélites da era orbital. A interpretação das imagens de satélite permitiu ao homem ampliar o conhecimento sobre a superfície da Terra e o uso do computador e de sistemas avançados para o tratamento das informações espaciais trouxe maior precisão na obtenção dos dados. Essas novas tecnologias, conhecidas como geotecnologias e que incluem os sistemas de informação geográfica e o sensoriamento remoto, tornaram-se ferramentas indispensáveis no processo de elaboração de mapas.

Sistemas de Informação Geográfica (SIG) são programas utilizados para o tratamento computacional de dados geográficos, ou seja, dados que representam objetos e fenômenos em que a localização geográfica é uma característica inerente e indispensável. O SIG armazena a geometria e os atributos dos dados que estão georreferenciados, isto é, localizados na superfície terrestre segundo uma projeção cartográfica. Além do armazenamento, esses sistemas realizam o tratamento, a análise e visualização das geoinformações, possibilitando a apresentação ao usuário final de forma compreensiva e facilmente interpretável. Uma característica básica do SIG é a de tratar relações espaciais entre objetos geográficos. Portanto, aplicações em estudos ambientais podem abranger desde a escala global à regional ou local (CÂMARA et al., 1996).

O monitoramento dos recursos naturais por meio das geotecnologias permite a rápida detecção de alterações ambientais, pois os satélites realizam a varredura da superfície terrestre de forma repetitiva e em um curto espaço de tempo (VIEIRA et al., 2007). Dessa forma, o emprego das geotecnologias e da cartografia digital tem possibilitado ao Brasil, a partir da década de 90, o mapeamento de seu ambiente físico com maior rapidez e menor custo, ainda que de forma modesta (MEIRELES et al., 2007). Tal mapeamento é de extrema importância no processo de planejamento do uso racional e sustentável dos recursos naturais pelas atividades antrópicas, dentre elas a agropecuária.

Na área do sensoriamento remoto, um aspecto que tem experimentado maior aprimoramento é a resolução espacial. Esta evolução nos sistemas sensores tem revolucionado os paradigmas da interpretação de imagens, tornando viável a identificação de construções com muito mais detalhes, bem como outros objetos que anteriormente não eram.

Os sistemas de aquisição de dados de Sensoriamento Remoto, definidos como sistema sensores, constituem-se de qualquer equipamento capaz de

transformar a radiação eletromagnética refletida pelos alvos da superfície terrestre em um sinal passível de ser convertido em informações sobre o meio ambiente (NOVO, 1989).

As imagens obtidas por sensores remotos são o produto de interações da radiação com a atmosfera e com a superfície. A distinção entre os padrões de uso da terra é possível devido ao comportamento específico dos objetos com a radiação eletromagnética, em função do comprimento de onda e das características bio-físico-químicas dos alvos.

Os usuários dessas imagens necessitam de uma análise qualitativa e quantitativa. A execução da avaliação quantitativa é realizada eficientemente por meio de sistemas computacionais, pois pode ser processada de maneira digital. A metodologia para a análise quantitativa das imagens digitais é chamada de classificação digital de imagens (RICHARDS, 1993).

A classificação de imagens de Sensoriamento Remoto consiste em estabelecer um processo de decisão no qual um pixel ou um grupo de pixels é definido como pertencente a uma determinada classe. Essa classificação representa uma boa opção na coleta de dados sobre a superfície terrestre reduzindo custo e tempo necessários à sua realização. O processamento de imagens de satélite para fins de mapeamento representa uma ferramenta de grande utilidade devido à sua grande abrangência em termos de área, periodicidade de imageamento em intervalos curtos, possibilidade de análise visual e espectral e baixo custo de aquisição. A classificação de imagens multiespectrais visa à categorização da cobertura da terra distinguindo as composições de diferentes materiais superficiais.

A identificação de feições em imagens capturadas por sensoriamento remoto é feita através da habilidade do analista em diferenciar padrões, utilizando seu conhecimento intuitivo e o de fotointerpretação sobre a área de estudo. O intérprete fica limitado de executar esta mesma função com as

imagens digitais, pois estas são multiespectrais. Além disto, o intérprete não tem acuidade visual para discriminar o limite da resolução radiométrica dos sensores atuais. Portanto a interpretação visual de imagens digitais gera produtos com algumas limitações (BRONSVELD et al, 1994).

Na classificação automática os valores de nível de cinza de cada pixel são agrupados e associados a um tipo de cobertura da superfície terrestre. Quando é efetuada para todos os pixels o resultado é um mapa temático mostrando a distribuição geográfica daquela área.

O uso de RNAs, aliado ao aumento de variáveis derivadas da imagem, que oferece a abordagem de classificação baseado em regiões, é uma alternativa viável e interessante no sensoriamento remoto, especialmente na classificação de imagens de alta resolução espacial.

### **2.2.2 Produtos do sensoriamento remoto**

Um dos produtos do sensoriamento remoto é a imagem digital. Essa imagem traz consigo informações coletadas pelo sensor no momento de sua passagem por determinada área. As imagens geradas por sensores orbitais são imagens chamadas matriciais, pois têm uma natureza discreta, ou seja, é formada de elementos independentes, dispostos na forma de uma matriz (SCHNEIDER, 2001). Cada elemento dessa matriz tem sua localização definida em um sistema de coordenadas do tipo linha e coluna, representados por  $x$  e  $y$ , respectivamente. A projeção de uma cena em um plano, normalmente representada como uma matriz de valores de intensidade luminosa, recebe o nome de imagem. Como os computadores não manipulam dados analógicos é necessário converter uma imagem contínua em sua forma digital.

A imagem digital corresponde à representação numérica do objeto, é uma função  $f(x, y)$  quantificada e amostrada, sendo a sua menor unidade

denominada de pixel (picture element). Uma imagem digital pode ser considerada como sendo uma matriz cujos índices de linhas e de colunas identificam um ponto na imagem, e o correspondente valor do elemento da matriz identifica a intensidade luminosa naquele ponto. Quanto mais pixels uma imagem tiver melhor é a sua resolução e qualidade. Na Figura 2.6, é possível visualizar a representação de uma imagem com 255 tons de cinza (SILVA, 2005).



Figura 2.6 Representação de uma imagem digital  
Fonte: SILVA, 2005.

A cada instante, uma pequena área do terreno é coberta por um sensor e o total de energia desta unidade de área é armazenado sob forma de um número digital através do processo de varredura. Tratando-se de uma imagem colorida ou multiespectral, várias matrizes são necessárias para armazenar os valores correspondentes à informação multiespectral desta imagem.

As imagens são classificadas em relação ao número de cores. Esta diferença na representação de uma imagem digital é decorrência do número de bits utilizado pelo dispositivo de aquisição na captura da mesma (SOUZA, 2000). Assim temos: imagem binária, na qual os pixels assumem apenas dois valores: 0 e 1, representando o preto e o branco respectivamente; imagem monocromática, cujos pixels podem assumir uma faixa de valores variando do

preto ao branco, correspondentes aos níveis de cinza; imagem colorida, pode ser vista como a sobreposição de três imagens monocromáticas, cada uma delas representando as intensidades das cores vermelho, verde e azul que compõem a imagem original.

### **2.2.3 Bandas**

Moreira (2003) comenta que as cenas coletadas pelos sensores podem ser imageadas por diferentes categorias de satélite, como os militares, científicos e meteorológicos. Os sensores utilizados para dados em nível orbital estão geralmente voltados para os estudos dos recursos naturais e operam em diferentes números de bandas que estão associadas aos comprimentos de onda. Dentre os sensores multiespectrais mais utilizados podem-se citar os sensores Thematic Mapper (TM) dos satélites Landsat, High Resolution Visible (HRV) do satélite SPOT, e os sensores embarcados nos satélites IKONOS e QUICKBIRD.

O TM opera em 7 faixas espectrais, também chamadas bandas espectrais do espectro eletromagnético, que correspondem a comprimentos de onda específicos de cada sensor. A resolução espacial é entendida como a capacidade do sensor em captar e registrar a menor área possível no terreno. No caso do sensor TM, a resolução espacial é de 30 x 30m no terreno, ou seja, tudo que estiver na superfície terrestre em uma área de 900m<sup>2</sup> será registrado em um único pixel da imagem produzida. Para a banda 6 essa resolução espacial é igual a 120 x 120m (ANDRADE, 2011).

As aplicações das bandas espectrais do satélite TM Landsat, segundo Silva & Francisco (2002) são:

- Banda 1 (0,450 - 0,520  $\mu\text{m}$ ) Azul: Útil para mapeamento de águas costeiras, diferenciação entre solo e vegetação, mapeamento de florestas

e detecção de feições culturais (mancha urbana, rodovias, etc.), entre outras.

- Banda 2 (0,520 - 0,600  $\mu\text{m}$ ) Verde: Corresponde à reflectância da vegetação verde e sadia. Também é útil para identificação de feições culturais.
- Banda 3 (0,630 - 0,690  $\mu\text{m}$ ) Vermelho: Útil para discriminação entre espécies de plantas e delinear solo e feições culturais. Permite um bom contraste entre áreas ocupadas com vegetação e aquelas sem vegetação, apresentando níveis de cinza mais escuros para áreas com vegetação e níveis mais claros para áreas descobertas. Apresenta bom contraste entre diferentes tipos de cobertura vegetal (ex.: campo, cerrado e floresta). Permite o mapeamento da drenagem através da visualização da mata galeria e entalhe dos cursos dos rios em regiões com pouca cobertura vegetal. É a banda mais utilizada para delimitar manchas urbanas e identificar áreas agrícolas.
- Banda 4 (0,760 - 0,900  $\mu\text{m}$ ) Infravermelho próximo: Permite estimar a quantidade de biomassa de vegetação presente em uma cena. É útil para identificação de culturas agrícolas, enfatizando a diferenciação solo/agricultura e água/solo. Apresenta sensibilidade à morfologia do terreno, permitindo o mapeamento de corpos d'água como rios, lagos, reservatórios, áreas úmidas de várzeas, geologia e geomorfologia e macrófitas aquáticas. Tem grande sensibilidade também à absorção da radiação eletromagnética pelos óxidos de ferro e titânio, comuns em solos muito intemperizados das regiões tropicais;
- Banda 5 (1,550 - 1,750  $\mu\text{m}$ ) Infravermelho médio: Apresenta sensibilidade ao teor de umidade das plantas, permitindo detectar estresse na vegetação causado pela falta de água. Também é usada para obter informações sobre a umidade do solo. Esta banda sofre



perturbações caso ocorra excesso de chuva antes da obtenção da cena pelo satélite.

- Banda 6 (10,40 - 12,50  $\mu\text{m}$ ) Infravermelho termal: Apresenta sensibilidade nos fenômenos relativos aos contrastes térmicos. Usada para estudos de propriedades termais de rochas, solos, vegetação e água. Também utilizada para mapeamento da temperatura de águas oceânicas superficiais.
- Banda 7 (2,080 - 2,350  $\mu\text{m}$ ) Infravermelho médio: Apresenta sensibilidade à morfologia do terreno. Importante para estudos nas áreas de Geomorfologia, Solos e Geologia. Muito usada para a discriminação de tipos de rochas e no estudo de solos, como também para detectar o grau de umidade em que se encontram os solos.

### **2.3 Classificação de imagens de satélite**

A Classificação Digital de imagens são procedimentos utilizados para separar e identificar os objetos na superfície terrestre detectado pelos sensores dos satélites. Segundo CRÓSTA (1992) a classificação digital é um processo que extrai informações das imagens digitais para o reconhecimento de padrões espectrais e objetos homogêneos com o auxílio da inspeção visual humana.

O INPE (2000) descreve que o processo de classificação pode ser basicamente dividido em dois tipos de classificadores: classificadores por pixel e os por região. Os classificadores por pixel utilizam as informações espectrais isoladas referentes a cada pixel para agregar as regiões homogêneas. Enquanto que os classificadores por região utilizam não somente as informações espectrais de cada pixel, mas também as informações espaciais que envolvem a relação entre os pixels e seus vizinhos.

A distinção entre os padrões de uso da terra é possível graças ao comportamento espectral específico dos objetos ao longo do espectro eletromagnético, ou seja, estes objetos da superfície terrestre interagem (reflectância, absorbância e transmitância) com a radiação eletromagnética de maneira diferenciada, em função do comprimento de onda, de acordo com suas características bio-físico-químicas.

De acordo com Ribeiro e Centeno (2002), a melhoria de informação visual para a interpretação humana e o processamento de dados de cenas para percepção automática por meio de máquinas, é o principal incentivador ao estudo dos métodos de processamento digital de imagens.

### **2.3.1 O problema da identificação automática de café**

Para mapear café, classificadores automáticos são raramente usados. Isso porque a resposta espectral dessa cultura é bastante complexa, em função das diversas variáveis que envolvem a caracterização da mesma e do ambiente em que está inserida (VIEIRA et al, 2006) , tais como, variações do estágio fenológico, vigor vegetativo, espaçamento das plantas nas lavouras e dos tratamentos culturais utilizados, existência de culturas intercalares, maior sombreamento devido ao relevo acidentado e baixa resolução espacial das imagens Landsat utilizadas. Além disso, sua resposta espectral se assemelha muito a da mata nativa, como visto na Figura 2.6.




Figura 2.7 Representação de uma imagem digital (ANDRADE, 2011)

Moreira et al. (2004) afirmam que, embora a cultura do café apresente variações no comportamento espectral devido a fatores como espaçamento, idade e época do ano, a mesma pode ser identificada e mapeada em imagens de satélites com razoável precisão.

### **3 MATERIAIS E METODOS**

Os materiais usados neste trabalho bem como os programas que serão utilizados durante o desenvolvimento serão descritos a seguir.

Para o desenvolvimento de um trabalho baseado em redes neurais artificiais são necessárias diversas etapas: definição do problema; coleta dos dados de treinamento e de teste; pré e pós-processamento dos dados; arquitetura da rede; treinamento; teste e validação.

#### **3.1 Área de estudo**

A área de estudo desse trabalho será a cidade de Três Pontas localizada no Sul de Minas Gerais. A região de Três Pontas apresenta uma cafeicultura em relevo mais suavizado e áreas de café contíguas (VIEIRA et al., 2006).

A região representa 70% da renda agrícola. Seu clima é do tipo tropical de altitude. A altitude média do município é de 905 metros, sendo que a máxima atinge 1.234 metros na Serra de Três Pontas. É uma região que pode ser considerada privilegiada para o mapeamento da cultura cafeeira, pois apresenta um relevo suave ondulado, que permite maior incidência de luz solar na cultura, obtendo assim uma melhor resposta espectral (SOUSA et al., 2009).

Os dados multiespectrais que serão utilizados para a classificação automática utilizando Redes Neurais Artificiais, correspondem a imagens orbitais TM/Landsat 5, bandas 3, 4 e 5, com data de passagem de 16/07/2007 adquiridas junto ao Instituto Nacional de Pesquisas Espaciais – INPE. A Figura 3.1 mostra a imagem que será utilizada para a classificação.




Figura 3.1 Imagem a ser utilizada na classificação (ANDRADE, 2011)

### 3.1 Pré-processamento da imagem

O reconhecimento de padrões em uma imagem depende muito da qualidade da própria imagem, portanto, para que não ocorram erros no reconhecimento é necessário que a imagem passe por um tratamento anterior, que visa melhorar as características destas, ou destacar os pontos de interesse, possibilitando aos sistemas melhores taxas de acerto.

A imagem a ser classificada e o mapa de classificação visual serão submetidos aos pré-processamentos necessários para que a rede seja capaz de reconhecer as mesmas classes nas imagens multiespectrais, são eles: correção atmosférica, restauração e registro geométrico.

A metodologia proposta irá separar os ambientes geomórficos, a fim de permitir uma melhor coleta de amostras; e incluir máscaras na rede de drenagem e na área urbana, diminuindo assim a quantidade e a variabilidade dos alvos observados nas imagens. Para o desenvolvimento desta máscara, será utilizada a Linguagem Espacial para Geoprocessamento Algébrico (LEGAL), do SPRING.

Para a realização da classificação, os dados de sensoriamento remoto foram submetidos aos pré-processamentos necessários para que a RNA fosse capaz de reconhecer as mesmas classes nas imagens multiespectrais. A metodologia utilizada foi fundamentada no trabalho de Andrade et al. (2011). A Figura 3.2 ilustra este processo.

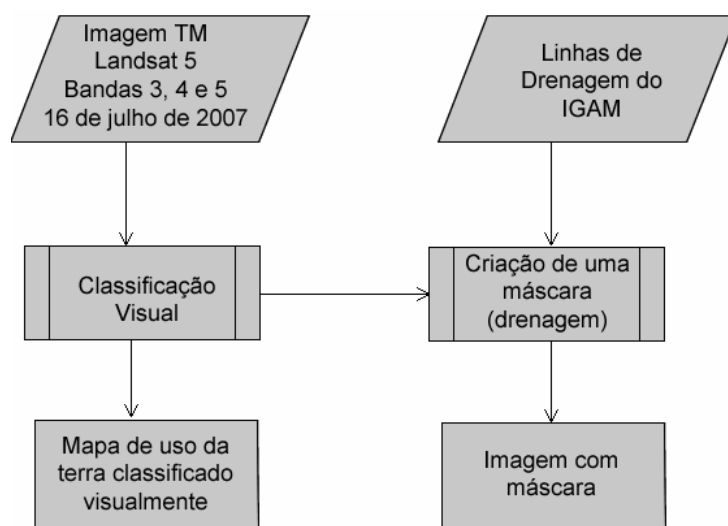


Figura 3.2 Pré-processamento da imagem (ANDRADE, 2010)

Foram utilizadas as linhas de drenagem do Instituto Mineiro de Gestão das Águas (IGAM), e sobre elas realizado o levantamento espacial das áreas que deveriam estar preservadas utilizando a relação de proximidade (buffer) criando-se uma máscara ao longo da rede de drenagem, em cada uma das três bandas,

seguindo a resolução 303/2002 do Código Florestal do CONAMA. Em seguida, foi realizado o cruzamento do buffer com o mapa de uso da terra, e atribuído o valor dez aos pixels que se encontravam nestas áreas, utilizando a Linguagem LEGAL do SPRING. Foi criada também, uma máscara na área urbana de Três Pontas e atribuído aos pixels o valor de 255 (ANDRADE, 2011).

### **3.3 Definição da arquitetura da RNA**

VIEIRA (2000) reporta que o algoritmo de aprendizado da rede neural mais utilizado na classificação de imagem oriundas do sensoriamento remoto é o retropropagação (backpropagation), com arquitetura multi-camadas (MLP).

A definição do número de neurônios uma rede neural multicamadas implica na determinação prévia da dimensionalidade dos dados de entrada e das classes. Para determinar o número de camadas de entrada, camadas escondidas e o número de neurônios de cada camada serão executados testes que ajudarão na escolha da arquitetura para a melhor classificação desta imagem.

Portanto na implementação deste trabalho será adotado um modelo de rede neural com estrutura de múltiplas camadas, treinada com algoritmo backpropagation.

Esses testes terão sua corretude testada através da análise do índice estatístico Kappa, para cada arquitetura testada.

### **3.4 Treinamento e validação**

Ao final de todo o processo de treinamento, todas as redes serão submetidas à validação, com um conjunto de amostras de teste independente do conjunto de amostras de treinamento. Após esse processo, a rede neural que

obteve o melhor desempenho é escolhida para ser utilizada na classificação do uso e cobertura da terra da área para cada composição da área avaliada.

A avaliação é a determinação do nível de exatidão ou confiança da classificação (índice Kappa) e da exatidão global da classificação de cada rede, através da análise da matriz de confusão (CONGALTON, 1991). Uma matriz de significância Kappa também será gerada para verificar a existência de diferenças significativas ou não entre os resultados obtidos e para a escolha da melhor arquitetura de rede para a classificação final das imagens (VIEIRA, 2000).



## **4 RESULTADOS**

Para avaliar o desempenho da RNA, será utilizado o índice Kappa que é baseado na construção de matrizes de erro, sendo este o método mais tradicional de verificação da precisão de uma classificação. O uso desse coeficiente é satisfatório na avaliação da precisão de uma classificação temática, pelo fato de levar em consideração toda a matriz de confusão no seu cálculo, inclusive os elementos de fora da diagonal principal, os quais representam as discordâncias na classificação (BERNARDES, 2006).

Para o cálculo do índice será necessária uma área de verificação (verdade de campo), onde todos os elementos da cena serão identificados. Neste trabalho usaremos como verdade de campo uma classificação feita visualmente da área de estudo.

Os índices de acurácia Kappa que serão obtidos na classificação por RNA poderão ser prejudicados pelos fatores ambientais que interferem no padrão espectral da imagem, tais como, variações do estágio fenológico, vigor vegetativo, do espaçamento das plantas nas lavouras e dos tratos culturais utilizados, existência de culturas intercalares, maior sombreamento devido ao relevo acidentado e baixa resolução espacial da imagem utilizada.

Segundo Foody & Arora (1997), a arquitetura de uma rede neural também pode ter uma influência significativa em sua habilidade para classificar dados de sensores remotos.

### **4.1 Resultados Esperados**

Espera-se que ao final deste trabalho tenhamos desenvolvido um sistema de classificação automática de áreas cafeeiras em imagens de satélite, com resultados superiores aos encontrados na literatura que variam de 70 a 80%.

## 5 CONCLUSÃO

A caracterização ambiental é fundamental para o planejamento da agricultura sendo que o nível de conhecimento desses fatores no tempo e espaço auxilia diretamente nesse planejamento. Como resultado de sua aplicação podemos obter zoneamentos e mapeamentos de culturas agrícolas, assim como sua evolução, localização e identificação de áreas adequadas a cada tipo de uso e exploração.

Segundo Medeiros et al (1996) novas técnicas e metodologias de mapeamento são evidenciadas, experimentadas e adotadas, a fim de agilizar o processo de tomada de decisão, minimizar e racionalizar custos operacionais e, concomitantemente, fornecer informações cada vez mais confiáveis num menor espaço de tempo.

Assim, redes neurais artificiais como classificação supervisionada, podem ser consideradas como uma alternativa aos classificadores atualmente utilizados para a classificação de imagens espectrais, uma vez que nenhuma hipótese prévia sobre a distribuição dos dados a serem classificados é exigida, não restringindo a possibilidade de incorporação de dados não espectrais na classificação.

A principal dificuldade na utilização de redes neurais artificiais na classificação, ainda é a determinação da arquitetura ótima da rede, visto que não há nenhuma teoria para se determinar, a priori do treinamento, a arquitetura que melhor resultado apresentaria na classificação. Ainda não se possui uma metodologia consistente para cada simulação proposta. (NEURAI,2004). A melhor forma de se estruturar uma rede é começar com poucas camadas escondidas e com poucos neurônios em cada camada. A complexidade da rede deve ser gradualmente aumentada, até que o resultado desejado seja obtido.

Trabalhos futuros visam incorporar à estrutura da RNA, atributos como forma e textura dos alvos, visto que estes são os atributos utilizados pela interpretação visual, em momentos onde a resposta espectral apenas não é suficiente.

## **Referências**

GALO, M. L. B. T. 2000. **Caracterização Ambiental do Parque Estadual Morro do Diabo através de dados e técnicas de Sensoriamento Remoto: Abordagens utilizando redes neurais artificiais**. Tese (doutorado em ciências da engenharia ambiental), Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2000. 205p.

ANDRADE, L. N.; **Redes neurais artificiais aplicadas na identificação automática de áreas cafeeiras em imagens de satélite**. Tese (mestrado em Ciência da computação), Universidade Federal de Minas Gerais, Belo Horizonte. 2011. 92p.

ANDRADE, L. N.; VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L. & SOUZA, V. C. O.. **Aplicação de Redes Neurais Artificiais (RNA) na análise e classificação de áreas cafeeiras da região de Machado-MG**. In IX Congreso Latinoamericano y del Caribe de Ingeniería Agrícola - XXXIX Congresso Brasileiro de Engenharia Agrícola (CLIA/CONBEA), Vitória/ES, 2010.

BENEDIKTSSON, J. A., SWAIN, P. H., ERSOY, O. K. **Neural Network Approaches Versus Statistical Methods in Classification of Multisource Remote Sensing Data**. IEEE Transactions on Geoscience and Remote Sensing, v. 28, n. 4, 1990.

BERNARDES, T. **Caracterização do ambiente agrícola do Complexo Serra Negra por meio de Sensoriamento Remoto e Sistemas de Informação**

**Geográfica.** Dissertação (Mestrado em Ciência do Solo) - Universidade Federal de Lavras, Lavras, 2006. 119 p.

BOCANEGRA, C.W.R.. Procedimentos **para tornar mais Efetivo o Uso das Redes Neurais Artificiais em Planejamento de Transportes.** Dissertação de Mestrado – Escola e Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2002.

BREAK, C. (2008). **Sul de minas: café representa 70% da renda agrícola.** Disponível em: <<http://www.coffeefreak.com.br/ocafezal.asp?SE=6&ID38>>. Acesso em: 15 set. 2011.

BRONSVELD, K.; CHUTIRATTANAPAN, S.; PATTANAKANOK, B.; SUWANWEAKAMTORN, R.; TRAKOOLDIT, P. **The use of local knowledge in land use/land cover mapping from satellite images.** ITC Journal. v. 4, 1994.

CÂMARA, G.; CASANOVA, M. A.; HEMERLY, A. S.; MAGALHÃES, G. C.; MEDEIROS, C. M. B. **Anatomia dos Sistemas de Informação Geográfica.** São José dos Campos: INPE, 1996. 193p.

CONGALTON, R. G. **A review of assessing the accuracy of classifications of remotely sensed data.** Remote Sensing of Environment, v.49, n.12, 1991.

CONSELHO NACIONAL DO CAFÉ. **História.** Disponível em: <<http://www.cncafe.com.br/conteudo.asp?id=2>>. Acesso em: 15 set. 2011.

COSTA, T.C.C. **Avaliação de estratégias para classificação de imagens orbitais em mapeamento de uso e cobertura da terra.** Dissertação (Doutorado em Ciência Florestal) - Universidade Federal de Viçosa, Viçosa. 1999. 109 p.

DAZZY, Rudimar L. S. **Sistemas especialistas connexionistas: implementação por redes diretas e bidirecionais.** Dissertação de mestrado, Universidade Federal de Santa Catarina, Programa de Pós-Graduação em Ciência da Computação, UFSC, Florianópolis, Santa Catarina. 1999.

EPIPHANIO, J. C. N.; LEONARDI, L.; FORMAGGIO, A. R. **Relações entre parâmetros culturais e resposta espectral de cafezais.** Pesquisa Agropecuária Brasileira. v. 29, n. 3, p. 439-447, mar. 1994.

FERNÁNDEZ, CABALLERO et al. **On Motion Detection Through a Multi-Layer Neural Network Architecture.** Neural Networks, v.13, 2000.

FOODY, G. M.; ARORA, M. K. **An evaluation of some factors affecting the accuracy of classification by an artificial neural network.** International Journal of Remote Sensing, v.18, n.4, 1997.

GALO, M. L. B. T. 2000. **Caracterização Ambiental do Parque Estadual Morro do Diabo através de dados e técnicas de Sensoriamento Remoto: Abordagens utilizando redes neurais artificiais.** Tese (doutorado em ciências da engenharia ambiental), Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2000. 205p.

GONZALES, R.C.; WOODS, R.E. **Processamento de Imagens Digitais.** Edgard Blücher Ltda. São Paulo, 2000. 527 p.

HAYKIN, S. **Neural Networks: A Comprehensive Foundation**. USA: Macmillan Publishing. 1994. 696p.

HAYKIN, S. **Redes Neurais. princípios e prática**. Porto Alegre: Bookman, 2001. 900 p.

HEPNER, G. F. **Artificial Neural Networks Classification using a Minimal Training Set: Comparison to Conventional Supervised Classification**. Photogrammetric Engineering and Remote Sensing, v. 56, n. 4, 1990.

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS. **Tutorial SPRING**. INPE, São José dos Campos. 2002.

KINOSHITA, S.K.; MARQUES, P.M.A. e FRÈRE, A.F. **Utilização da Análise de Componentes Principais e Redes Neurais Artificiais para a Classificação de Nódulos em Mamogramas Digitalizados**. Anais do CBEB'2000, 2000.

LIPPMANN, R. P.. **An introduction to computing with neural nets**. IEEE ASSP Magazine, v.4, 1987.

LIU, Z. K., XIAO, J. Y. **Classification of remotely-sensed image data using artificial neural networks**. International Journal of Remote Sensing, v. 12, n. 11, 1991.

MATLAB. **User's Guide – Neural Network Toolbox**, version 3.0. Mth Works. 1998.

DEMUTH, H. BEALE, M., HAGAN M. **“Neural Network Toolbox™6, User’s Guide”**, The Mathworks™, 2008.

MEDEIROS, L. F. **Redes neurais em delphi**. Florianópolis: Visual Books Editora, 2003. 115p.

MEIRELES, E. J. L.; VOLPATO, M. M. L.; ALVES, H. M. R.; VIEIRA, T. G.C. **Zoneamento agroclimático: um estudo de caso para o café**. Informe Agropecuário, Belo Horizonte, v. 28, n. 241, 2007.

MIDDLETON, G. V. **Data analysis in the Earth Sciences using MATLAB**. Prentice Hall, 2000. 260p.

MOREIRA, M. A. **Fundamentos do sensoriamento remoto e metodologias de aplicação**. 2 ed. - Viçosa: UFV, 2003. 307 p.

MURNION, S. D. **Comparison of Back Propagation and Binary Diamond Neural Networks in the Classification of a Landsat TM Image**. Computers & Geosciences, v.22, n.09, 1996.

NEURAI (2004) – Disponível em: <<http://www.din.uem.br/ia/neurais>>. Acesso em: 20 out. 2011.

NOVO, E. M. L. M. **Sensoriamento Remoto: Princípios e Aplicações**. São Paulo, Edgard Blücher. 1989.

PICOLI, M. C. A. **Estimativa da produtividade agrícola da cana-de-açúcar utilizando agregados de redes neurais artificiais: estudo de caso usina**



**Catanduva.** Dissertação (Mestrado em Sensoriamento Remoto), Instituto Nacional de Pesquisas Espaciais, São José dos Campos: INPE, 2006. 90p.

RIBEIRO, S. R. A.; CENTENO J. A. S. **Clasificación del uso del suelo utilizando redes neurales y el algoritmo maxver.** Innovación, Año 14 n.1, Antofagasta – Chile, 2002.

RICHARDS, B. **Remote sensing and digital image analysis.** Springer –Verlag, Berlin. 1993.

SILVA, Renato Ramos. **Reconhecimento de imagens digitais utilizando redes neurais artificiais.** Monografia (Graduação em Ciência da Computação). Universidade Federal de Lavras, Lavras – MG. 2005. 51 p.

SCHALKOFF, R. J. **Pattern Recognition: Statistical, Structural and Neural Approaches.** New York: John Wiley and Sons. 1992.

SOUZA, F. P. C., **Localização e Leitura Automática de Caracteres Alfanuméricos: Uma Aplicação na Identificação de Veículos.** Porto Alegre. Dissertação (Mestrado em Engenharia Elétrica) – Universidade Federal do Rio Grande do Sul. 2000. 96 p.

SOUSA, R. B.; VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L.; SOUZA, V.C. O.; SANTOS, W. J. R. & SILVA, E. 2009. **Mapeamento de áreas cafeeiras do Sul de Minas Gerais - Machado e Três Pontas.** In Simpósio de Pesquisa dos Cafés do Brasil (SPCB), volume 6, Vitória. Brasília: Embrapa Café, CD-ROM.

TORINO, C. V. e BARRETO, D. T. **Detecção de Fumaça Através do Processamento de Imagem Utilizando Redes Neurais em um Sistema Híbrido**. XIV Congresso Brasileiro de Automática, Natal – RN, 2002.

VIEIRA, C. A. O. **Accuracy Of Remotely Sensing Classification Of Agricultural Crops: A Comparative Study**, Thesis Submitted to the University of Nottingham for the Degree of Doctor of Philosophy, 2000. 396 p.

VIEIRA, T. G. C.; ALVES, H. M. R.; LACERDA, M. P. C.; VEIGA, R. D.; EPIPHANIO, J. C. N. **Crop parameters and spectral response of coffee (Coffea arabica L.) areas within the state of Minas Gerais, Brazil**. Coffee Science, v.1, n.2, 2006.

VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L.; SOUZA, V. C. O de.; BERNARDES, T. **Sistema de geoinformação para a cafeicultura do sul de Minas**. Informe Agropecuário, v.28, n.241, 2007.