

Discriminação de áreas cafeeiras de imagens multiespectrais da região de Três Pontas – MG através de Redes Neurais Artificiais e Extratores de Textura

Alexsandro Cândido de Oliveira Silva¹

Wilian Soares Lacerda¹

Lívia Naiara de Andrade¹

Tatiana Grossi Chquiloff Vieira²

¹Universidade Federal de Lavras – UFLA

Caixa Postal 3037 – 37200-000 – Lavras – MG, Brasil

alexsandrococ@yahoo.com.br

{lacerda, liviaandrade}@dcc.ufla.br

²Empresa de Pesquisa Agropecuária de Minas Gerais – EPAMIG

Caixa Postal 3037 – 37200-00 – Lavras – MG, Brasil

tatiana@epamig.ufla.br

Abstract: Remote Sensing Images show favorable to the study of spatial and temporal variations of the land surface. However the spectral information of these images may not be sufficient to discriminate objects that have similar pixel values as coffee areas and forests. An alternative is to use spatial attributes that consider the region and not only the pixel singly. In satellite images, coffee areas feature lines and shapes, whereas areas of natural vegetation are rough, irregulars and heterogeneous because of the various species of plants. Thus these two classes have different standards when it considers the regions itself and the texture was the spatial attribute chosen to be studied in this work. The application of the Artificial Neural Networks (ANNs) tends to be a promising approach for discrimination of classes of land use in satellite images. However, an ANN does not show a satisfactory performance when it uses only spectral data. In this work, it was developed a procedure for automatic pattern recognition using ANN and it was observed the potential of the inclusion of texture features in the class discrimination. The texture features were extracted from the LandSat5 image of the coffee region of Três Pontas, South of Minas Gerais. The ANN trained with the features of texture showed satisfactory performance proving that this kind of spatial attribute is significant in the discrimination of coffee areas and forests.

Palavras-chave: remote sensing, image processing, texture features, computational intelligence, sensoriamento remoto, processamento de imagens, características de textura, inteligência computacional.

1. Introdução

As imagens de sensoriamento remoto cobrem grandes extensões territoriais e são focos de estudos das informações da superfície da terra, já que registram a energia refletida e/ou emitida por objetos, áreas ou fenômenos, Florenzano (2002). Mas os dados espectrais propícios destas imagens, muitas vezes, não são suficientes na distinção de objetos alvos que tenham reflectância similar. Os valores digitais que identificam as regiões cafeeiras são similares aos de vários tipos de vegetação natural, o que causa confusão na separação entre essas classes e dificulta o bom desempenho de algoritmos de interpretação automática de imagens.

A variabilidade dos padrões de cultura cafeeira decorrente dos vários estados fenológicos, espaçamentos e talhões, culturas intercalares, o relevo que altera o sombreamento e a geometria de reflexão são alguns fatores que dificultam a definição de regras estatísticas para identificação de intervalos de nível de cinza referentes à cultura cafeeira, além de comprometerem o reconhecimento de padrões por classificadores automáticos baseados apenas no comportamento espectral dos alvos.

Uma alternativa aos métodos convencionais de classificação por pixel pode ser os classificadores que consideram atributos espaciais como características de textura do dossel da vegetação. Rocha e Leite (2002) afirmam que a textura é um dos atributos mais

importantes na classificação e reconhecimento de classes em imagens de sensoriamento remoto. A extração de características de textura pode aumentar o desempenho dos classificadores, já que podem diferenciar objetos que possuam características espectrais similares.

O desenvolvimento de algoritmos mais eficientes para manipulação de imagens digitais favorece o desenvolvimento de sistemas de reconhecimento de padrões e discriminação como as Redes Neurais Artificiais (RNA). Uma RNA é composta por unidades básicas de processamento, os neurônios artificiais, que são conectados em rede e processam a informação de forma paralela, Andrade (2011). Algumas de suas características são a capacidade de aprender, tomadas de decisões e, principalmente, a generalização da informação em que a rede aprende a lidar com um problema e é capaz de reconhecer e fornecer uma solução quando lhe é apresentado outro similar, Andrade (2011), Martins et al. (2002).

O treinamento de uma RNA é a aprendizagem, a aquisição do conhecimento. Esse conhecimento é armazenado nas conexões entre os neurônios. O processo de treinamento de uma rede é determinar a intensidade da conexão entre os neurônios, Barreto (2002). Uma RNA treinada apenas com dados espectrais das imagens de satélite não apresenta uma discriminação satisfatória entre áreas cafejeiras e matas. Estudos comprovam que a inserção de atributos de textura aumenta o desempenho da RNA, Rennó (1998).

Portanto, esse trabalho objetiva-se a desenvolver um procedimento para discriminação automática de classes de uso da terra utilizando abordagens baseadas em paradigmas de aprendizado de máquina e atributos espaciais de imagens de satélites.

2. Metodologia de Trabalho

2.1 Área de estudo e imagem de satélite

A área escolhida para estudo foi a região cafeeira de Três Pontas que se localiza na região sul do estado de Minas Gerais (Figura 1). Esta região apresenta um relevo predominantemente suave ondulado a ondulado, apresenta uma cafeicultura em relevo mais suavizado e áreas de café contíguas que representam em torno de 70% da renda agrícola, Andrade (2011).

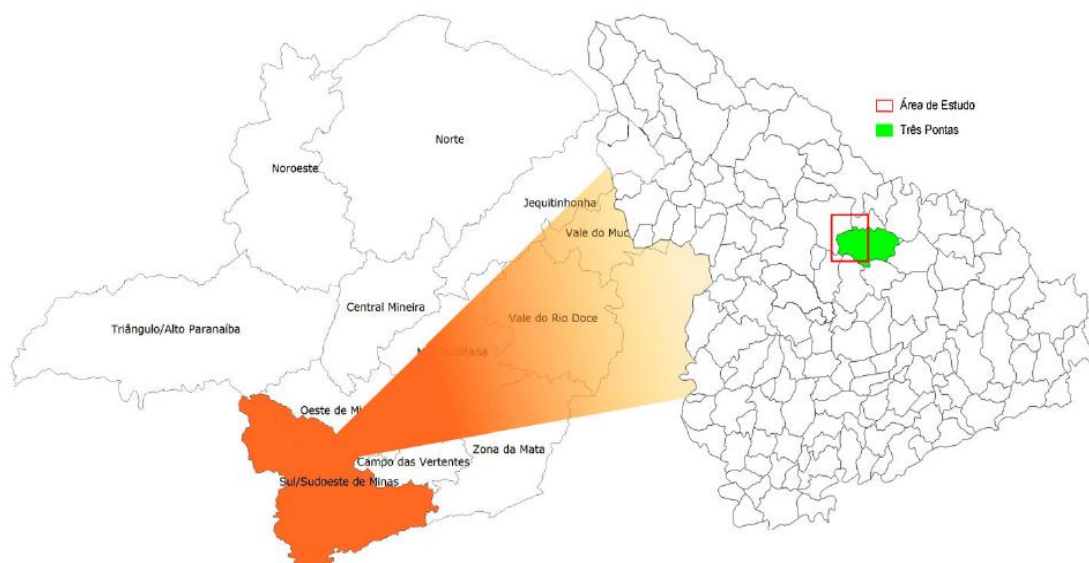


Figura 1: Localização da área de estudo: Três Pontas no sul do estado de Minas Gerais.

A imagem de satélite utilizada neste trabalho corresponde à imagem orbital TM/Landsat5 com data de passagem de 16 de julho de 2007, adquirida junto ao Instituto Nacional de Pesquisas Espaciais – INPE. Foram empregadas as bandas espectrais 3 (vermelho), 4

(infravermelho próximo) e 5 (infravermelho médio) com máscaras de drenagem e de área urbana em todas. Também foi empregada uma banda referente ao cálculo do Índice de Vegetação NDVI (*Normalized Difference Vegetation Index*). De acordo com Boschi e Galo (2007) o uso desta banda “acarreta maior brilho de vegetação e melhora a aparência da distribuição espacial de informações das imagens”.

2.2 Rede Neural Artificial

A Rede Neural Artificial aplicada neste trabalho para classificação dos dados foi do tipo *Feedforward MLP (Multilayer Perceptron)*. Essa arquitetura da RNA possui uma ou mais camadas intermediárias sendo nessas camadas onde ocorre a maior parte do processamento e extração das características dos dados.

O aprendizado da rede foi supervisionado, no qual é apresentada à rede a saída desejada para os dados de entrada. Com esse conjunto entrada-saída desejada o treinamento é feito através da aprendizagem por correção do erro. Para conseguir melhor capacidade de generalização da rede foi utilizada a validação cruzada.

O algoritmo de aprendizado da rede foi o *Backpropagation* com *momentum*. O aprendizado com *momentum* utiliza uma memória para acelerar e estabilizar a convergência.

2.3 Procedimento Metodológico

A imagem foi pré-processada, Andrade (2011), quando foram criadas máscaras ao longo da rede de drenagem e também na área urbana. Este pré-processamento foi realizado em cada uma das bandas 3, 4 e 5. A banda do NDVI é expressa através de uma matemática de bandas. O cálculo é entre as bandas 3, concernente ao espectro vermelho (VER) e a banda 4, concernente ao infravermelho próximo (IVP) (Equação 1):

$$NDVI = \frac{IVP - VER}{IVP + VER} \quad (1)$$

Por meio do software Envi 4.7, comercializado pela Sulsoft (2012), foi feita uma divisão (*subset*) de cada uma das bandas para selecionar amostras de cada classe para treinamento da rede (Figura 2b) e para validação da mesma (Figura 2a). Foram selecionadas amostras para as classes de “Café”, “Mata”, “Água” e “Outros usos”. Dentro da classe de “Outros usos”, na região da imagem para treinamento da rede, estão contidas amostras de solos expostos, pastagens, demais cultivos além da área urbana. A área urbana foi classificada como “Outros usos” pelo fato de a mesma não estar presente na região de validação. Para se fazer uma coleta precisa dos polígonos utilizou-se o mapa de uso e ocupação da terra (Figura 3). Esse mapa foi classificado visualmente e conferido em campo por especialistas do Laboratório de Geoprocessamento – GeoSolos, Epamig (2011).



(a)




Figura 2: Imagem com sobreposição de bandas através de filtros coloridos RGB. (a) região da imagem para validação da rede; (b) região da imagem para treinamento da rede.




Figura 3: Mapa de Uso e ocupação da terra da região de Três Pontas – MG.

Após a coleta das ROIs (*Regions of Interest*), realizou-se a extração das medidas de textura utilizando o software Texture, Rennó (1995). Este programa trabalha com uma banda por vez. Os mesmos polígonos foram utilizados para extração das medidas de textura nas bandas 3, 4, 5 e NDVI, tanto para a região de treinamento quanto para a região de validação. Todas as extrações foram realizadas com a quantização fixada em 256 níveis de cinza. Mais detalhes sobre o cálculo das medidas de textura podem ser encontrados em Haralick *et al.* (1973).

Segundo Rocha e Leite (2002), o processo de cálculo preciso das texturas depende em grande porcentagem do tamanho da janela que definirá a vizinhança. Janelas de tamanho pequeno talvez não consigam capturar o padrão particular da classe, enquanto que janelas de tamanho maior possam incluir pixels não pertencentes à classe (pixels de mais de uma classe). Considerando isto, as medidas de textura foram extraídas com diferentes tamanhos de janela definindo a vizinhança: 3x3, 5x5 e 9x9 pixels.

Segundo Pacifici *et al.* (2009), algumas medidas de textura como energia, contraste, variância, correlação e entropia são consideradas mais relevantes na discriminação entre

objetos, sendo que energia e contraste são as medidas mais significantes na discriminação entre texturas. Neste trabalho, foram utilizadas seis medidas de textura para diferenciar as classes de uso da terra: energia, contraste, correlação, entropia, *chi-square* e soma do vetor variância.

As medidas de textura foram os dados de entrada para a RNA que foi implementada no software Scilab 5.3.3 utilizando o *toolbox ANN* desenvolvido pelo Grupo Scilab, Pires (2004). Estes dados foram normalizados antes de iniciar o treinamento e a validação da rede. Várias fases de treinamento da RNA foram realizadas de acordo com o tamanho da janela de vizinhança (3x3, 5x5 e 9x9 pixels), a taxa de aprendizado da rede (0,1 ou 0,01), a arquitetura da rede (1 ou 2 camadas escondidas) e o número de neurônios nestas camadas (40 ou 20 para uma camada escondida; 40 e 20 ou 20 e 10 para duas camadas escondidas). O número de iterações também foi alterado para treinamento, mas sem valores previamente definidos, já que foram realizados vários testes repetidas vezes para uma mesma arquitetura da RNA e para uma mesma configuração de extração das medidas de textura com quantidades diferentes de iterações. As condições de parada do treinamento da rede foram o número de iterações e o EQM (Erro Quadrático Médio) fixado no valor de 0,001.

Após a classificação dos dados com os pesos da rede atualizados, calculou-se o Erro Quadrático Total (EQT) da rede através da comparação entre os resultados obtidos pela classificação e os dados da saída desejada. O EQT foi calculado a cada iteração, tanto para os dados de treinamento da rede quanto para os dados de validação (Equação 2):

$$EQT = soma(saída_{desejada} - saída_{obtida})^2 \quad (2)$$

Os processos de treinamento e de validação da RNA aconteceram simultaneamente. A cada iteração de treinamento da rede os pesos das ligações entre os neurônios eram atualizados e os dados de treinamento e de validação eram classificados de acordo com esses pesos. Com isso foi possível calcular a porcentagem de acerto total da rede no momento de melhor generalização, ou seja, no momento em que o EQT para os dados de validação eram menores.

3. Resultados e Discussão

O foco deste trabalho está na classificação dos dados de validação da rede e assim encontrar a melhor generalização. A Tabela 1 apresenta os melhores resultados com suas respectivas configurações de arquitetura de rede e de janela de extração e está organizada em ordem crescente pela porcentagem de acertos dos dados de validação.

O resultado 16, com porcentagem de acerto de validação de 92,10%, foi o melhor encontrado com uma arquitetura de rede com duas camadas escondidas, a primeira com 40 (quarenta) neurônios e a segunda com 20 (vinte) neurônios, e uma taxa de aprendizado de 0,01. A janela de extração das medidas de textura foi de 5x5 pixels. A Figura 4 apresenta os gráficos dos Erros Quadráticos Totais de treinamento e de validação deste resultado.

Os resultados 1 e 7 foram obtidos com a mesma configuração de rede e a mesma taxa de aprendizado do resultado 16, mas com janela de extração das medidas de textura de tamanho 9x9 e 5x5 pixels, respectivamente, e apresentaram porcentagem de acerto de validação diferentes. Essa mesma situação pode ser observada entre os resultados 2, 5 e 13 que foram obtidos com apenas uma camada escondida com 40 (quarenta) neurônios e taxa de aprendizado de 0,1. Os resultados 3, 14 e 15 têm situação análoga, e foram obtidos com duas camadas escondidas, 20 neurônios na primeira e 10 na segunda, e uma taxa de aprendizado de 0,01.

Tabela 1: Resultados das melhores generalizações da Rede Neural Artificial

Resultado	Camadas escondidas	Neurônios por camada	Taxa de aprendizado	Iteração general.	Iterações totais	Janela de extração	Erro Quadrático total		Porcentagem acerto total		Tempo total de treinamento (seg)
							Trein.	Valid.	Trein.	Valid.	
1	2	40 e 20	0,01	682	1000	9 x 9	189,90	147,70	92,63%	90,10%	806,303
2	1	40	0,1	140	300	9 x 9	225,97	146,05	91,19%	90,10%	176,889
3	2	20 e 10	0,01	991	1000	3 x 3	172,77	154,87	93,44%	90,30%	624,469
4	1	40	0,01	1760	2500	9 x 9	173,21	148,73	93,63%	90,40%	148,727513
5	1	40	0,1	373	1000	5 x 5	175,08	153,96	93,19%	90,50%	559,152
6	2	40 e 20	0,1	289	300	5 x 5	206,69	140,21	91,94%	90,60%	236,902
7	2	40 e 20	0,01	296	1500	3 x 3	215,76	147,42	91,50%	90,70%	1.139,454
8	2	20 e 10	0,1	142	500	3 x 3	271,54	142,00	88,75%	90,80%	312,105
9	1	20	0,1	157	1000	3 x 3	213,77	147,30	91,31%	90,80%	459,405
10	1	20	0,1	344	1000	5 x 5	190,16	136,41	92,38%	90,90%	449,820
11	1	40	0,01	1000	1000	5 x 5	196,71	142,32	92,44%	90,90%	559,963
12	1	20	0,01	1506	2000	5 x 5	185,00	138,62	92,88%	91,10%	906,830
13	1	40	0,1	270	500	3 x 3	187,55	147,52	92,44%	91,10%	281,175
14	2	20 e 10	0,01	786	2000	9 x 9	201,95	129,96	92,31%	91,10%	1.263,462
15	2	20 e 10	0,01	1401	2000	5 x 5	170,13	137,57	93,31%	91,50%	1.231,887
16	2	40 e 20	0,01	1088	1500	5 x 5	198,85	122,76	92,25%	92,10%	1.184,144

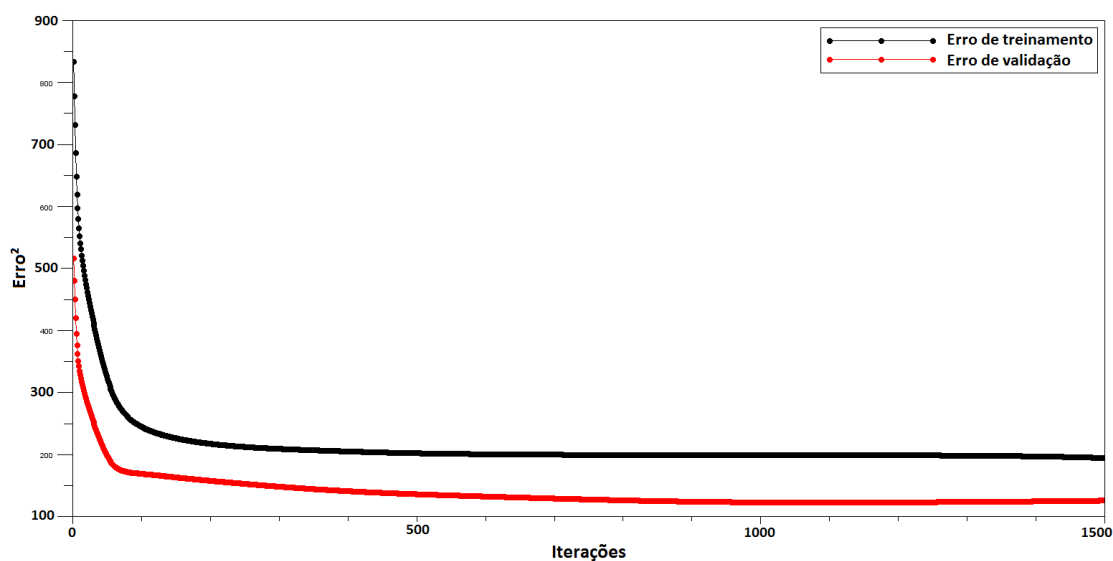


Figura 4: Gráfico de Erro Quadrático Total de treinamento e de validação para o melhor resultado.

Os resultados também podem ser avaliados quanto à variação da taxa de aprendizado. O resultado 16 foi alcançado com uma taxa de aprendizado de 0,01. O resultado 6, com 90,6% de porcentagem de acerto de validação, foi conseguido com a mesma arquitetura de rede e com os mesmos dados de entrada que o resultado 16, mas com taxa de aprendizado de 0,1 e apresentou porcentagem de acerto de validação diferente deste.

Condições similares de mesma arquitetura de rede, medidas de textura extraídas com o mesmo tamanho de janela e diferentes porcentagens de acerto de validação podem ser encontradas entre os resultados 10 e 12, os resultados 5 e 11, os resultados 2 e 4 e os resultados 3 e 8.

4. Conclusões

Os dados de entrada incorporados à rede foram apenas as medidas de textura extraídas dos polígonos coletados. As Redes Neurais Artificiais se mostraram fortes ferramentas na classificação destes dados apresentando resultados bastante satisfatórios. Conclui-se que o atributo espacial de textura foi adequado na discriminação de áreas cafeeiras e matas em imagens de satélite.

Os resultados 1, 7 e 16 apresentaram, respectivamente, 90,1%, 90,7% e 92,1% de porcentagem de acerto de validação. Estes resultados diferem apenas quanto aos dados de entrada da rede que foram extraídos com diferentes tamanhos de janela. Conclui-se que as janelas de extração de tamanho 5x5 pixels foram mais favoráveis no cálculo das medidas de textura. Janelas com tamanho maior e menor apresentaram uma porcentagem de acerto de validação inferior àquela apresentada por uma janela de 5x5 pixels. Isto confirma o que foi proposto por Rocha e Leite (2002) que o tamanho da janela de extração influencia no processo de classificação. Janelas de tamanho maior podem incluir pixels não pertencentes à classe e janelas de tamanho menor podem não capturar o padrão da classe. Em outros resultados com a mesma arquitetura de rede e a mesma taxa de aprendizado as melhores porcentagens de acerto de validação foram encontradas com dados extraídos com janelas de 5x5 pixels.

Portanto, o classificador automático construído com a RNA mostra-se bastante favorável a próximos estudos e mapeamentos de imagens de sensoriamento remoto. Próximos passos a serem desenvolvidos sequencialmente a esse trabalho são a incorporação de novos parâmetros para o treinamento da rede, como os atributos espectrais e atributos espaciais de forma que

podem auxiliar no aprendizado da rede atingindo-se índices de acertos ainda mais favoráveis, e a geração de mapas a partir da classificação dos dados pela RNA.

Agradecimentos

Os autores agradecem o apoio financeiro da FAPEMIG, CNPq e EPAMIG para realização e publicação deste trabalho.

Referências Bibliográficas

Andrade, L. N. **Redes Neurais Artificiais aplicadas na identificação automática de áreas cafeeiras em imagens de satélite**. 2011. 92 p. (CDU519.6*82.10). Dissertação (Mestrado em Ciência da Computação) – Universidade Federal de Minas Gerais, Belo Horizonte. 2011.

Barreto, J. M. **Introdução às Redes Neurais Artificiais**. Florianópolis: Departamento de Informática e de Estatística, Universidade Federal de Santa Catarina, 2002. 57 p.

Boschi, L. S.; Galo, M. L. B. T. **Análise da Incerteza na representação de Classes de Cobertura do Solo Urbano resultantes da aplicação de uma Rede Neural Artificial**. Boletim de Ciências Geodésicas, v. 13, p. 22-41, 2007.

Epamig – Laboratório de Geoprocessamento – GEOSOLOS. Disponível em: <<http://www.epamig.br/geosolos>>. Acesso em 13 out. 2011.

Florenzano, T. G. **Imagens de Satélite para Estudos Ambientais**. São Paulo: Oficina de Textos, 2002. 97 p.

Haralick, R. M.; Shanmugam, K.; Dinstein, I. H. Textural Features for Image Classification. **System, Man and Cybernetics, IEEE Transactions on**, v.3, n.6, p. 610-621, 1973.

Martins, M. P.; Guimarães, L. F.; Fonseca, L. M. G. Classificador de Texturas pro Redes Neurais. Itajaí, SC. **Anais II Congresso Brasileiro de Computação**, 2002, p. 1-12.

Pacifici, F.; Chini, M.; Emery, W. J. A neural network approach using multi-scale textural metrics from very high-resolution panchromatic imagery for urban land-use classification. **Anais Remote Sensing of Environment** 113, Fevereiro 2009, p. 1276-1292.

Pires, P. S. M. **Introdução ao Scilab Versão 3.0**. Natal: Departamento de Engenharia de Computação e Automação, Universidade Federal do Rio Grande do Norte, 2004. Disponível em: <<http://www.dca.ufrn.br/~pmotta/sciport-3.0.pdf>>. Acesso em 16.ago.2012.

Rennó, C. D. **Avaliação de medidas texturais na discriminação de classes de uso utilizando imagens SIR-C/X-SAR do perímetro irrigado de Bebedouro, Petrolina, PE**. 1995, 111p. (INPE-10441-TDI/926). Dissertação (Mestrado em Sensoriamento Remoto) – Instituto Nacional de Pesquisas Espaciais, São José dos Campos. 1995.

Rennó, C. D.; Freitas, C. C.; Sant'Anna, S. J. S. A system for region image classification based on textural measures. **Image Processing Techniques**, p. 159-164, Sep. 1998. Proceedings of the Second Latino-American Seminar on Radar Remote Sensing.

Rocha, A. R.; Leite, N. J. Classificação de texturas a partir de vetores de atributos e função de **distribuição de probabilidades**. Campinas, SP. Universidade Estadual de Campinas, 2002. Disponível em: <http://www.ic.unicamp.br/~rocha/msc/ipdi/texture_classification.pdf>. Acesso em: 10 abr. 2012.

SulSoft – Alimentando sua criatividade. Disponível em: <<http://www.sulsofto.com.br>>. Acesso em 28.jul.2012.