

**REDES NEURAIS ARTIFICIAIS
APLICADAS NA IDENTIFICAÇÃO
AUTOMÁTICA DE ÁREAS CAFEEIRAS EM
IMAGENS DE SATÉLITE**

Lívia Naiara de Andrade

Orientadores: Clodoveu Augusto Davis Junior

Wilian Soares Lacerda

Redes neurais artificiais aplicadas na identificação automática de áreas cafeeiras em imagens de satélite

Dissertação apresentada ao Departamento de Ciência da Computação do Instituto de Ciências Exatas da Universidade Federal de Minas Gerais como requisito parcial para a obtenção do grau de Mestre em Ciência da Computação.

Belo Horizonte

2011

© 2011, Livia Naiara de Andrade.
Todos os direitos reservados.

Andrade, Lívia Naiara

D1234p Redes neurais artificiais aplicadas na identificação
automática de áreas cafeeiras em imagens de satélite/
Lívia Naiara de Andrade — Belo Horizonte, 2011.
xviii, 90 f. : il. ; 29cm

Dissertação (mestrado) — Universidade Federal de
Minas Gerais

Orientador: Prof. Clodoveu Augusto Davis Junior
Co-orientador: Wilian Soares Lacerda

1. Redes Neurais Artificiais. 2. Classificação automática
3. Imagens de satélite. I. Título

CDU519.6*82.10



UNIVERSIDADE FEDERAL DE MINAS GERAIS
INSTITUTO DE CIÊNCIAS EXATAS
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

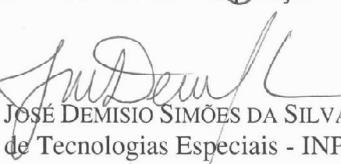
FOLHA DE APROVAÇÃO

Redes neurais artificiais aplicadas na identificação automática de áreas cafeeiras
em imagens de satélite

LÍVIA NAIARA DE ANDRADE

Dissertação defendida e aprovada pela banca examinadora constituída pelos Senhores:


PROF. CLODOVEU AUGUSTO DAVIS JÚNIOR - Orientador
Departamento de Ciência da Computação - UFMG


PROF. JOSÉ DEMISIO SIMÕES DA SILVA
Centro de Tecnologias Especiais - INPE


M.Sc. TATIANA GROSSI CHQUILOFF VIEIRA
Empresa de Pesquisa Agropecuária de Minas Gerais - EPAMIG


PROF. WILIAN SOARES LACERDA
Departamento de Ciência da Computação - UFLA


PROF. LUIZ CHAIMOWICZ
Departamento de Ciência da Computação - UFMG

Belo Horizonte, 21 de fevereiro de 2011.

À Deus, pelo dom da vida.

Ofereço

Aos meus queridos pais, Sirlene e Marcos, pelo amor e carinho dedicados, e aos meus irmãos, Marcos Vinícius e Luana,

Dedico.

Agradecimentos

À Deus, Pai de misericórdia e ao Senhor Jesus Cristo, modelo de oração e de vida, espírito de sabedoria e fortaleza, pela vida, por sempre iluminar o meu caminho e por fazer-me vitoriosa em mais uma etapa da vida.

Aos meus familiares, que jamais deixaram de acreditar em mim, principalmente meu Pai e minha Mãe, que me ensinaram que uma pessoa deve ser honesta e ter fé. Aos meus irmãos pelos momentos de imensa alegria vividos em família. Sem o amor e apoio de vocês eu jamais teria chegado até aqui.

A minha co-orientadora Tatiana, que foi a grande idealizadora deste trabalho, mas principalmente, por toda a paciência, dedicação e atenção a mim disponibilizadas, além das "injeções" constantes de incentivo.

Ao meu orientador, Prof. Clodoveu Davis Jr. pelas excelentes contribuições e direcionamento que deu ao trabalho, além dos rápidos retornos e revisões.

Ao meu co-orientador, Prof. Wilian Soares Lacerda, pela paciência, atenção, conselhos, constantes incentivos diários e disponibilidade indispensáveis para a constituição deste trabalho.

Às pesquisadoras Helena Maria Ramos Alves e Margarete Marin Lordelo Volpato pelo apoio, sugestões, companheirismo, dedicação e ensinamentos prestados.

Aos meus amigos do Laboratório de Geoprocessamento da EPAMIG - GeoSolos, Vanessa, Rafael, Ricardo, Walbert, Lili, Claudinho, Katiane, Carol, Lisiâne, Liliany, que foram peças fundamentais no dia-a-dia do desenvolvimento deste trabalho. Em especial, a minha amiga Juliana, por ter me incentivado e ajudado a ingressar no curso de mestrado, mas acima de tudo, por ser a pessoa que nos momentos mais difíceis me motivava a não abandonar a batalha.

Ao Grupo de Oração Universitário do Instituto de Ciências Exatas (GOU-ICEEx) da UFMG pelo carinho e orações constantes de paz e tranquilidade durante essa fase importante de minha vida.

Ao Instituto Nacional de Pesquisas Espaciais – INPE pelo fornecimento das imagens TM/Landsat 5 e à Cooperativa Regional de Cafeicultores de Guaxupé Ltda – Cooxupé pelas imagens do satélite HRV/SPOT 5 cedidas.

Agradeço também, a Fundação de Amparo à Pesquisa de Minas Gerais – FAPEMIG, ao Consórcio Brasileiro de Pesquisa e Desenvolvimento do Café – CBPD/Café e a Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – CAPES pelos recursos financeiros e bolsas.

*“E o que ele manda é isso: que creiamos no seu Filho, Jesus Cristo,
e que nos amemos uns aos outros, como Cristo nos mandou fazer.”*

(Jo 3.23)

Resumo

A cafeicultura é atividade de fundamental importância na região Sul do estado de Minas Gerais e técnicas de estimativa da área plantada, visando previsões de safra confiáveis, estão sendo intensamente pesquisadas. A cultura cafeeira tem o padrão espectral muito próximo ao da mata, dificultando a classificação automática das classes de uso da terra. A aplicação de Redes Neurais Artificiais (RNA) na classificação de dados de Sensoriamento Remoto tem se mostrado uma abordagem promissora na discriminação de classes de maior complexidade. Neste sentido, o presente trabalho de dissertação apresenta uma aplicação de Redes Neurais Artificiais para a classificação automática de dados de sensoriamento remoto, que fosse adequada para a identificação e mapeamento do uso e ocupação das terras, com ênfase na identificação de áreas cafeeiras nas regiões de Guaxupé, Machado e Três Pontas, Sul de Minas Gerais. O *software* utilizado para pré-processamento e validação das classificações foi o SPRING, e para o processamento e classificação das imagens foi o Idrisi. Para as três regiões cafeeiras estudadas, a metodologia para desenvolvimento da aplicação da RNA foi dividida em três etapas principais: na primeira foi realizado o pré-processamento dos dados, em que foram criadas máscaras em cada uma das três bandas das imagens; na segunda etapa a RNA foi treinada a partir de amostras representativas das classes de interesse (café, mata, água, outros usos e área urbana) e aplicada sobre a imagem, verificando assim seu potencial em discriminar as classes de saída estabelecidas; a terceira etapa consistiu na análise e validação dos resultados, realizando um cruzamento entre o mapa classificado visualmente e o mapa classificado pela Rede Neural Artificial. Utilizou-se o índice Kappa para avaliar o desempenho da RNA, uma vez que o uso desse coeficiente é satisfatório na avaliação da precisão de uma classificação temática. Para a região de Guaxupé, o índice Kappa do mapa classificado pela RNA ficou em 71,85% em relação ao mapa de referência, que é um índice considerado bom. Para a região de Machado, os resultados da classificação foram índices Kappa de 55,84% para o relevo mais movimentado e 60,29% para o relevo menos movimentado, superiores aos resultados encontrados na literatura. E para a região de Três Pontas a RNA obteve um índice Kappa de 67,61%, que também é considerado um índice bom. A metodologia de Redes Neurais Artificiais apresentou um bom resultado, porém, sugere-se que utilize outros dados de entrada para a RNA, uma vez que somente as bandas espectrais não são suficientes para uma classificação otimizada.

Palavras-chave: Redes Neurais Artificiais, Classificação Automática, Imagens de Satélite, Cafeicultura.

Abstract

Coffee production is of fundamental importance in the southern region of Minas Gerais state and techniques for estimating the area planted are being intensely investigated in order to produce reliable yield estimates. Coffee trees have a similar spectral pattern to forest, making it difficult to automatically classify these land use types. The application of Artificial Neural Networks (ANN) to the classification of remotely sensed data is a promising approach in discriminating more complex classes of land use/cover. This study presents an application of Artificial Neural Networks for the automatic classification of remote sensing data which was adapted for the identification of land use with emphasis in the coffee areas in the municipalities of Guaxupé, Machado and Três Pontas, South region of Minas Gerais state in Brazil. The software used for preprocessing the data and validate the ratings was SPRING. To process and classify the images was used the IDRISI software. For the three regions the methodology for the application of ANN was divided in three main stages: in the first, the pre-processing of the data was accomplished. Masks were created in each one of the three bands of the images; in the second stage, the ANN was trained with representative samples of the classes of interest (coffee, forest, water, other uses and urban area) and applied on the image in order to verify its potential for discriminating established land use classes; the third stage consisted of the analysis and validation of the results, using as reference the map classified visually. The Kappa index was used to access the accuracy of the thematic maps obtained with the ANN. For the Guaxupé region, the Kappa index (k) was 71.85%, which is considered good. For the Machado region, the result of the classification by ANN was 55.84% for the more undulated part of the experimental area and 60.29% for the smoother landscapes. Although the kappa for Machado were lower than Guaxupé, the results obtained were better than what is found in the literature. For the region of Três Pontas the index Kappa obtained was 67,61%, that is also considered a good index. The ANN methodology presented good results. However, as the spectral bands only were not sufficient to carry out an optimized classification, it is recommended to use other environmental attributes as input data to improve the performance of the ANN.

Keywords : Artificial Neural Networks, automatic classification, satellite image, coffee crop.

Lista de figuras

Figura 2-1 - Imagem TM/Landsat 5, bandas 3, 4 e 5.....	25
Figura 2-2 - Modelo de neurônio usado em redes neurais artificiais.....	28
Figura 2-3 - Rede de neurônios dispostos em camadas.....	29
Figura 2-4 - Diferença entre as texturas do café e da mata.....	34
Figura 3-1 - Áreas de estudo: Guaxupé, Machado e Três Pontas.....	45
Figura 3-2 - Imagens HRV/SPOT 5, bandas 1, 2 e 3 da região de Guaxupé.....	46
Figura 3-3 - Imagens TM/Landsat 5, bandas 3, 4 e 5 da região de Machado.....	47
Figura 3-4 - Imagens TM/Landsat 5, bandas 3, 4 e 5 da região de Três Pontas.....	47
Figura 3-5 - <i>Software</i> Idrisi, classificadores baseados em Redes Neurais.....	49
Figura 3-6 – Metodologia do trabalho.....	50
Figura 3-7 - Pré-processamento realizado para a região de Guaxupé.....	52
Figura 3-8 - Pré-processamento realizado para a região de Machado.....	53
Figura 3-9 - Pré-processamento realizado para a região de Três Pontas.....	54
Figura 3-10 - Classificação da imagem pela RNA.....	55
Figura 3-11 - Validação dos resultados.....	57
Figura 4-1 - Mapa de uso da terra classificado visualmente da região de Guaxupé.....	60
Figura 4-2 - Mapa da região de Guaxupé, classificado pela RNA.....	61
Figura 4-3 - Mapa de interseção das áreas cafeeiras da região de Guaxupé.....	62
Figura 4-4 - Mapa de uso da terra classificado visualmente da região de Machado.....	65
Figura 4-5 - Mapa da região de Machado, classificado pela RNA.....	66
Figura 4-6 - Mapa de interseção das áreas cafeeiras da região de Machado.....	68
Figura 4-7 - Mapa de uso da terra classificado visualmente da região de Três Pontas.....	70
Figura 4-8 - Mapa da região de Três Pontas, classificado pela RNA.....	71
Figura 4-9 - Mapa de interseção das áreas cafeeiras da região de Três Pontas.....	73

Lista de tabelas

Tabela 2-1 - Principais sensores multiespectrais em operação	24
Tabela 2-2 – Tabulação cruzada.....	36
Tabela 2-3 - Valor para avaliar o grau de concordância a partir do índice Kappa.....	37
Tabela 4-1 - Configurações utilizadas para realização dos testes, região de Guaxupé	59
Tabela 4-2 - Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %), região de Guaxupé	61
Tabela 4-3 - Configurações utilizadas para realização dos testes, região de Machado.....	64
Tabela 4-4 - Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %), região de Machado	67
Tabela 4-5 - Configurações utilizadas para realização dos testes, região de Três Pontas..	69
Tabela 4-6 - Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %), região de Três pontas	72
Tabela 4-7 - Resultados alcançados (índice Kappa) com a classificação pela RNA e demais classificadores automáticos.....	74

Lista de abreviaturas

APP	Área de Preservação Permanente
CONAMA	Conselho Nacional do Meio Ambiente
EMQ	Erro Médio Quadrático
EPAMIG	Empresa de Pesquisa Agropecuária de Minas Gerais
FAPEMIG	Fundação de Amparo à Pesquisa de Minas Gerais
HRG	<i>Haute Résolution Géométrique</i>
HRS	<i>Haute Résolution Stereoscopique</i>
HRV	<i>High Resolution Visible</i>
IGAM	Instituto Mineiro de Gestão das Águas
INPE	Instituto Nacional de Pesquisas Espaciais
LEGAL	Linguagem Espacial para Geoprocessamento Algébrico
Matlab	<i>MATrix LABoratory</i>
MLP	<i>Multi-Layer Perceptron</i>
NDVI	<i>Normalized Difference Vegetation Index</i>
REM	Radiação Eletromagnética
RNA	Redes Neurais Artificiais
SIG	Sistema de Informação Geográfica
SOM	<i>Self-Organizing Map</i>
SPRING	Sistema de Processamento de Informações Georreferenciadas
SR	Sensoriamento Remoto
TM	<i>Thematic Mapper</i>
UFLA	Universidade Federal de Lavras

Sumário

CAPÍTULO 1.....	18
INTRODUÇÃO	18
1.1 OBJETIVOS DO TRABALHO	20
1.2 ORGANIZAÇÃO DESTE DOCUMENTO.....	21
CAPÍTULO 2.....	22
REFERENCIAL TEÓRICO	22
2.1 ASPECTOS TEÓRICOS DO SENSORIAMENTO REMOTO	22
2.2 REDES NEURAIS ARTIFICIAIS	27
2.2.1 <i>Neurônio Artificial</i>	28
2.2.2 <i>Rede de Neurônios</i>	29
2.2.3 <i>Aprendizado da rede</i>	30
2.2.4 <i>Backpropagation</i>	31
2.2.5 <i>Dificuldades de dimensionamento</i>	32
2.3 MAPEAMENTO DE ÁREAS CAFEEIRAS A PARTIR DE IMAGENS DE SATÉLITE.....	33
2.4 CLASSIFICAÇÃO AUTOMÁTICA DE ÁREAS CAFEEIRAS.....	35
2.4.1 <i>Avaliação da acurácia da classificação</i>	35
2.4.2 <i>Classificação de imagens com base em características espectrais</i>	37
2.4.3 <i>Aplicação de Redes Neurais Artificiais em atividades agrícolas</i>	39
2.4.4 <i>Classificação de imagens com base em atributos de textura e forma</i>	41
2.5 CONSIDERAÇÕES FINAIS.....	43
CAPÍTULO 3.....	44
METODOLOGIA.....	44
3.1 ÁREAS DE ESTUDO	44
3.2 IMAGENS DE SATÉLITE UTILIZADAS	46
3.3 FERRAMENTAS COMPUTACIONAIS UTILIZADAS NO PROCESSAMENTO E ANÁLISE DOS DADOS	48
3.4 PROCEDIMENTO METODOLÓGICO	50
3.4.1 <i>Pré-processamento dos dados</i>	51
3.4.2 <i>Classificação da imagem pela RNA</i>	55

3.4.3 <i>Validação dos resultados</i>	56
3.5 CONSIDERAÇÕES FINAIS.....	57
CAPÍTULO 4.....	44
RESULTADOS E DISCUSSÃO	58
4.1 RESULTADOS OBTIDOS NA REGIÃO DE GUAXUPÉ	58
4.2 RESULTADOS OBTIDOS NA REGIÃO DE MACHADO	63
4.3 RESULTADOS OBTIDOS NA REGIÃO DE TRÊS PONTAS	69
4.4 CONSIDERAÇÕES SOBRE OS RESULTADOS OBTIDOS	73
CAPÍTULO 5.....	76
CONCLUSÕES.....	76
5.1 CONSIDERAÇÕES FINAIS.....	76
5.2 RECOMENDAÇÕES GERAIS	77
5.3 PROPOSTAS DE CONTINUIDADE.....	79
REFERÊNCIAS BIBLIOGRÁFICAS	80

Capítulo 1

Introdução

O café é o segundo produto mais importante na pauta das exportações agrícolas, constituindo uma das mais importantes fontes de renda para a economia brasileira. Minas Gerais destaca-se no cenário brasileiro como o maior produtor, com uma participação de 50,99% do café produzido no país [CONAB, 2008]. O café é responsável por 70% da renda das propriedades rurais do Sul de Minas. Não obstante a importância econômica e social da cafeicultura mineira como geradora de renda e empregos, ainda existe pouca informação quantitativa sobre a ocupação e distribuição espacial da cultura no Estado. Faltam informações tanto sobre a extensão e distribuição das áreas cafeeiras quanto sobre as características dos ambientes onde estas áreas se localizam. Exemplo disso é a discordância real existente entre estatísticas oficiais governamentais sobre produção e área plantada no Estado [SOUZA *et al.*, 2009]. Por outro lado, o mapeamento de uso da terra com café em Minas Gerais, especialmente na região Sul do Estado, constitui grande desafio. Por conta de sua extensão territorial, da dinâmica acentuada da ocupação humana, do relevo montanhoso e da confusão espectral entre as classes temáticas café e vegetação natural, a utilização de produtos de sensoriamento remoto para identificação das áreas cafeeiras é dificultada.

A caracterização e o mapeamento dos agroecossistemas cafeeiros constituem informação imprescindível para o direcionamento das atividades agrícolas, a preservação dos recursos naturais existentes, o desenvolvimento sócio-econômico regional e a formulação de políticas públicas voltadas ao estímulo da competitividade e da sustentabilidade do agronegócio café. Essa caracterização precisa ser constantemente atualizada no tempo e no espaço, visando o estabelecimento dos parâmetros necessários para o monitoramento da atividade. A metodologia convencional de levantamento e atualização de informações sobre a cobertura e uso da terra caracteriza-se pelo alto custo e pela dificuldade de obtenção de dados em curtos períodos de tempo, o que limita sua aplicação. Avanços na ciência da computação têm auxiliado a extração de informação de imagens de

sensoriamento remoto, bem como o uso de sistemas de informação geográfica (SIG) para armazenar, analisar e apresentar os mais variados tipos de informação georreferenciada [BURROUGH & MCDONNELL, 1998].

Por meio da geotecnologia, mapas gerados a partir de imagens de satélites podem ser processados e integrados a outras informações, como solos, relevo, clima e dados cadastrais provenientes das mais variadas fontes, visando à construção de uma base de dados sobre uma dada cultura. Normalmente, encontram-se implementados em sistemas computacionais classificadores de imagens multiespectrais baseados em conceitos estatísticos. Para realizar essa classificação automaticamente, informações a priori sobre as estatísticas dos dados são indispensáveis. Esse fato torna-se uma limitação quando tais informações não existem ou são insuficientes.

Na busca de novas metodologias para a classificação automática de dados de sensoriamento remoto, pesquisadores e alunos do laboratório de Geoprocessamento da EPAMIG - GeoSolos, têm desenvolvido estudos utilizando os sistemas de informação geográfica Idrisi [CLARK, 2007] e SPRING [CÂMARA *et al.*, 1996]. O Idrisi possui entre suas ferramentas de trabalho vários tipos de redes neurais, das quais está sendo utilizado o tipo Multi-Layer Perceptron. O *software* SPRING é utilizado tanto no pré-processamento, para registro da imagem, criação de máscaras e buffer quanto no pós-processamento, para validação da classificação, obtida pelo cruzamento entre o mapa de referência classificado visualmente e o mapa gerado pela rede neural.

Os resultados obtidos até o momento mostram que existem diferenças sutis de resposta espectral entre áreas plantadas com café e outros tipos de vegetação, variações estas que estão relacionadas aos parâmetros da cultura. A cultura cafeeira apresenta resposta espectral bastante complexa, em função da variabilidade de seus diversos parâmetros, tais como declividade, espaçamento entre plantas, estado vegetativo, estágio fenológico, sombreamento e manejo, entre outros [VIEIRA *et al.*, 2006]. Como exemplo, pode-se levar em consideração o fato de que cafezais com mais de três anos de plantio, considerados “café em produção”, apresentam uma resposta espectral bem próxima à da mata, o que dificulta a classificação.

Uma vez que variáveis do meio físico e fenologia da cultura podem alterar a resposta espectral da cultura cafeeira ou mesmo informar sobre prováveis classes de uso da terra, torna-se desejável a inclusão de dados auxiliares na forma de novas camadas de informação. Alguns exemplos de dados auxiliares que podem ser inseridos nos procedimentos de classificação são: topografia do terreno, geologia, solos, medidas de textura e séries temporais de imagens [DALLEMAND, 1987; BATISTA *et al.*, 1990; TARDIN *et al.*, 1992; MOREIRA *et al.*, 2004; VIEIRA *et al.*, 2007a]. Neste sentido pretende-se fazer uso desses dados para interpretação e mapeamento de áreas cafeeiras por meio de métodos que permitam tal inclusão, como o treinamento de redes neurais.

Esta dissertação está inserida no projeto “Identificação de áreas cafeeiras por meio de geotecnologia e abordagens automatizadas não-probabilísticas” financiado pela Fundação de Amparo à Pesquisa de Minas Gerais (FAPEMIG), faz parte do Programa de Pesquisa do Café da Empresa de Pesquisa Agropecuária de Minas Gerais (EPAMIG) em parceria com a Universidade Federal de Lavras (UFLA). O projeto refere-se à investigação de métodos adequados para lidar com os novos desafios da análise da geoinformação e a disponibilização de conhecimento para estudos relacionados à cafeicultura usando geotecnologia. Postula-se que sensores remotos e geotecnologias são ferramentas fundamentais para o estudo e avaliação de sistemas agrícolas e que Redes Neurais Artificiais possam ser usadas para identificar áreas plantadas com a cultura do café.

1.1 Objetivos do trabalho

Este trabalho de dissertação tem como objetivo geral definir um procedimento de classificação automática utilizando Redes Neurais Artificiais (RNA) para discriminação de classes de uso e ocupação da terra em imagens de satélite, propiciando assim, uma alternativa mais eficiente para a classificação automática de áreas cafeeiras, em relação aos classificadores automáticos conhecidos.

Assim será possível conhecer a área plantada com café em imagens de satélite gerando o mapa de uso da terra de áreas cafeeiras de regiões do Sul de Minas, de forma automática e com alto índice de acerto. Futuramente este mapeamento e esta tecnologia serão expandidos para toda área produtora de café de Minas Gerais.

A partir do objetivo geral, buscou-se atingir os seguintes objetivos específicos:

- Verificar se a metodologia de Redes Neurais Artificiais é adequada para a classificação automática de áreas cafeeiras a partir de imagens de satélite;
- Avaliar o potencial do modulo de Redes Neurais do *software* Idrisi para classificação automática de imagens de satélite, variando a quantidade de neurônios e de camadas escondidas, taxas de aprendizado, fator de *momentum* e o número de iterações;
- Verificar a utilidade do pré-processamento dos dados antes do treinamento pela Rede Neural Artificial;
- Avaliar o método proposto em comparação com outros métodos apresentados na literatura.

1.2 Organização deste documento

O conteúdo desta dissertação foi organizado em cinco capítulos. Ao longo de todo o texto tem-se sempre em foco a classificação automática de imagens de Sensoriamento Remoto utilizando-se a técnica de Redes Neurais Artificiais.

No Capítulo 1 é apresentada a introdução, no qual o problema abordado é contextualizado, e a motivação para o desenvolvimento do trabalho e os objetivos que se deseja alcançar são descritos.

Apresenta-se no Capítulo 2, um levantamento bibliográfico sobre os conceitos relacionados a esse trabalho. São apresentados aspectos teóricos do Sensoriamento Remoto, conceitos sobre Redes Neurais Artificiais, técnicas para mapeamento de áreas cafeeiras e a aplicação dessas.

No Capítulo 3 é descrita a metodologia utilizada. São apresentadas as três etapas principais para desenvolvimento da aplicação da RNA: pré-processamento, classificação e validação dos resultados. Cada uma dessas etapas é descrita detalhadamente.

O Capítulo 4 apresenta os resultados e discussões das classificações realizadas. Os resultados estão apresentados de acordo com a área de estudo. Iniciou-se apresentando os resultados obtidos para a região de Guaxupé. Para a região de Machado, são apresentados dois resultados, um para cada ambiente, já que a região apresenta ambientes geomorfologicamente diferentes. Em seguida, são apresentados os resultados obtidos para a região de Três Pontas.

Por fim, o Capítulo 5 expõe as conclusões do trabalho de dissertação, proporcionando uma dedução positiva do emprego de Redes Neurais Artificiais na classificação automática de imagens de Sensoriamento Remoto. Com o intuito de aperfeiçoar a ferramenta, algumas propostas de continuidade são sugeridas como trabalhos futuros.

Capítulo 2

Referencial Teórico

Neste Capítulo são apresentados os conceitos necessários para o entendimento deste trabalho de dissertação. Na primeira seção são apresentados aspectos teóricos do Sensoriamento Remoto e seus produtos (imagens orbitais). Em seguida são apresentados conceitos sobre Redes Neurais Artificiais, que são técnicas computacionais que apresentam modelos matemáticos que visam a solução de problemas com base na organização de neurônios do cérebro humano. Na terceira seção são apresentadas técnicas para mapeamento de áreas cafeeiras a partir de imagens de satélite. Na quarta seção são apresentados os índices utilizados para avaliar a acurácia das classificações, e aplicações de Redes Neurais Artificiais e a utilização de atributos de textura e forma na classificação automática de imagens de satélite.

2.1 Aspectos teóricos do Sensoriamento Remoto

Os sistemas de aquisição de dados de Sensoriamento Remoto (SR), definidos como sistemas sensores, constituem-se de qualquer equipamento capaz de detectar e registrar a radiação eletromagnética refletida pelos alvos e convertê-la em um sinal passível de ser registrado e apresentado de forma adequada à extração de informações [NOVO, 1989].

De acordo com Moreira [2001], no Sensoriamento Remoto orbital a radiação eletromagnética (REM) interage com os alvos da superfície terrestre, podendo ser absorvida, refletida, transmitida e emitida seletivamente. Com o desenvolvimento tecnológico atual, é possível medir, com razoável precisão e à distância, as propriedades espectrais desses alvos. O uso de sistemas sensores em nível orbital, para obtenção de dados da radiação refletida e/ou emitida pelos alvos da

superfície terrestre, é muito importante para o reconhecimento da superfície da Terra de maneira rápida e eficaz. No caso da vegetação, a REM que chega à superfície da Terra se decompõe em três frações: uma parte da radiação é absorvida pelos pigmentos contidos na folha, outra parte é refletida pelas folhas, e a terceira parte sofre o processo de transmissão através das camadas de folhas.

A quantidade de energia eletromagnética refletida pelas folhas pode ser influenciada por três principais fatores, sendo eles: pigmentos, espaços ocupados pela água e ar, e estruturas celulares. Curran [1983] relata ainda que essa energia refletida pode ser afetada também pelo conteúdo de água, maturação ou idade da folha e a condição de iluminação (folhas expostas ao sol e folhas constantemente à sombra).

A diversidade de aplicações do Sensoriamento Remoto faz com que um número cada vez maior de pesquisadores de diferentes áreas do conhecimento utilize essa ferramenta. Uma das principais vantagens dessa técnica é que ela permite a análise de grandes áreas em apenas uma imagem, em imageamentos contínuos e em intervalos regulares, levando a obtenção de dados multiespectrais, multitemporais e em diferentes resoluções espaciais [KOFFER, 1992].

Moreira [2003] comenta que as cenas coletadas pelos sensores podem ser imageadas por diferentes categorias de satélite, como os militares, científicos e meteorológicos. Os sensores utilizados para dados em nível orbital estão geralmente voltados para os estudos dos recursos naturais e operam em diferentes números de bandas que estão associadas aos comprimentos de onda. Dentre os sensores multiespectrais mais utilizados podem-se citar os sensores *Thematic Mapper* (TM) dos satélites Landsat, *High Resolution Visible* (HRV) do satélite SPOT, e os sensores embarcados nos satélites IKONOS e QUICKBIRD.

O TM opera em 7 faixas espectrais, também chamadas bandas espectrais do espectro eletromagnético, que correspondem a comprimentos de onda específicos de cada sensor. A resolução espacial é entendida como a capacidade do sensor em captar e registrar a menor área possível no terreno. No caso do sensor TM, a resolução espacial é de 30 x 30m no terreno, ou seja, tudo que estiver na superfície terrestre em uma área de 900m² será registrado em um único pixel da imagem produzida. Para a banda 6 essa resolução espacial é igual a 120 x 120m.

A quantidade de bandas espectrais, resolução espacial e largura da faixa imageada de alguns satélites são apresentados na Tabela 2-1.

Tabela 2-1. Principais sensores multiespectrais em operação

Satélite/Sensor	Bandas Espectrais (comprimento de onda)	Resolução Espacial	Largura da Faixa Imageada
Landsat TM	1 (0,45 – 0,52 μm) 2 (0,52 – 0,60 μm) 3 (0,63 – 0,69 μm) 4 (0,76 – 0,90 μm) 5 (1,55 – 1,75 μm) 6 (10,4 – 12,5 μm) 7 (2,08 – 2,35 μm)	30m 120m 30m	185 km
SPOT 5- HRG	B1 (0,50 – 0,59 μm) B2 (0,61 – 0,68 μm) B3 (0,78 – 0,89 μm) B4 (1,58 – 1,75 μm) PAN (0,48 – 0,71 μm)	10m 20m 2,5 a 5m	60 x 60 Km
IKONOS II	MS1 (0,45 – 0,53 μm) MS2 (0,52 – 0,61 μm) MS3 (0,64 – 0,72 μm) MS4 (0,77 – 0,88 μm) PAN (0,45 – 0,90 μm)	4m 1m	11 Km
QuickBird	GSD1 (0,45 – 0,52 μm) GSD2 (0,52 – 0,60 μm) GSD3 (0,63 – 0,69 μm) GSD4 (0,76 – 0,90 μm) PAN (0,45 – 0,90 μm)	2,44m 0,61m	16.5 km

FONTE: SILVA & FRANCISCO [2002].

Segundo Florenzano [2002] as imagens obtidas por sensores eletrônicos, em diferentes canais, são individualmente produzidas em escala de cinza. A quantidade de energia refletida pelos objetos vai determinar a sua representação nessas imagens em diferentes tons de cinza, entre o branco (quando refletem toda a energia) e o preto (quando absorvem toda a energia). Ao projetar e sobrepor essas imagens, através de filtros coloridos, usando azul, verde e vermelho (cores primárias), é possível gerar imagens coloridas, conforme ilustrado na Figura 2-1. Nas imagens coloridas, a cor de um objeto vai depender da quantidade de energia por ele refletida, da mistura das cores (segundo o processo aditivo) e da associação das cores com as imagens.

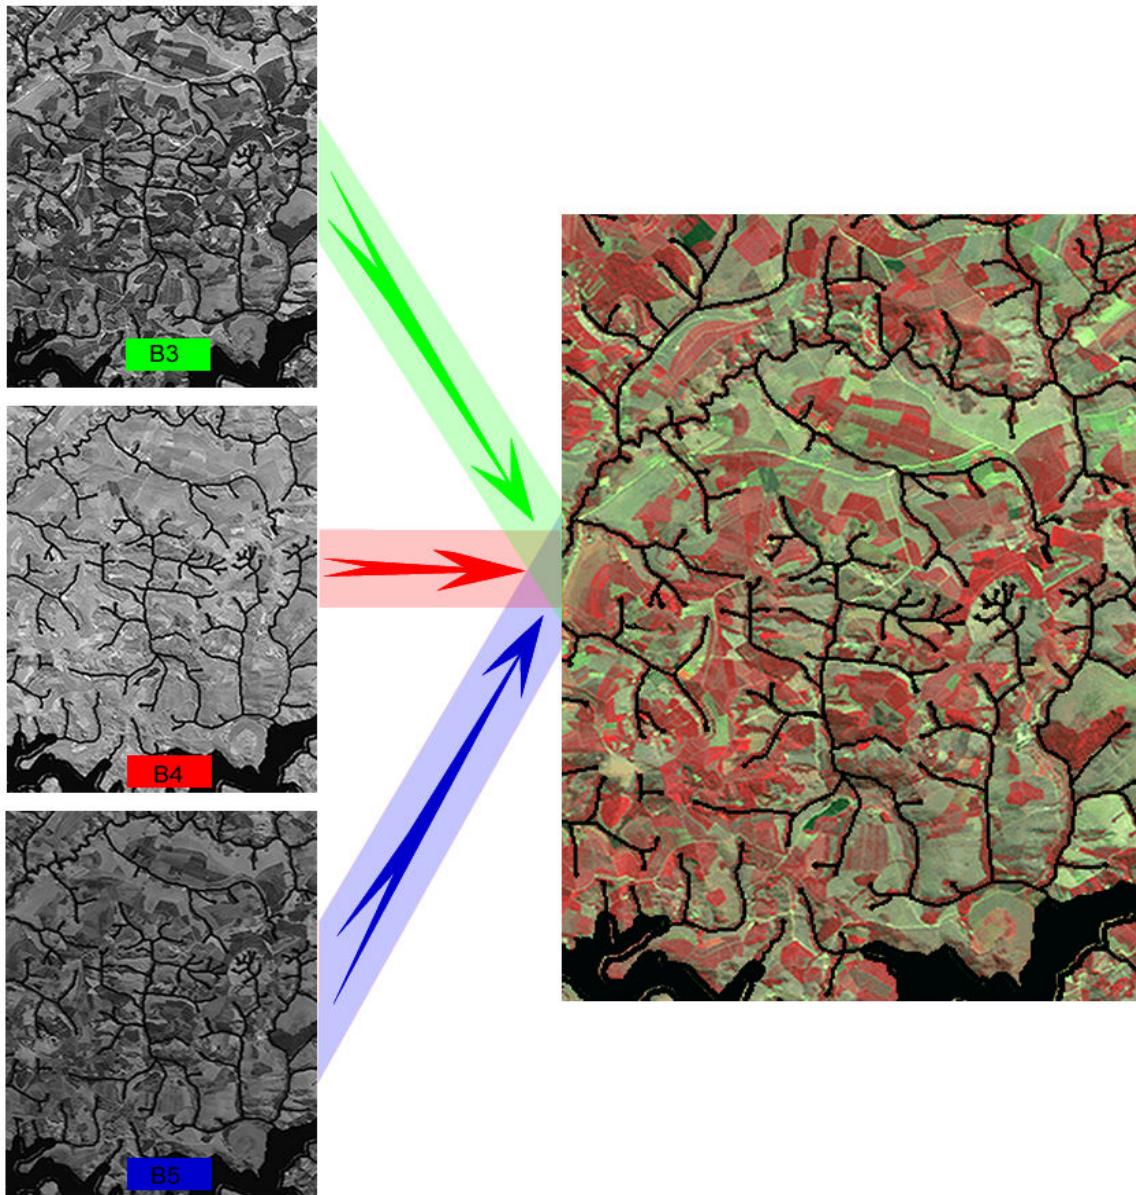


Figura 2-1 – Imagem TM/Landsat 5, bandas 3, 4 e 5, com as cores verde, vermelho e azul, respectivamente.

As aplicações das bandas espectrais do satélite TM Landsat, segundo Silva & Francisco [2002] são:

- **Banda 1 (0,450 - 0,520 µm) Azul:** Útil para mapeamento de águas costeiras, diferenciação entre solo e vegetação, mapeamento de florestas e detecção de feições culturais (mancha urbana, rodovias, etc.), entre outras.
- **Banda 2 (0,520 - 0,600 µm) Verde:** Apresenta grande sensibilidade à presença de sedimentos em suspensão, possibilitando sua análise em termos de quantidade e qualidade. Corresponde à reflectância da vegetação verde e sadia. Também é útil para identificação de feições culturais.

- **Banda 3 (0,630 - 0,690 μm) Vermelho:** Útil para discriminação entre espécies de plantas e delinear solo e feições culturais. Permite um bom contraste entre áreas ocupadas com vegetação e aquelas sem vegetação, apresentando níveis de cinza mais escuros para áreas com vegetação e níveis mais claros para áreas descobertas. Apresenta bom contraste entre diferentes tipos de cobertura vegetal (ex.: campo, cerrado e floresta). Permite o mapeamento da drenagem através da visualização da mata galeria e entalhe dos cursos dos rios em regiões com pouca cobertura vegetal. É a banda mais utilizada para delimitar manchas urbanas e identificar áreas agrícolas.
- **Banda 4 (0,760 - 0,900 μm) Infravermelho próximo:** Permite estimar a quantidade de biomassa de vegetação presente em uma cena. É útil para identificação de culturas agrícolas, enfatizando a diferenciação solo/agricultura e água/solo. Apresenta sensibilidade à morfologia do terreno, permitindo o mapeamento de corpos d'água como rios, lagos, reservatórios, áreas úmidas de várzeas, geologia e geomorfologia e macrófitas aquáticas. Tem grande sensibilidade também à absorção da radiação eletromagnética pelos óxidos de ferro e titânio, comuns em solos muito intemperizados das regiões tropicais;
- **Banda 5 (1,550 - 1,750 μm) Infravermelho médio:** Apresenta sensibilidade ao teor de umidade das plantas, permitindo detectar estresse na vegetação causado pela falta de água. Também é usada para obter informações sobre a umidade do solo. Esta banda sofre perturbações caso ocorra excesso de chuva antes da obtenção da cena pelo satélite.
- **Banda 6 (10,40 - 12,50 μm) Infravermelho termal:** Apresenta sensibilidade nos fenômenos relativos aos contrastes térmicos. Usada para estudos de propriedades termais de rochas, solos, vegetação e água. Também utilizada para mapeamento da temperatura de águas oceânicas superficiais.
- **Banda 7 (2,080 - 2,350 μm) Infravermelho médio:** Apresenta sensibilidade à morfologia do terreno. Importante para estudos nas áreas de Geomorfologia, Solos e Geologia. Muito usada para a discriminação de tipos de rochas e no estudo de solos, como também para detectar o grau de umidade em que se encontram os solos.

Outro sistema sensor importante para aplicações em agricultura é o sistema SPOT, da empresa francesa SPOT Image. O mais conhecido é o SPOT 5, satélite que foi lançado em maio de 2002. Ele possui a bordo os sensores HRS (*Haute Résolution Stereoscopique*) que gera pares esterescópicos e tem resolução espacial de 10 m; HRG (*Haute Résolution Géométrique*) com 10 m, 20 m e de 2,5 a 5 m de resolução e o VGT2 (*Vegetation-2*) com 1 km. A Resolução temporal do SPOT é de 26 dias, podendo ser reduzida para até 2–3 dias, dependendo da latitude, devido à capacidade de variação do ângulo de

observação do sensor. O satélite SPOT tem como missão primordial obter imagens da Terra para o uso do solo, agricultura, florestas, geologia, cartografia, planejamento regional, recursos hídricos e aplicações de SIG [SPOT IMAGE, 2010].

De acordo com a SPOT Image [2010], as principais aplicações das bandas do satélite HRV/SPOT, são:

- **Banda 1 (0,50 - 0,59 μm) Verde:** Reflectância de vegetação verde sadia; mapeamento de águas.
- **Banda 2 (0,61 - 0,68 μm) Vermelho:** Absorção da clorofila; diferenciação de espécies vegetais; diferenciação de solo e vegetação.
- **Banda 3 (0,78 - 0,89 μm) Infravermelho próximo:** Levantamento de fitomassa; delineamento de corpos d'água.
- **Banda 4 (1,58 - 1,75 μm) Infravermelho médio:** Prospecção Mineral, Óleo e Gás (Petróleo).
- **Banda PAN (0,48 - 0,71 μm):** Estudo de áreas urbanas, com imagens de alta resolução.

2.2 Redes Neurais Artificiais

A Inteligência Computacional busca, através de técnicas inspiradas na natureza, o desenvolvimento de sistemas inteligentes que imitem aspectos do comportamento humano. As Redes Neurais Artificiais (RNA) são técnicas computacionais que apresentam modelos matemáticos que visam a solução de problemas, com base na organização de neurônios do cérebro humano. A ideia é que a RNA seja capaz de aprender e tomar decisões baseadas na aprendizagem, adquirindo conhecimento através da experiência, ou seja, aprendendo, errando e fazendo novas descobertas.

Haykin [1994] descreve que McCullough e Pitts, em 1943, sugeriram a construção de uma máquina baseada ou inspirada no cérebro humano, estabelecendo as bases da neurocomputação, com modelos matemáticos. Em 1951, o primeiro neurocomputador denominado Snark foi construído, com capacidade de aprendizado. Snark ajustava automaticamente seus pesos entre as sinapses, mas não executava nenhuma função útil, porém serviu de inspiração para as ideias de estruturas que o sucederam. Frank Rosenblatt concebeu o “Perceptron” em 1957. Seu interesse inicial era o reconhecimento de padrões. Em 1962, Bernard Widrow, com a ajuda de alguns estudantes,

desenvolveu um novo tipo de elemento de processamento de redes neurais chamado de Adaline, com uma lei de aprendizado semelhante ao Perceptron. Um período de pesquisa silenciosa seguiu-se durante 1967 a 1982. O campo de pesquisa em Redes Neurais Artificiais “explodiu” em 1986, com a publicação do livro Parallel Distributed Processing (Processamento Distribuído Paralelo), editado por David Rumelhart e James McClelland. Em 1987, universidades anunciaram a formação de institutos de pesquisa e programas de educação em neurocomputação.

2.2.1 Neurônio Artificial

Assim como o sistema nervoso é composto por vários neurônios biológicos, a rede neural artificial é também formada por unidades que nada mais são que pequenos módulos que simulam o funcionamento de um neurônio. Estes módulos devem funcionar de acordo com os elementos em que foram inspirados, recebendo e retransmitindo informações [HAYKIN, 1994].

A Figura 2-2 ilustra um modelo de neurônio utilizado em redes neurais artificiais.

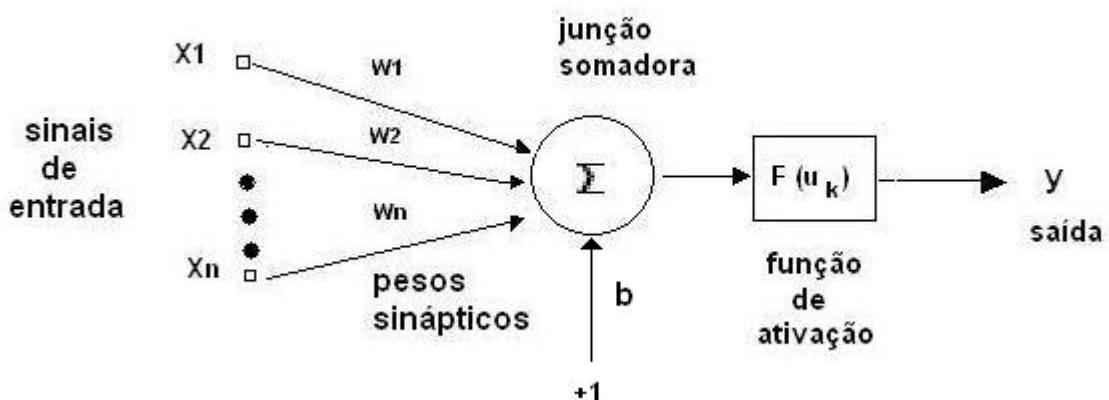


Figura 2-2 - Modelo de neurônio usado em redes neurais artificiais.

O funcionamento básico do neurônio artificial consiste no somatório de cada entrada (x_1, x_2, \dots, x_n) multiplicado pelo peso associado (w_1, w_2, \dots, w_n), além de uma entrada sempre com valor +1, produzindo um nível de atividade. O resultado passa por uma função de ativação ($F(u_k)$), que é disparada produzindo uma resposta de saída (y), que é submetida aos nós da camada seguinte.

2.2.2 Rede de Neurônios

As redes neurais são tipicamente organizadas em camadas (Figura 2-3) que definem sua estrutura topológica ou sua arquitetura (maneira como os elementos de processamento são organizados). Haykin [1994], explica que existem redes neurais de camada simples (*Perceptron*) constituídas por um grupo de neurônios arranjados em apenas uma camada, e as redes *Multi-Layer Perceptron (feedforward)*, formadas por várias camadas intermediárias ou pela combinação de várias redes de camadas simples. Nessa estrutura, a camada de entrada é aquela na qual os padrões são apresentados à rede; as camadas intermediárias são responsáveis por grande parte do processamento, podendo ser consideradas como extratoras de características; e a camada de saída é aquela onde o resultado final é concluído e apresentado.

A Figura 2-2 ilustra uma rede de neurônios dispostos em camadas.

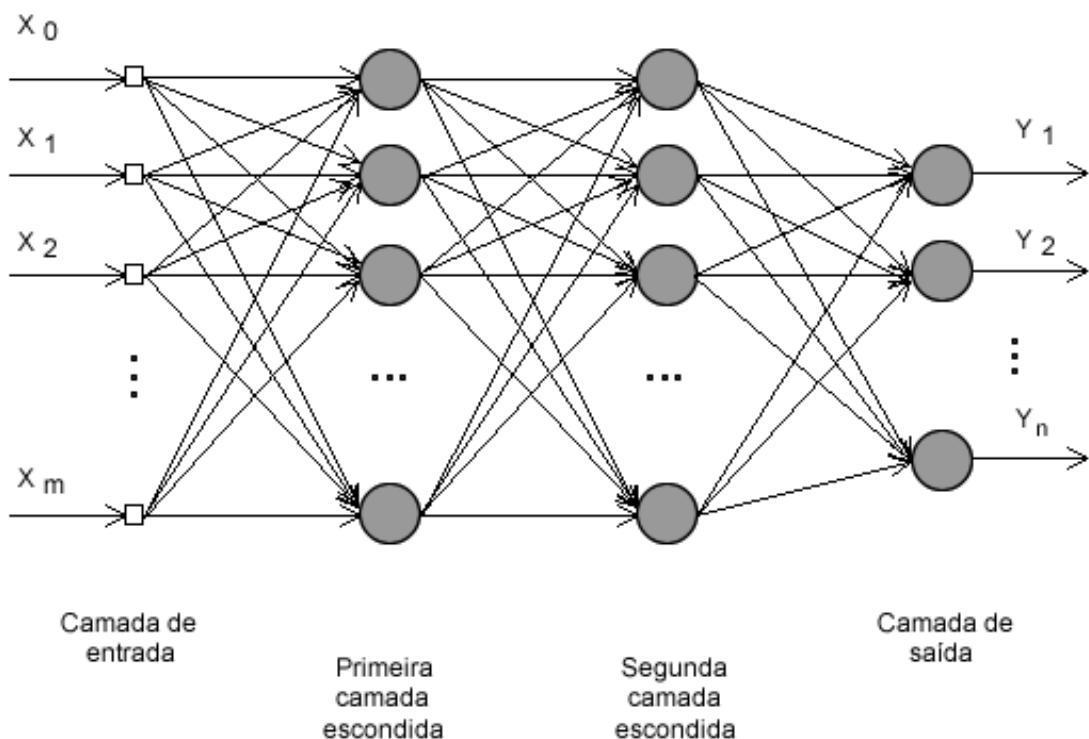


Figura 2-3 – Rede de neurônios dispostos em camadas.

Os modelos de redes neurais possuem uma etapa de treinamento, onde os pesos são ajustados de acordo com os padrões apresentados. Em outras palavras, elas aprendem a partir de

experiências, e são capazes de generalizar diante de informações que não lhe foram apresentadas durante o treinamento.

2.2.3 Aprendizado da rede

Uma das características mais importantes das RNAs é a sua capacidade de aprender por meio de exemplos. Na abordagem conexionista o conhecimento é adquirido através do ajuste das intensidades das conexões entre os neurônios. A etapa de aprendizado de uma RNA consiste em um processo iterativo de ajuste de parâmetros da rede, os pesos das conexões, que guardam, ao final do processo, o conhecimento que a rede adquiriu do ambiente externo [BRAGA *et al.*, 2007].

A forma utilizada pelas RNAs para armazenar conhecimento, segundo Braga *et al.* [2007], é através de aprendizagem, que consiste na fase em que a rede neural absorve dados e, a partir destes dados, modifica seus parâmetros. Isto é feito para que a RNA adquira, de modo gradativo, uma boa capacidade de resposta para o maior número de situações possíveis. Esta etapa pode ser considerada como uma adaptação da RNA às diferentes características de um problema. Por sua vez a generalização de uma RNA está associada à sua capacidade de dar respostas coerentes para dados não apresentados a ela durante o treinamento. Espera-se que uma RNA treinada tenha uma boa capacidade de generalização, independentemente de ter sido controlada durante o treinamento.

Há vários algoritmos diferentes para treinamento de redes neurais, podendo os mesmos ser agrupados em dois paradigmas principais: aprendizado supervisionado e aprendizado não supervisionado.

Aprendizado supervisionado

Aprendizado supervisionado implica, necessariamente, na existência de um supervisor, o qual é responsável por estimular as entradas da rede por meio de padrões de entrada e observar a saída calculada pela mesma, comparando-a com a saída desejada. Como a resposta da rede é função dos valores atuais do seu conjunto de pesos, estes são ajustados de forma a aproximar a saída da rede da saída desejada. O aprendizado supervisionado se aplica a problemas em que se deseja obter um mapeamento entre padrões de entrada e saída [BRAGA *et al.*, 2007]. Os exemplos mais conhecidos de algoritmos para aprendizado supervisionado são a regra delta e a sua generalização para redes de

múltiplas camadas, o algoritmo *backpropagation*.

Aprendizado não supervisionado

No aprendizado não supervisionado não há um supervisor externo para acompanhar o processo de aprendizado. Neste esquema de treinamento somente os padrões de entrada estão disponíveis para a rede, ao contrário do aprendizado supervisionado, cujo conjunto de treinamento possui pares de entrada e saída. Durante o processo de aprendizado os padrões de entrada são apresentados continuamente à rede, e a existência de regularidades nesses dados faz com que o aprendizado seja possível. Regularidade e redundância nas entradas são características essenciais para haver aprendizado não supervisionado. O aprendizado não supervisionado se aplica a problemas que visam à descoberta de características estatisticamente relevantes nos dados de entrada, como por exemplo, a descoberta de agrupamentos ou classes [BRAGA *et al.*, 2007].

2.2.4 Backpropagation

As redes *feedforward* usam o treinamento supervisionado realizado por um algoritmo chamado *error backpropagation* (retro-propagação de erro) [RUMELHART & MCCLELLAND, 1986]. Esse algoritmo, derivado da Regra Delta Generalizada [HAYKIN, 1994], permite um ajuste de pesos em cada uma das camadas da rede e é projetado para minimizar a soma do erro médio quadrático entre a saída calculada por uma arquitetura de múltiplas camadas e a saída desejada.

O processo de treinamento pelo algoritmo de retropropagação de erros, o *backpropagation*, começa com a definição de um conjunto arbitrário de pesos para as conexões da rede e envolve duas fases distintas. Na primeira, um vetor de entrada com a respectiva saída desejada é apresentado à rede e propagado através de suas camadas, computando uma saída para cada elemento de processamento. As saídas dos nós da última camada são, então, comparadas com as saídas desejadas e, a partir disso, são calculados os termos de erro. A segunda fase envolve uma passagem de volta através da rede a partir da última camada, durante a qual o erro é repassado para cada elemento de processamento e os pesos correspondentes são alterados. Em um treinamento bem sucedido, o erro diminui com o aumento do número de iterações e o procedimento converge para um conjunto estável de pesos [GALO, 2000].

2.2.5 Dificuldades de dimensionamento

A definição da quantidade de camadas intermediárias da rede e o número de neurônios em cada camada são de extrema importância para seu desempenho, principalmente no que se refere à sua capacidade de generalização.

Segundo Cybenko [1988], uma camada intermediária é suficiente para aproximar qualquer função contínua, e duas camadas são suficientes para aproximar qualquer função. A utilização de duas camadas intermediárias somente é necessária quando a função a ser aproximada apresenta descontinuidades. Assim, a utilização de um número maior de camadas do que o necessário pode levar a problemas de convergência da rede, já que as camadas intermediárias trabalham com estimativas de erro.

Braga *et al.* [2007] explicam que o número de neurônios determina a capacidade da rede em resolver problemas de determinada complexidade. Quanto maior o número de neurônios, maior a complexidade da rede e maior a sua abrangência em termos de soluções possíveis. A determinação do número de neurônios é, na verdade, o problema mais fundamental em aprendizado de redes neurais, pois não existe na literatura uma regra geral que determine de forma precisa qual deve ser o número de neurônios de uma rede neural para a solução de um determinado problema.

Normalmente, o número de camadas e o número de neurônios em cada camada são definidos em função de uma inspeção prévia nos dados e da complexidade do problema. A quantidade de dados, as características, a dimensão e a variabilidade desses dados são algumas maneiras de realizar a inspeção prévia. Sabe-se, no entanto, que o ajuste inadequado da complexidade da rede pode levar a efeitos indesejáveis na resposta final do modelo. A questão de ajuste da complexidade da rede ao problema é tratada na literatura como um dilema entre o *bias* e a variância do modelo, que envolve a obtenção de um modelo que não seja muito rígido a ponto de não modelar fielmente os dados, mas que também não seja excessivamente flexível a ponto de modelar também o ruído [BRAGA *et al.*, 2007]

O equilíbrio entre *bias* (rigidez) e a variância (flexibilidade) da rede é obtido por meio de seu dimensionamento. Quanto maior a sua estrutura, maior o número de parâmetros livres ajustáveis e, consequentemente, maior a sua flexibilidade. Porém, quando os dados são apresentados à rede não se tem real conhecimento de sua complexidade, daí a dificuldade do problema de dimensionamento. Redes superdimensionadas podem provocar erros de *overfitting*, e as subdimensionadas podem provocar *underfitting*.

O *overfitting* acontece quando a rede memoriza os padrões de treino e perde assim a capacidade de generalizar, deixando de prever corretamente as saídas relativas a pontos que não se encontram no conjunto de treino. O *overfitting* pode ocorrer quando há um número excessivo de neurônios ou camadas para o problema que está sendo abordado. Pode também ocorrer *overfitting* no treinamento, quando a rede neural é treinada com uma quantidade de épocas além do necessário.

O *underfitting* ocorre quando a rede não é treinada suficientemente para se tornar capaz de produzir resultados satisfatórios, ou seja, quando há um número muito baixo de neurônios ou de camadas para o problema que está sendo abordado. Pode ocorrer também *underfitting* no treinamento, quando a rede neural é treinada com uma quantidade de épocas abaixo do necessário.

2.3 Mapeamento de áreas cafeeiras a partir de imagens de satélite

Os primeiros mapeamentos de uso da terra baseavam-se em trabalhos de campo. As técnicas convencionais de levantamento e atualização de informações sobre a cobertura e uso da terra caracterizavam-se pelo alto custo e pela dificuldade de obtenção de dados em curtos períodos de tempo. Posteriormente, a partir de década de 50, as fotografias aéreas passaram a ser usadas na identificação detalhada de culturas agrícolas. Na década de 70, as imagens orbitais passaram a ser um importante instrumento no mapeamento do uso e ocupação do solo [BORGES *et al.*, 1993]. Segundo Florenzano [2002], as imagens de satélites proporcionam uma visão sinóptica multitemporal de extensas áreas da superfície terrestre, mostrando o ambiente e sua transformação por alterações causadas por fenômenos naturais e pela ação do homem através do uso e da ocupação do espaço.

A cultura cafeeira tem sido mapeada com sucesso por diversos pesquisadores, como Dallemand [1987] e Batista *et al.* [1990]. Especificamente em Minas Gerais, Tardin *et al.* [1992], Moreira *et al.* [2004], Vieira *et al.* [2007a] e Vieira *et al.* [2007a] obtiveram bons resultados no mapeamento e caracterização da cultura cafeeira na região. Vieira *et al.* [2006] estudaram a relação entre os parâmetros da cultura cafeeira e a resposta espectral em imagens do sensor TM/Landsat, em áreas relevantes para a cafeicultura em Minas Gerais.

Moreira *et al.* [2004] afirmam que, embora a cultura do café apresente variações no comportamento espectral devido a fatores como espaçamento, idade e época do ano, a mesma pode ser identificada e mapeada em imagens de satélites com razoável precisão. Moreira [2007] mapeou

todo o estado de Minas Gerais, classificando visualmente imagens de satélite.

A resposta espectral da cultura cafeeira é bastante complexa, em função das diversas variáveis que envolvem a caracterização da mesma e do ambiente em que está inserida [VIEIRA *et al.*, 2006]. Além disso, sua resposta espectral assemelha-se muito com a da vegetação natural. Como as curvas espectrais da mata e do café são muito parecidas, é comum e esperada uma confusão entre essas duas classes. Por outro lado, o que mais diferencia visualmente uma área de mata, de uma ocupada com café é a textura das imagens (Figura 2-4).

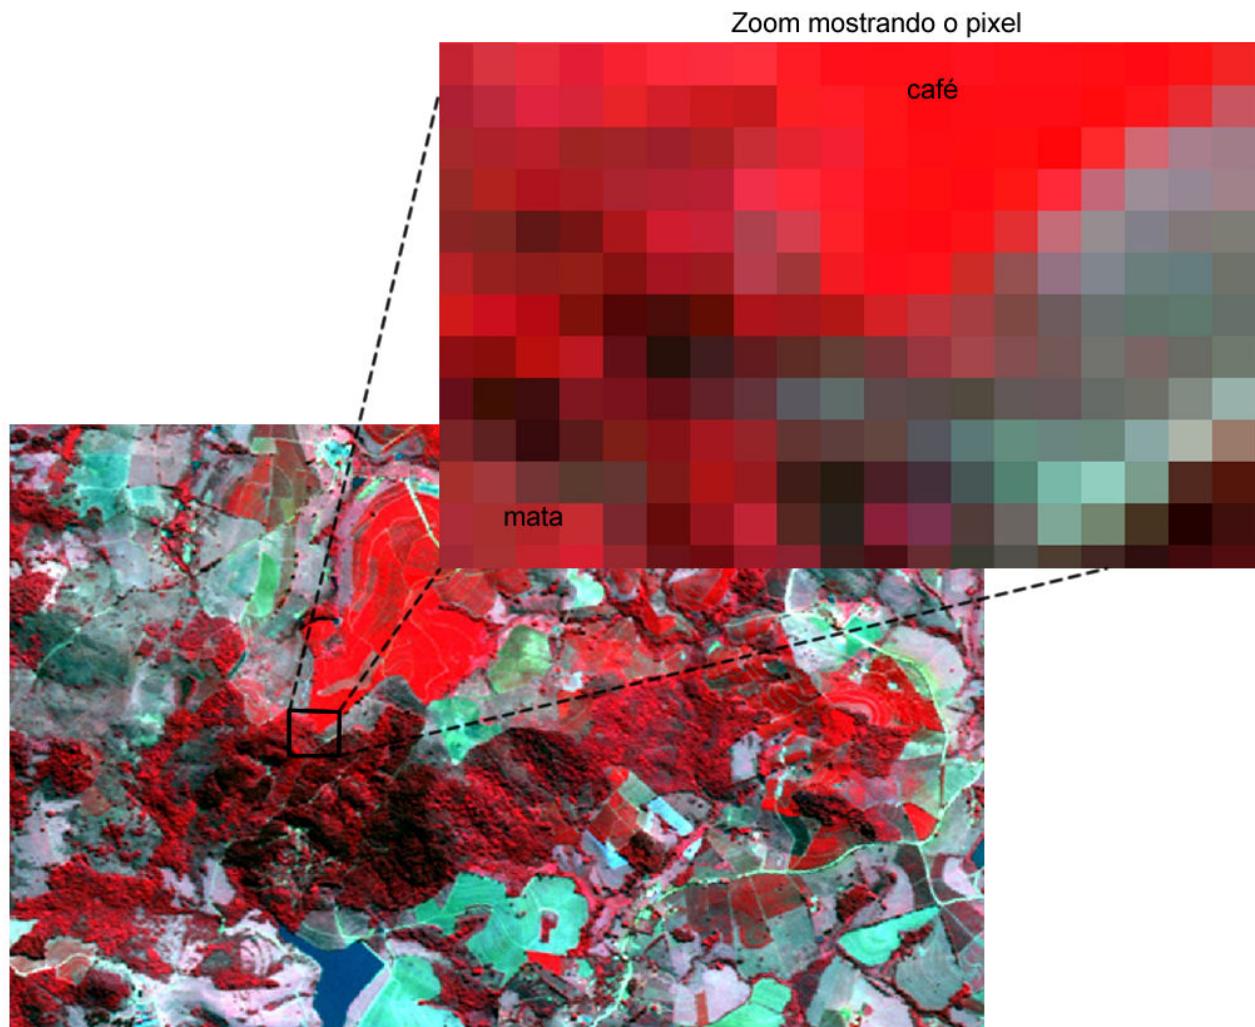


Figura 2-4 – Diferença entre as texturas do café e da mata.

2.4 Classificação automática de áreas cafeeiras

Como visto na seção 2.2.3, são considerados dois tipos de algoritmos de classificação: supervisionados e não supervisionados. Os supervisionados requerem uma amostra dos dados previamente classificados, e a partir daí aplicam o conhecimento representado pela amostra na classificação do restante dos dados. Essa pré-classificação da amostra é denominada “treinamento”. Os algoritmos não supervisionados dispensam o treinamento, e, portanto são capazes de distinguir classes apenas com base nas características intrínsecas do conjunto de dados. Os métodos supervisionados são muito mais comuns em classificação de dados de sensoriamento remoto.

Existem diversos classificadores automáticos implementados em *software*, como por exemplo, os disponíveis no SIG SPRING, os algoritmos Maxver, Battacharya e Isoseg.

O algoritmo Maxver é um classificador baseado no método estatístico de Máxima Verossimilhança. É o algoritmo mais comum que realiza a classificação de forma supervisionada. Considera a ponderação das distâncias entre médias dos níveis digitais das classes, utilizando parâmetros estatísticos. O classificador Isoseg é um algoritmo para classificar regiões de uma imagem segmentada. É um algoritmo de agrupamento de dados não-supervisionado, aplicado sobre o conjunto de regiões, que por sua vez são caracterizadas por seus atributos estatísticos de média, matriz de covariância, e também pela área. O algoritmo Battacharya realiza a classificação por meio de imagem segmentada, ou seja, usa um classificador por região. O princípio é análogo ao utilizado para o classificador Isoseg, porém a medida de distância usada é a distância de Battacharya. O classificador Battacharya, ao contrário do Isoseg, que é um classificador não supervisionado, requer interação do usuário, por meio do treinamento, portanto, é um método de classificação supervisionada. Neste caso, as amostras serão as regiões formadas na segmentação de imagens [SPRING, 2009b].

2.4.1 Avaliação da acurácia da classificação

No processo de análise dos dados do sensoriamento remoto, um passo fundamental é a avaliação da precisão temática. Os usuários necessitam saber quão confiáveis são os dados provenientes dos mapas temáticos, derivados da classificação de um produto do sensoriamento remoto, e através da matriz de confusão são possíveis derivar medidas e consequentemente verificar erros oriundos do processo de atribuição dos *pixels* a determinadas classes [VIEIRA, 2000].

A avaliação da acurácia pode ser obtida por meio de coeficientes de concordância

derivados da matriz de confusão, sendo que estes podem ser expressos como concordância total ou para classes individuais. Congalton [1991] relata que o uso do coeficiente Kappa (κ) é satisfatório na avaliação da precisão de uma classificação temática, pelo fato de levar em consideração toda a matriz de confusão no seu cálculo, inclusive os elementos de fora da diagonal principal, os quais representam as discordâncias na classificação, diferentemente da exatidão global, por exemplo, que utiliza somente os elementos diagonais (concordância real).

Lobão *et al.* [2005], descrevem que, para o cálculo do coeficiente Kappa é necessário a construção de um mapa de verdade de campo, para que se possa fazer uma tabulação cruzada indicando a proporção de casos presentes e/ou ausentes nos mapas: Mapa classificado (1) e o Mapa verdade (2). Considerando uma situação com apenas duas classes, o resultado é expresso em uma tabela onde: a célula a indica a proporção dos casos em que o real (1) e o classificado (2) são corretos; b , quando (1) for correto e a (2) errado; c , quando a observação 1 for correto e a 2 errado; e a d , quando ambas forem erradas (Tabela 2-2).

Tabela 2-2 – Tabulação cruzada

		Mapa Classificado	
		SIM	NÃO
Mapa Verdade	SIM	a	b
	NÃO	c	d

Lobão *et al.* [2005] explicam, através das equações abaixo, como calcular o Kappa a partir da tabulação cruzada.

$$P_o = a+d \quad (1)$$

$$P_e = (a+b)(a+c) + (b+d)(c+d) \quad (2)$$

$$K = (P_o - P_e) / (1 - P_e) \quad (3)$$

Os coeficientes calculados pelo K são qualificados, neste trabalho, com base na Tabela 2-3, adaptada de Galparsoro & Fernández [2001].

Tabela 2-3 - Valor para avaliar o grau de concordância a partir do índice Kappa.

Valor do Kappa	Concordância
< 0,20	Pobre
0,21 – 0,40	Fraca
0,41 – 0,60	Moderada
0,61 – 0,80	Boa
0,81 – 1,00	Muito Boa

2.4.2 Classificação de imagens com base em características espectrais

Classificadores automáticos para o mapeamento de áreas cafeeiras foram estudados por [MARQUES, 2003; BERNARDES *et al.*, 2007; SANTOS *et al.*, 2007; VIEIRA *et al.*, 2009b].

A fim de averiguar qual o melhor classificador automatizado, dentre os disponíveis no *software* SPRING, Marques [2003] realizou uma classificação por região, usando o algoritmo Battacharya e outra classificação feita de forma supervisionada, *pixel a pixel*, usando o algoritmo Maxver (máxima verossimilhança), ambos sobre uma imagem da região cafeeira de Machado (MG). Os treinamentos dos classificadores foram realizados sobre amostras coletadas dentro dos limites definidos pela interpretação da imagem orbital. A exatidão das classificações automatizadas do *software* SPRING foi medida por meio do método estatístico Kappa. Marques concluiu que os algoritmos classificadores obtiveram um bom desempenho na elaboração do mapa temático de uso da terra, para a área estudada. O mapa elaborado pelo algoritmo Battacharya obteve um bom desempenho (42% para o Kappa) e o mapa elaborado pelo algoritmo Maxver classificado como razoável (39% para o Kappa). O algoritmo Battacharya foi mais preciso na elaboração do mapa temático de uso da terra do que o algoritmo Maxver.

Bernardes *et al.* [2007], utilizando imagens Landsat, avaliaram o desempenho de diferentes métodos para classificação automática de áreas cafeeiras no município de Patrocínio-MG, na região denominada Serra Negra. Foram testados três algoritmos de classificação automática: Battacharya, Maxver e Isoseg, tidos como abordagens probabilísticas. O relevo plano com grandes extensões de terra ocupadas com culturas anuais e perenes com características mais homogêneas, presente na área estudada, favoreceu o bom desempenho dos classificadores, sendo o algoritmo

Battacharya o que melhor se adaptou, com 73% de acerto, seguido do classificador Maxver, com 57% e Isoseg, com 47% de acerto em relação ao conjunto de dados considerado como referência. Tal comportamento das classificações automáticas pode ser explicado pelas peculiaridades da área estudada. A região constitui uma estrutura dômica resultante de processos vulcânicos, sendo a parte central predominantemente plana, onde as classificações se comportam bem para a cultura de café, porém as bordas da estrutura tem relevo bastante movimentado, o que resultou em padrões complexos de sombreamento pelo relevo e áreas cafeeiras segmentadas e intercaladas com fragmentos florestais, dificultando o reconhecimento.

Ainda justificando a influência do relevo e padrões de forma e tamanho das lavouras na classificação automática de imagens orbitais, Machado [2002] encontrou índices de acerto extremamente baixos para classificação supervisionada de diversas transformações de imagens visando a identificação da cultura cafeeira na região de Manhuaçu. Os valores encontrados variaram de 25 a 42% e o autor explica que problemas relacionados à similaridade espectral, à topografia accidentada da região, com o consequente sombreamento das imagens, e à fragmentação das lavouras de café, localizadas em áreas contíguas a matas, foram os principais causadores de baixo desempenho.

Vieira *et al.* [2009b] desenvolveram um trabalho em que era proposto avaliar a exatidão da interpretação visual de uma imagem SPOT 5 no mapeamento do café na região de Guaxupé, tendo como referência dados obtidos em campo, bem como comparar o desempenho de técnicas de mapeamento automático da mesma área em comparação com a interpretação visual, visando a avaliação da viabilidade de aplicação destas técnicas para agilizar o mapeamento do parque cafeeiro na região. Foram trabalhadas imagens SPOT 5 com resolução espacial de 10 metros e de 2,5 metros. A cena foi submetida ao processamento por diferentes métodos de classificação automática para a imagem com resolução de 10 metros e por interpretação visual para a imagem com resolução de 2,5 metros. Dados obtidos em campo foram tomados como referência para obtenção de índices de exatidão do mapeamento. Foram estratificadas as classes café, mata e outros usos, sendo esta última oriunda do agrupamento dos demais tipos de vegetação como culturas anuais, pastagens, solo exposto, áreas urbanas, etc. A interpretação visual apresentou maior acerto no mapeamento da cultura cafeeira, 75% com o índice Kappa, enquanto os classificadores Battacharya e Isoseg alcançaram os índices kappa de 51% e 58%, respectivamente. Considerando-se a alta resolução espacial da imagem SPOT 5 (2,5 metros), era de se esperar que a interpretação visual desta imagem proporcionasse uma exatidão próxima de 100%, já que a identificação dos diferentes tipos de cobertura vegetal pode ser feita de maneira bem mais precisa do que com produtos de sensoriamento remoto em uso atualmente.

2.4.3 Aplicação de Redes Neurais Artificiais em atividades agrícolas

Redes neurais artificiais classificadoras têm sido utilizadas com sucesso para a solução de vários problemas ligados à atividade agrícola, como o florescimento e a maturação fisiológica da soja [ELIZONDO *et al.*, 1994], a qualidade em grãos de milho [LIAO *et al.*, 1993], a detecção de rachaduras em ovos [PATEL *et al.*, 1995], a classificação de grãos para semente [LUO *et al.*, 1999], a produtividade do milho [LIU & GOERING, 1999] e na direção de tratores agrícolas [PINTO *et al.*, 1999].

Varella *et al.* [2002] desenvolveram um programa computacional para estimar a cobertura do solo, utilizando-se redes neurais treinadas por retropropagação do erro. Os dados para treinamento da RNA foram obtidos de imagens digitais coloridas. O programa computacional classificador apresentou índice de exatidão global de 82,10%, e esse resultado mostra que RNAs podem ser utilizadas em programas computacionais classificadores para separar o solo descoberto da cobertura do solo, utilizando como dados de entrada valores numéricos de um pixel e seus vizinhos, apresentando-se como alternativa para a classificação de imagens mesmo onde os objetos não podem ser diferenciados aplicando a técnica da limiarização.

Bilobrovec *et al.* [2004] utilizaram redes neurais artificiais para a modelagem de séries históricas de dados. Para tal, usaram uma rede neural do tipo *Multi-Layer Perceptron* (MLP) com aprendizado utilizando o algoritmo *backpropagation*, e concluíram que as Redes Neurais Artificiais são uma ferramenta poderosa para a realização de simulações, capazes de realizar prognósticos com o mesmo nível de precisão ou, em alguns casos, até com precisão maior que os modelos estatísticos clássicos.

Picoli [2006] utilizou um modelo de RNAs com a finalidade de estimar a produtividade agrícola da cana-de-açúcar por talhão utilizando variáveis quantitativas, qualitativas e espectrais. A rede utilizada foi do tipo *Multi-Layer Perceptron* (MLP), com uma camada oculta, utilizando o algoritmo *backpropagation*, para treinamento da rede. Segundo a autora, conseguiu-se atingir o objetivo principal, que foi estimar a produtividade agrícola da cana-de-açúcar.

Ribeiro *et al.* [2005] compararam diferentes métodos de classificação em imagens digitais multiespectrais de alta resolução do sensor IKONOS II para o mapeamento da cobertura terrestre. Os métodos de classificação foram o da Mínima Distância, o da Máxima Verossimilhança e o de Redes Neurais Artificiais (utilizando algoritmo de treinamento *backpropagation*). Eles

concluíram que os métodos que mostraram melhor desempenho foram Redes Neurais Artificiais e Máxima Verossimilhança.

Nas últimas décadas, diversos estudos têm sido realizados utilizando abordagens alternativas para melhoria do mapeamento da cobertura vegetal em diferentes regiões através de métodos que incorporam dados auxiliares. Através da adição de informações de relevo, SKIDMORE [1989] mapeou com sucesso diferentes espécies de eucaliptos em uma região de estudo na Austrália. Carvalho [2001] utilizou, além dos dados espectrais contidos nas imagens, séries temporais de *Normalized Difference Vegetation Index* (NDVI), dados de textura e feições topográficas visando o mapeamento de florestas semideciduais na região de Lavras-MG e concluiu que as séries temporais de índices de vegetação foram mais importantes na área estudada. O autor relata ainda que os dados topográficos foram importantes como dados de entrada na classificação por redes neurais.

A abordagem de RNA foi utilizada por Cruz & Galo [2003], em imagens de sensoriamento remoto de datas e sensores diferentes para discriminar entre classes de uso e cobertura da terra. Uma imagem TM/Landsat foi adotada como referência para o treinamento e validação da rede neural e então aplicada tanto à própria imagem quanto a uma cena CCD/CBERS. Os resultados obtidos indicaram que passando os dados multiespectrais e multisensores por um pré-processamento, obedecendo as condições de similaridade espectral e à normalização radiométrica das bandas, uma rede treinada com dados de uma data e sensor pode ser aplicada a uma segunda imagem, tomada em outra data e por outro sensor.

Navares *et al.* [2009], estudando os aspectos relacionados à reflectância da imagem na classificação de áreas cafeeiras na região de Machado-MG por meio de redes neurais artificiais, observaram que existe uma variação na assinatura espectral do café em produção em relação a épocas mais secas ou menos secas. Isto também acontece com a mata. Existem bandas em que, devido à premissa anterior, seria possível diferenciar café em produção de mata. Dependendo da época do ano, certa banda seria mais adequada do que outra.

Vieira *et al.* [2009a], concluíram que o reconhecimento de padrões da cultura cafeeira por métodos automatizados é dificultado tanto pela complexidade da cultura, como pela similaridade do padrão espectral café/mata. Fragmentos de vegetação nativa, como cerrado e mata densa, são os que mais dificultam o desempenho dos algoritmos para interpretação automática de imagens. Uma possibilidade para melhorar a classificação por RNA seria a filtragem dos dados já classificados removendo as pequenas áreas classificadas, o que refinaria o mapa obtido por esta técnica. Outras alternativas seriam a utilização de relações de proximidade (buffer), por exemplo em redes de drenagem, áreas urbanas e outras classes que não interessariam à classificação desejada.

2.4.4 Classificação de imagens com base em atributos de textura e forma

Diversos estudos vêm sendo desenvolvidos utilizando-se abordagens alternativas para melhoria do mapeamento da cobertura vegetal em diferentes regiões através de métodos que incorporam dados auxiliares, visando minimizar o problema da ambiguidade espectral entre as classes de café e mata.

Rocha & Leite [2004] definem a textura como uma das características mais importantes para classificar e reconhecer objetos e cenas, podendo ser caracterizada por variações locais dos valores de *pixels* que se repetem de maneira regular ou aleatória ao longo do objeto ou imagem. Textura pode também ser definida como um arranjo repetitivo de padrões sobre uma área, com o objetivo de medir a sua aspereza, observando fatores como as dependências de níveis de cinza, auto-correlação, entre outros.

As texturas podem ser referenciadas como sendo um conjunto de determinados padrões existentes nas superfícies físicas, perceptíveis ao olho humano e que trazem grande quantidade de informações sobre a natureza da superfície, como suavidade, rugosidade e regularidade. Para descrição de padrões de texturas em imagens, normalmente são utilizadas três abordagens principais: a estatística, a estrutural e a espectral [GONZALEZ & WOODS, 2000].

Os atributos de forma possibilitam a separação dos objetos que possuem formas diferentes e mesma resposta espectral. A análise da forma do objeto é de fundamental importância para estudos relacionados com o espaço urbano e áreas agrícolas, onde existem classes com formas geométricas definidas (pivô central, talhões). Os classificadores tradicionais, baseados em princípios espetrais, são os que habitualmente encontram-se implementados na maioria dos softwares utilizados em processos de extração de atributos de uma região. No processamento digital de imagens, a representação de uma região não consiste apenas na diferenciação dos níveis de cinza dos objetos, mas também da delimitação de sua fronteira através da forma dos objetos (região) e também de sua textura.

Han & Hayes [1990] concluíram que a técnica textural de classificação de imagens elimina a necessidade de um sistema colorido de aquisição, porém a obtenção da informação textural de imagens digitais envolve uma quantidade considerável de recursos computacionais, resultando em um longo tempo de processamento. Assim, as RNAs, utilizando como dados de entrada os valores numéricos de um pixel e seus vizinhos, apresentam-se como alternativa para a classificação de imagens.

Andrade *et al.* [2003] explicam que os objetos visíveis na imagem podem ser espectralmente muito próximos, e sua discriminação visual pode ser possível utilizando outros atributos além dos espetrais. Os dados providos pelos sistemas sensores de alta resolução apresentam maior detalhe, e os métodos de classificação orientados a objeto passam a ter maior importância, já que os mesmos consideram, além dos atributos espetrais, as relações espaciais entre os *pixels*. No caso particular de uma cena urbana, a análise da forma ganha significado, pois os objetos presentes na imagem são construídos pelo homem, com um predomínio de formas geométricas. O ganho obtido com a inclusão de parâmetros de forma é significativo. Nesse trabalho a acurácia estimada para a classe “construções” subiu de 38% para 84%. A precisão do resultado da classificação realizada é dependente da segmentação utilizada para a extração das regiões das imagens. Quando a segmentação é realizada em áreas com segmentos muito pequenos ou muito grandes, a classificação não dará um bom resultado.

Martins *et al.* [2007] utilizaram uma rede neural artificial para classificação de texturas. Para tanto definiram uma rede neural formada por uma arquitetura de *Perceptrons*, onde o processo de treinamento foi o algoritmo *backpropagation*. Os resultados mostraram que a rede foi capaz de classificar texturas corretamente. Os autores concluíram que o processo de classificação apresentado pode ser utilizado em sistemas de análise por visão computacional que envolvem imagens com texturas aleatórias, tais como: grãos e outros alimentos em esteiras de carregamento, tecidos em fábricas e imagens de satélites.

Oliveira *et al.* [2009] utilizando um classificador por regiões, aplicaram um método de extração de atributos de forma, implementando algoritmos significativos na separabilidade de classes e analisando a geometria de imagens CBERS-2B, câmera pancromática de alta resolução HRC. Os atributos de forma levaram a resultados eficientes no processo de classificação por regiões. Os autores explicam ainda que o bom resultado no processo de classificação de região não depende apenas da etapa de extração de atributos, mas também da imagem segmentada.

Souza *et al.* [2009], partindo do pressuposto de que a distinção entre a textura do café e da mata é muito utilizada pelo interpretador no momento da classificação visual, devido à grande ambiguidade espectral existente entre essas classes, desenvolveram um estudo sobre os padrões texturais que diferenciam o cafezal e a mata. Foi usado o classificador textural do software Texture [RENNÓ *et al.*, 1998] sobre imagens do satélite TM/Landsat 5, bandas 3 e 4. Os melhores resultados foram gerados utilizando as medidas *cluster shade*, uma quantização de 256 níveis de cinza e janela de 3x3 *pixels*, obtendo um índice Kappa de 86%, demonstrando que as medidas texturais podem ser usadas satisfatoriamente na discriminação entre as classes temáticas de café e mata.

No caso da distinção entre mata e café, que possuem os valores de reflectância muito

próximos [VIEIRA *et al.*, 2006], espera-se que os atributos de textura contribuam para sua classificação, pois o dossel da mata possui uma textura heterogênea e uma área irregular. Já o dossel do cafeeiro possui uma textura mais homogênea e uma forma regular (linhas retas, ângulos).

2.5 Considerações Finais

Neste Capítulo foram apresentados os conceitos necessários para o embasamento deste trabalho de dissertação. Iniciou-se apresentando conceitos teóricos sobre Sensoriamento Remoto e satélites orbitais, apresentando também as principais aplicações das bandas espectrais dos satélites TM/Landsat e HRV/SPOT. Na sequência, foram apresentados conceitos sobre Redes Neurais Artificiais; técnicas para mapeamento de áreas cafeeiras; e alguns classificadores automáticos de imagens de satélite. Finalizando o Capítulo, foram referenciados trabalhos utilizando Redes Neurais Artificiais e atributos de textura e forma na classificação automática de imagens de satélite, e os índices utilizados para avaliar a acurácia das classificações.

Espera-se que as redes neurais artificiais sejam utilizadas na identificação de classes de uso e ocupação da terra em imagens multiespectrais utilizando atributos de textura e forma, tornando-se importantes para o desenvolvimento de novas ferramentas na discriminação de dados em imagens de sensoriamento remoto, além da redução de custos e de tempo na obtenção de mapas temáticos para a cultura do café.

No próximo capítulo serão apresentados os métodos utilizados neste trabalho de dissertação para classificação automática de imagens de satélite com redes neurais artificiais. São apresentadas também as áreas de estudo e as ferramentas computacionais utilizadas no processamento e análise dos dados.

Capítulo 3

Metodologia

O desenvolvimento da metodologia do presente trabalho de dissertação tem como função a definição de um sistema de classificação automática de imagens de satélite que seja adequado para a identificação e mapeamento do uso e ocupação das terras, com ênfase na cultura do café, por meio de um modelo de Redes Neurais Artificiais. Os diversos procedimentos de classificação automática disponíveis apresentam limitações decorrentes principalmente nas resoluções espetrais e radiométricas das imagens orbitais e nas características intrínsecas da cultura do café.

3.1 Áreas de estudo

As áreas de estudo são as regiões cafeeiras de Machado, Três Pontas e Guaxupé. Foram escolhidas estas três regiões do Sul de Minas Gerais por apresentarem características ambientais diferentes. A região de Machado possui um relevo muito íngreme, causando dificuldade no mapeamento de uso da terra por causa das sombras que ocorrem na imagem de satélite. A região de Três Pontas apresenta uma cafeicultura em relevo mais suavizado e áreas de café contíguas [VIEIRA *et al.*, 2006]. Já a região de Guaxupé possui relevo suave ondulado a ondulado, intermediário entre as outras duas regiões, caracterizado por áreas mais recortadas na imagem. A Figura 3-1 ilustra a localização das regiões no estado de Minas Gerais.

A região de Guaxupé, localizada no Planalto de Poços de Caldas, posiciona-se geograficamente entre as coordenadas $21^{\circ}5'42.46''$ S a $21^{\circ}17'10.85''$ S e $46^{\circ}36'59.12''$ W a $46^{\circ}51'30.28''$ W, numa área de 520 km^2 . Na região prevalecem altitudes de 500 a 1300 metros, clima ameno, temperatura média anual de $20,6^{\circ}\text{C}$, precipitação média anual de 1690 mm, relevo suave

ondulado a ondulado, predomínio de Latossolos e Argissolos. Devido a suas condições geográficas e climáticas, o município de Guaxupé apresenta condições privilegiadas para o cultivo do café.

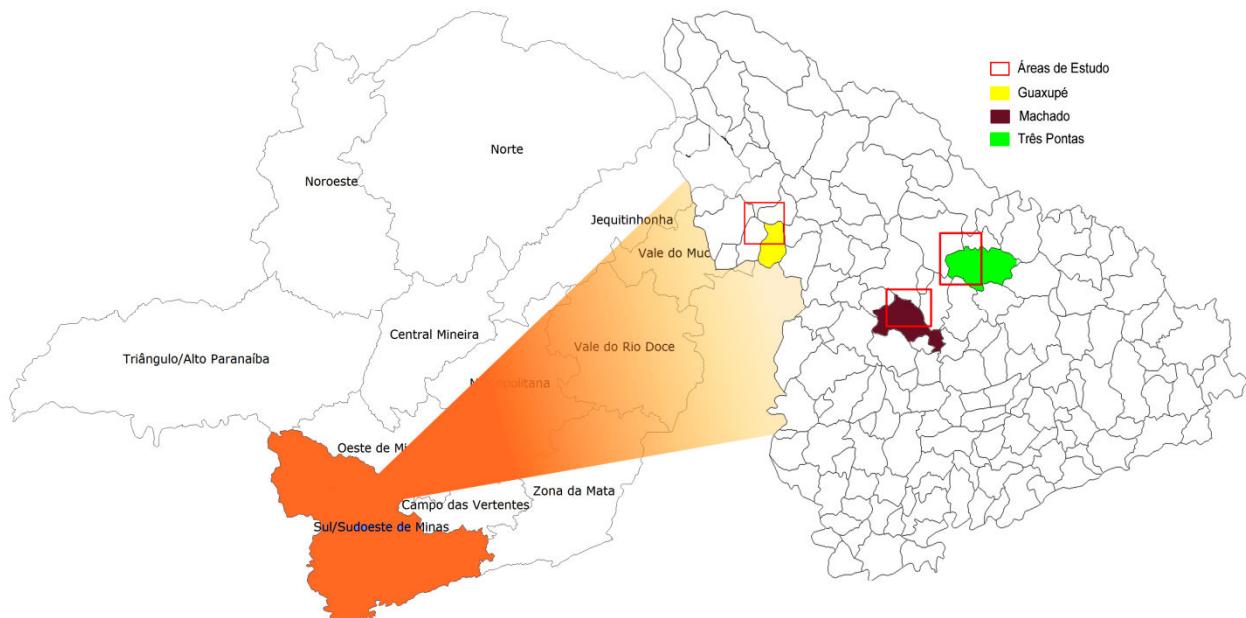


Figura 3-1 – Localização das áreas de estudo: Guaxupé, Machado e Três Pontas, no estado de Minas Gerais.

A região de Machado é delimitada pelas coordenadas 21°42'05'' S e s 21°31'10'' S, e entre 46°02'38'' W e 45°47'30'' W, com área total de 520 km². O ambiente é caracterizado por áreas elevadas, com altitudes de 780 a 1260 metros, clima ameno, sujeito a geadas, moderada deficiência hídrica, relevo suave ondulado a forte ondulado, com grande possibilidade de produção de bebidas finas, sistemas de produção de médio a alto nível tecnológico. Lacerda (2001) desenvolveu um trabalho na mesma região e mostrou que existem dois ambientes geomorfológicos: Ambiente N-NE-E, em relevo predominantemente plano a ondulado, ocorrendo na região norte, nordeste e leste em relação ao núcleo urbano; e Ambiente W-NW, ocorrendo relevo predominantemente ondulado a montanhoso na região oeste e noroeste em relação ao núcleo urbano.

Na região de Três Pontas a cafeicultura representa 70% da renda agrícola. Posiciona-se geograficamente entre as coordenadas 21° 17' 10.07'' S a 21° 27' 57.41'' S e 45° 30' 4.69'' W a 45° 45' 3.33'' W, com uma área total de 510 km². A região é cortada por três redes de drenagem principais, que desaguam na Represa de Furnas. Seu clima é do tipo tropical de altitude, com temperatura média anual oscilando entre 18°C e 19°C, o que evidencia o predomínio de temperaturas amenas, durante boa parte do ano. A altitude média do município é de 905 metros, sendo que a máxima atinge 1.234 metros na Serra de Três Pontas. É uma região que pode ser considerada

privilegiada para o mapeamento da cultura cafeeira, pois apresenta um relevo predominantemente suave ondulado, que permite maior incidência de luz solar na cultura, obtendo-se assim uma melhor resposta espectral [SOUZA *et al.*, 2009].

3.2 Imagens de satélite utilizadas

Os dados multiespectrais utilizados para classificação automática com Redes Neurais Artificiais, correspondem a imagens orbitais TM/Landsat 5, bandas 3, 4 e 5, para as regiões de Machado e Três Pontas, com datas de passagem de 16/08/2007 e 16/07/2007, respectivamente, adquiridas junto ao Instituto Nacional de Pesquisas Espaciais – INPE. Para a região de Guaxupé foram utilizadas imagens multiespectrais do satélite HRV/SPOT, bandas 1, 2 e 3, com datas de passagem de 28/05/2005 (a imagem foi cedida pela Cooperativa Regional de Cafeicultores de Guaxupé Ltda – Cooxupé). As Figuras 3-2, 3-3 e 3-4 mostram as imagens utilizadas para classificação. Para validação das classificações, foram utilizados Mapas de Uso e Ocupação da Terra de Guaxupé, Machado e Três Pontas–MG [EPAMIG, 2009], classificados visualmente e conferidos em campo.

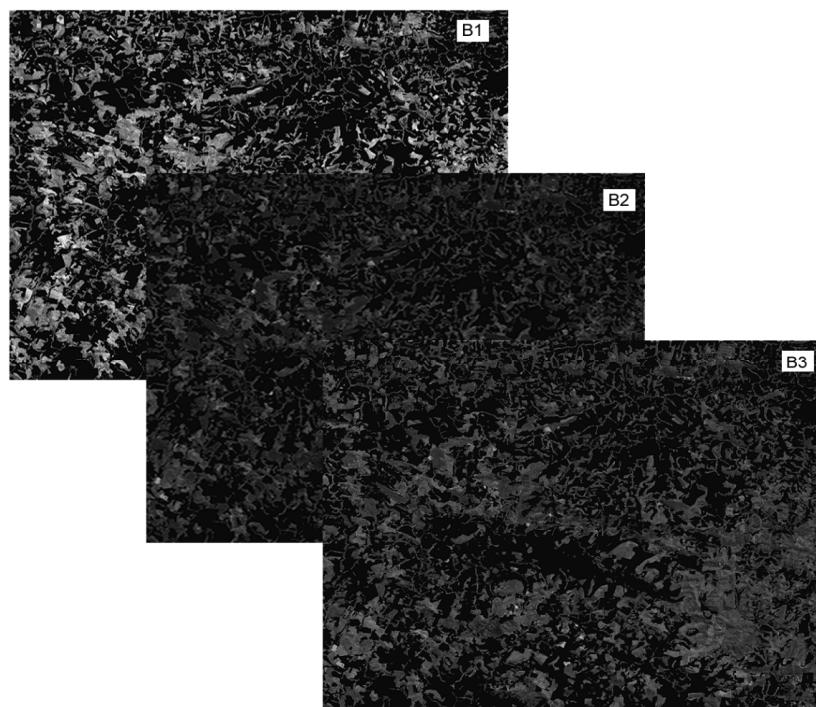


Figura 3-2 - Imagens HRV/SPOT 5, bandas 1, 2 e 3 da região de Guaxupé, com máscara de outros usos.

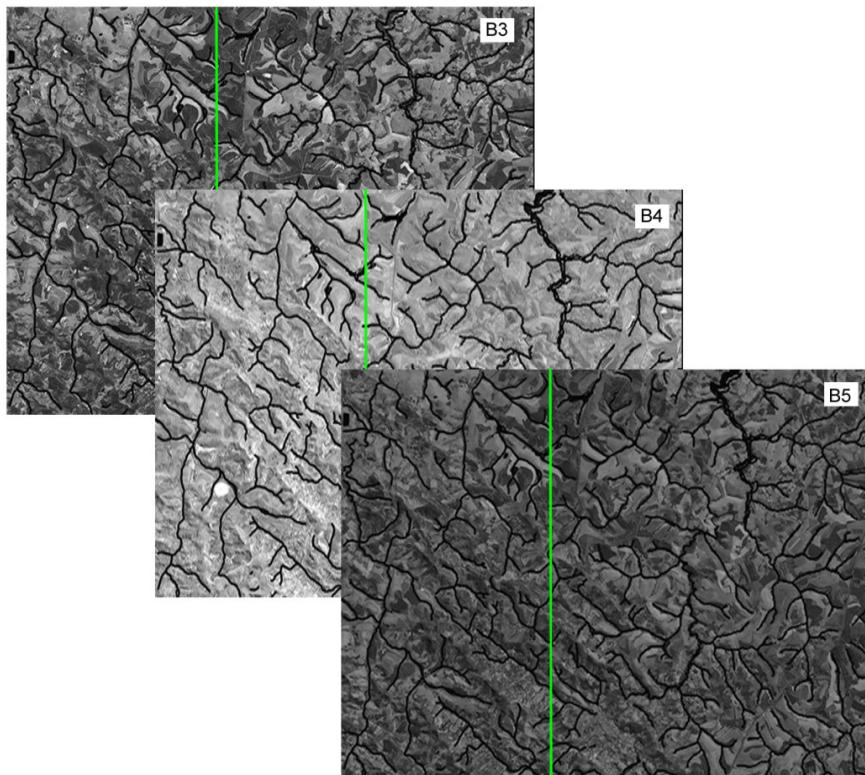


Figura 3-3 – Imagens TM/Landsat 5, bandas 3, 4 e 5 da região de Machado, com máscara de drenagem.

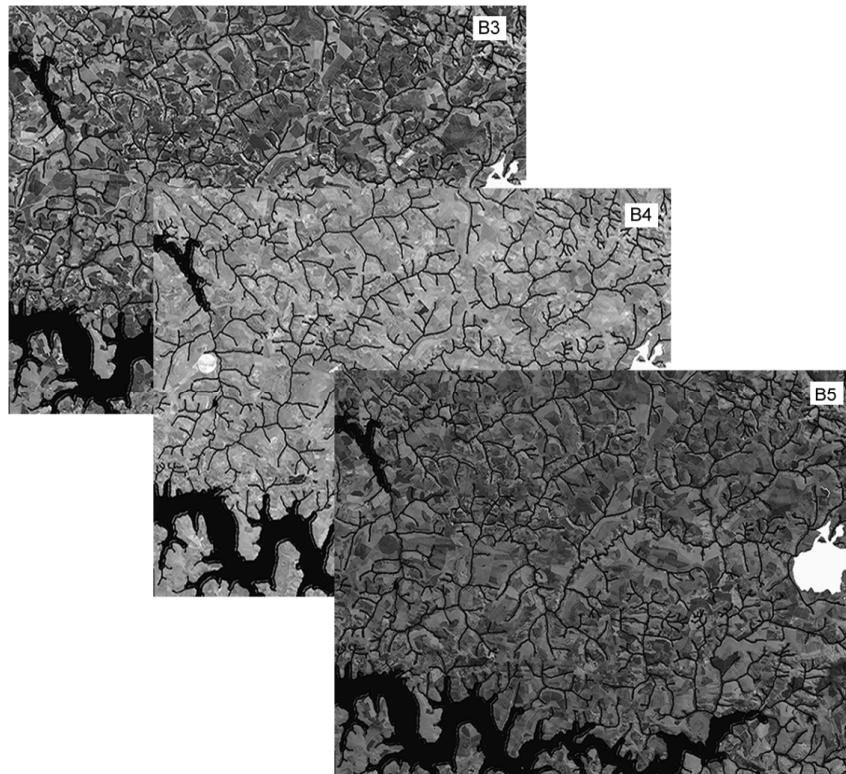


Figura 3-4 – Imagens TM/Landsat 5, bandas 3, 4 e 5 da região de Três Pontas, com máscara de drenagem e área urbana.

3.3 Ferramentas computacionais utilizadas no processamento e análise dos dados

Para o processamento e análise digital dos dados multiespectrais foi utilizado um microcomputador tipo PC, processador Intel Xeon com 3,25 GB de memória RAM contendo o sistema operacional Windows XP Service Pack 3.

No desenvolvimento desse trabalho foram utilizados os seguintes aplicativos: *software* SPRING [CÂMARA *et al.*, 1996], versão 4.3.3, para o pré-processamento dos dados (registro e classificação da imagem, criação de *buffers* e máscaras) e pós-processamento (validação das classificações) e o *software* IDRISI Andes [EASTMAN, 2006], versão 15.0, para o processo de treinamento e classificação dos dados através de Redes Neurais Artificiais.

- **SPRING**

O SPRING (Sistema de Processamento de Informações Georreferenciadas) é um sistema de informação geográfico (SIG) desenvolvido pelo Instituto Nacional de Pesquisas Espaciais (INPE) em São José dos Campos/SP para ambientes UNIX e Windows [SPRING, 2009a]. Tem se mostrado uma opção altamente atrativa na área de geoprocessamento, pois pode ser considerado um *software* de domínio público e constitui um produto desenvolvido com tecnologia totalmente nacional.

A estrutura do sistema garante uma organização que permite o armazenamento e recuperação eficiente dos dados, graças à natureza de seu subsistema de armazenamento de dados. Um “Banco de Dados” no SPRING corresponde, fisicamente, a um diretório onde são armazenados tanto o modelo de dados com suas definições de Categorias e Classes, quanto aos projetos pertencentes ao banco. Os projetos são armazenados em subdiretórios juntamente com seus arquivos de dados: pontos, linhas, imagens orbitais e aéreas, imagens temáticas, textos, grades e objetos. Inicialmente, deve-se criar um banco para, então, ativá-lo e inserir dados no mesmo.

O sistema SPRING constitui-se de quatro aplicativos ou programas executáveis: o Impima – utilizado para leitura de imagens e conversão para o formato GRIB; o SPRING – programa principal do sistema onde serão modelados os dados; o Scarta - programa que permite a elaboração de cartas a partir de dados previamente tratados no programa SPRING; e o programa Iplot - utilizado para abrir um arquivo IPL, criado pelo Scarta [SPRING, 2009a].

▪ Idrisi

O software Idrisi é um sistema de informação geográfico e de processamento de imagens com ênfase em funções de análise de dados geográficos em formato matricial [EASTMAN, 2006]. Consiste de um programa principal de interface e mais de 150 módulos que abrangem um grande número de operações analíticas, desde ferramentas básicas para cálculo de distância, por exemplo, até ferramentas mais sofisticadas para análises complexas de dados geográficos. Desde a primeira versão em 1987, o Idrisi vem sendo desenvolvido na *Graduate School of Geography* da Clark University.

O Idrisi trabalha de forma analítica sobre imagens, cobrindo o espectro de necessidades de SIG e de Sensoriamento Remoto, desde consulta a banco de dados e modelagem espacial, até realce e classificação de imagens. Dispõe de recursos especiais para monitoramento ambiental e gerenciamento de recursos naturais, destacando-se a análise de séries temporais/mudanças, apoio a decisão por critérios múltiplos e por objetivos múltiplos; análise de incerteza e modelagem para simulação [EASTMAN, 2006].

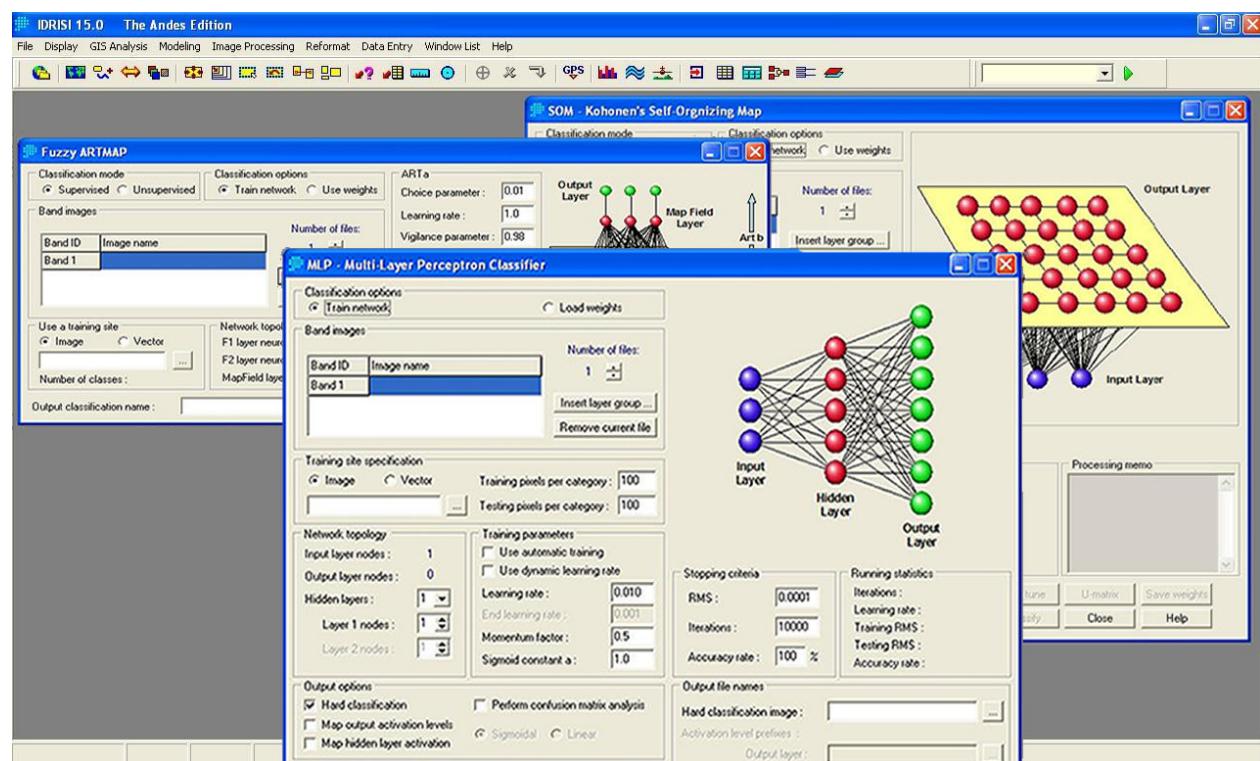


Figura 3-5 – Software Idrisi, classificadores baseados em Redes Neurais.

O Idrisi amplia as aplicações relativas ao sensoriamento remoto de imagens por meio de um inovador conjunto de técnicas de processamento, que incluem o aperfeiçoamento dos algoritmos de classificação, tais como por redes neurais e por análise de árvore de decisão. O Idrisi apresenta três classificadores de rede neural: *perceptron* de múltiplas camadas (MLP), *Self-organizing map* (SOM) e Fuzzy ARTMAP (Figura 3-5).

3.4 Procedimento Metodológico

O diagrama da Figura 3-6 exibe as três etapas principais para desenvolvimento da classificação das imagens pela Rede Neural.



Figura 3-6 – Metodologia do trabalho.

Para as três regiões cafeeiras estudadas, Guaxupé, Machado e Três Pontas, a metodologia para desenvolvimento da aplicação da RNA foi dividida em três etapas principais: na primeira foi realizado o pré-processamento dos dados, em que foram criadas máscaras em cada uma das três bandas utilizando a Linguagem Espacial para Geoprocessamento Algébrico (LEGAL), do SPRING. A segunda etapa consistiu no treinamento de uma Rede Neural Artificial dimensionada a partir de amostras representativas das classes de interesse (café, mata, água, outros usos e área urbana), as

quais foram coletadas na imagem utilizada tanto para treinamento quanto para validação. Ainda na segunda etapa, a rede treinada foi aplicada em toda a imagem, verificando assim seu potencial em discriminar as cinco classes de saída estabelecidas. A terceira etapa consistiu na análise e validação dos resultados, realizando um cruzamento entre o mapa classificado visualmente e o mapa classificado pela Rede Neural Artificial. Utilizou-se o índice Kappa para avaliar o desempenho da RNA, uma vez que o uso desse coeficiente é satisfatório na avaliação da precisão de uma classificação temática. Pelo fato de levar em consideração toda a matriz de confusão no seu cálculo, inclusive os elementos de fora da diagonal principal, os quais representam as discordâncias na classificação (BERNARDES, 2006).

3.4.1 Pré-processamento dos dados

Para a realização da classificação, os dados de sensoriamento remoto foram submetidos aos pré-processamentos necessários para que a RNA fosse capaz de reconhecer as mesmas classes nas imagens multiespectrais. Cada área de estudo foi submetida a um pré-processamento específico, isso ocorre porque as áreas apresentam características distintas, e consequentemente procedimentos diferentes são necessários para preparação dos dados.

▪ Guaxupé

As imagens de sensoriamento remoto do satélite SPOT possuem melhor resolução espacial se comparadas a imagens do Landsat. Considerando as características dos sensores remotos orbitais quanto à sua resolução espacial e espectral e os mecanismos de interação da radiação eletromagnética com a cultura do café, percebe-se uma variabilidade espectral bem tênuem com áreas de mata, de modo que os estudos envolvendo o mapeamento de áreas cafeeiras por meio de Sensoriamento Remoto têm sido desenvolvidos por Vieira *et al.* [2006] e Bernardes [2006]. Foi criada uma máscara sobre as três bandas da imagem SPOT, agregando as demais classes (outros usos, água, solo exposto e café em formação) do mapa classificado visualmente, a uma nova classe denominada outros usos (Figura 3-7). Para a criação desta máscara, foi utilizada a Linguagem Espacial para Geoprocessamento Algébrico (LEGAL), do SPRING, na qual a máscara deixava visível para a RNA apenas as classes café, mata e outros usos (classes agregadas).

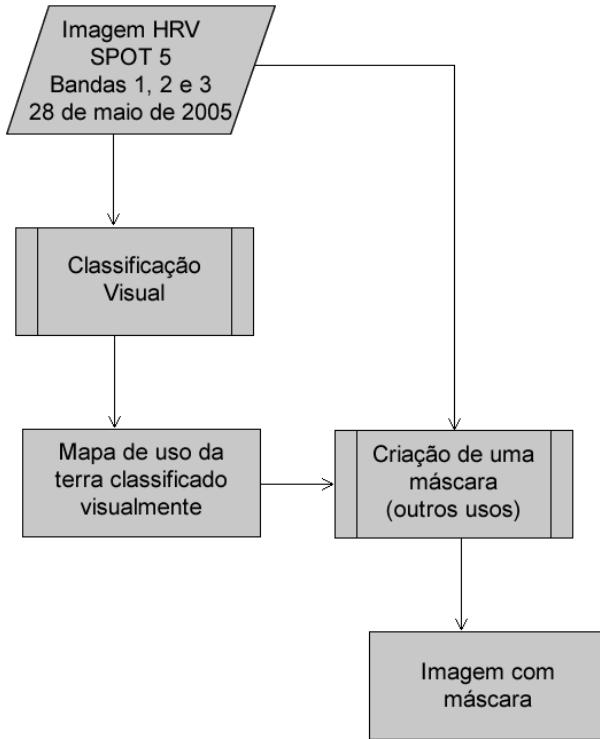


Figura 3-7 – Pré-processamento realizado para a região de Guaxupé.

▪ Machado

Para que a RNA fosse capaz de reconhecer as mesmas classes nas imagens TM/Landsat 5 da região de Machado, foi realizado um processo de restauração para melhorar a qualidade espacial dos dados. Boggione [2004] explica que as técnicas de restauração de imagens são orientadas para a modelagem da degradação e recuperação do sinal original que foi degradado durante o processo de formação de imagens.

Durante o processo de geração de imagens, a resolução espacial é degradada devido à difração óptica, ao tamanho do detector, às limitações do filtro eletrônico, canal de transmissão, etc. Esta degradação faz com que as imagens apresentem um aspecto borrado, que caracteriza a perda de detalhes. Com técnicas de restauração, é possível melhorar a resolução efetiva da imagem até um certo nível [BOGGIONE, 2004].

O processo de restauração realizado nas imagens transformou os *pixels* que possuíam a resolução espacial de 30m para 10m. Este processamento foi realizado para melhorar a qualidade espacial dos dados [FONSECA & MASCARENHAS, 1987]. Em seguida, a imagem foi dividida em

duas partes, separando assim os dois ambientes geomórficos existentes na região, segundo exposto em LACERDA [2001], que mostra que a região de Machado possui dois ambientes geomorfológicos: um com relevo mais movimentado e outro com relevo menos movimentado (Figura 3-8).

A resolução 303/2002 do Código Florestal do Conselho Nacional do Meio Ambiente (CONAMA – 303/2002) foi utilizada para o desenvolvimento de uma máscara nas Áreas de Preservação Permanente, pois estas áreas não deveriam possuir o cultivo do café e poderiam causar confusão na classificação pela rede neural. O código determina que, 30 metros no entorno da drenagem, 50 metros no entorno das nascentes e 100 metros no entorno das represas são áreas que devem ser preservadas. Foram desconsideradas as áreas de preservação permanente da resolução do CONAMA 303/2002, que inclui o terço superior de morros e montanhas cuja elevação ultrapasse 50m e tenha declividade superior a 30%, pois o objetivo foi criar máscaras nas APPs da rede de drenagem.

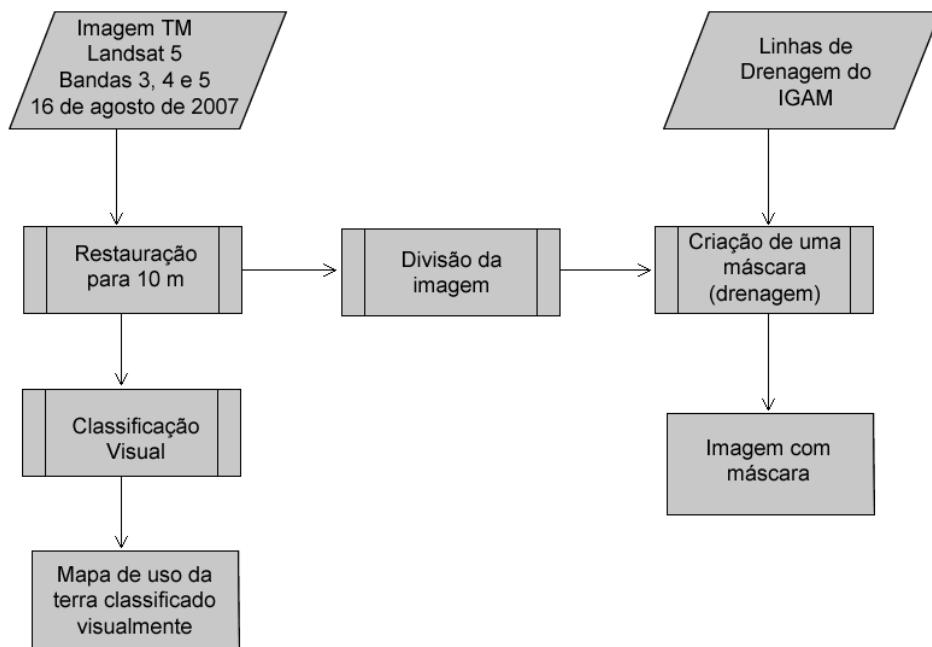


Figura 3-8 – Pré-processamento realizado para a região de Machado.

As linhas de drenagem do Instituto Mineiro de Gestão das Águas (IGAM) foram utilizadas para a criação de uma máscara nas três bandas da imagem. Sobre as linhas de drenagem foi feita a relação de proximidade (*buffer*) de 50m no entorno da drenagem. Utilizou-se 50m no entorno da drenagem para assegurar que todas as áreas preservadas seriam eliminadas durante a classificação. Com o *buffer* criado, foi realizado um cruzamento do *buffer* com o mapa de uso da terra, e atribuído o

valor dez aos *pixels* que se encontravam nestas áreas, utilizando a Linguagem Espacial para Geoprocessamento Algébrico (LEGAL), do SPRING. Esse procedimento foi realizado para tentar eliminar o erro causado durante o processo de classificação da RNA, uma vez que ao longo da drenagem existem pequenas áreas de mata que se confundem com café ou qualquer outra classe de uso. Foi criada, também, uma máscara na área urbana de Machado e atribuído aos *pixels* o valor de 255.

■ Três Pontas

Para a realização da classificação, os dados de sensoriamento remoto foram submetidos aos pré-processamentos necessários para que a RNA fosse capaz de reconhecer as mesmas classes nas imagens multiespectrais. A metodologia utilizada foi fundamentada no trabalho de ANDRADE *et al.* [2010]. A Figura 3-9 ilustra este processo.

Foram utilizadas as linhas de drenagem do Instituto Mineiro de Gestão das Águas (IGAM), e sobre elas realizado o levantamento espacial das áreas que deveriam estar preservadas utilizando a relação de proximidade (*buffer*), criando-se uma máscara ao longo da rede de drenagem, em cada uma das três bandas, seguindo a resolução 303/2002 do Código Florestal do CONAMA.

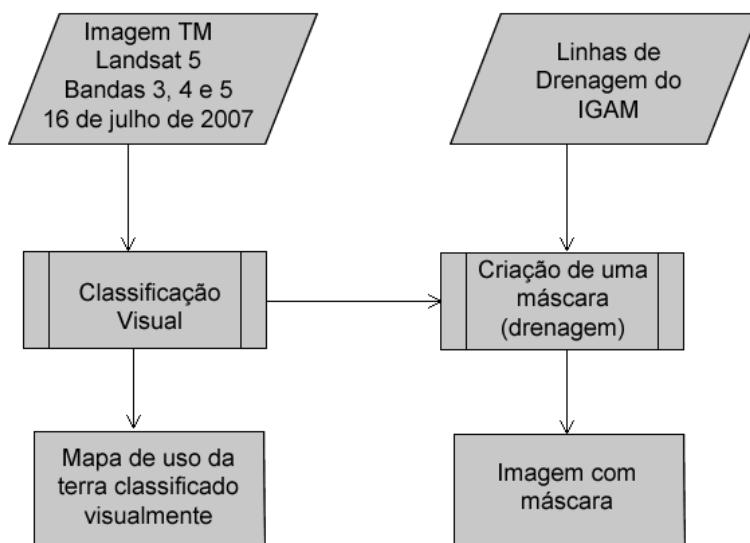


Figura 3-9 – Pré-processamento realizado para a região de Três Pontas.

Em seguida, foi realizado o cruzamento do *buffer* com o mapa de uso da terra, e atribuído o valor dez aos *pixels* que se encontravam nestas áreas, utilizando a Linguagem LEGAL do SPRING. Foi criada também, uma máscara na área urbana de Três Pontas e atribuído aos *pixels* o valor de 255.

3.4.2 Classificação da imagem pela RNA

Para as três regiões estudadas foram realizadas as classificações das imagens pela RNA constando das seguintes etapas: a definição e assinatura espectral das amostras; definição da arquitetura e treinamento da RNA; aplicação da rede; e obtenção do mapa classificado pela RNA (Figura 3-10).

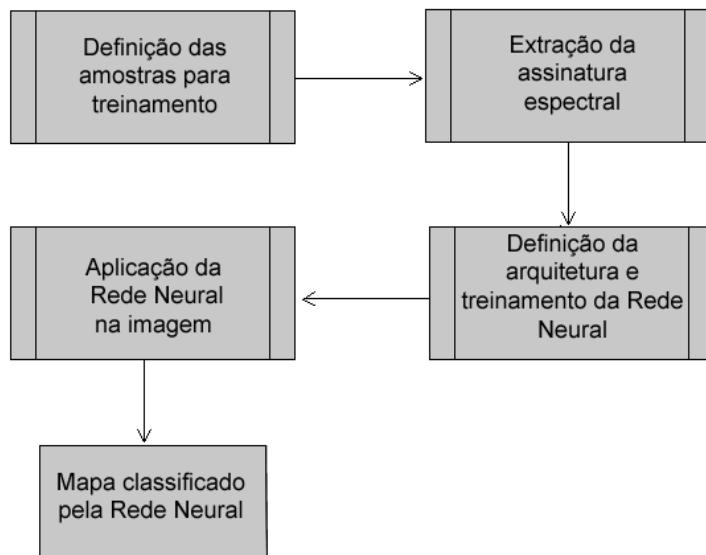


Figura 3-10 – Classificação da imagem pela RNA.

Foram selecionados entre 45 e 50 polígonos de tamanhos variados e espaçados para cada classe, da seguinte forma: ***café em produção***: correspondente aos cafezais em fase produtiva, com idade acima de 3 anos, porte maior que 1m e cobertura vegetal do solo acima de 50%; ***mata***: correspondente às áreas ocupadas por vegetação natural de porte variado, incluindo matas ciliares, resquícios de floresta tropical, capoeiras e vegetação de cerrado; ***área urbana***: área com grande concentração de construções; ***água***: áreas de rios, lagos naturais, represas e a máscara de drenagem; e ***outros usos***: lavouras cafeeiras recém-plantadas ou em formação, com cafeeiros abaixo de 3 anos e exposição parcial do solo, áreas com culturas anuais em diversos estágios de desenvolvimento, áreas com pastagem natural, pastagem formada, culturas anuais ou semiperenes.

Após a obtenção das áreas de treinamento, foi utilizado o módulo *Makesig* do Idrisi para realizar a extração da assinatura espectral do conjunto de amostras. Para a definição da arquitetura da RNA, foi executado o módulo de classificação por redes neurais do tipo *multi-layer perceptron*, do software Idrisi. O número de elementos da camada de saída foi definido com base no número de classes a serem classificadas na imagem, sendo cinco nós com valores identificados na criação das amostras. Foram realizados testes para obter a melhor arquitetura a ser utilizada (quantidade de camadas, quantidade de neurônios por camada, função de ativação).

A rede foi treinada utilizando o algoritmo de treinamento *backpropagation*, variando os parâmetros de treinamento: taxa de aprendizado, taxa de *momentum*, número de amostras de treinamento, entre outros. Em seguida, a rede já treinada foi aplicada sobre a área de estudo, identificando automaticamente as classes definidas durante a coleta das amostras, resultando em um mapa temático.

3.4.3 Validação dos resultados

Para validar a classificação da rede neural foram realizados cruzamentos entre os mapas obtidos pela classificação da RNA com o mapa de referência, utilizando a Linguagem LEGAL do SPRING (Figura 3-11). Os mapas de referência utilizados são os de uso e ocupação da terra de cada área de estudo, gerados pela Equipe de Geoprocessamento GeoSolos [EPAMIG, 2009], conferidos em campo. Com o cruzamento dos mapas, foi possível analisar o desempenho da RNA, utilizando o índice Kappa [LEÃO *et al.*, 2007], que é baseado na construção de matrizes de erro ou de contingência. O uso desse coeficiente é satisfatório na avaliação da precisão de uma classificação temática, pelo fato de levar em consideração toda a matriz de confusão no seu cálculo, inclusive os elementos de fora da diagonal principal, os quais representam as discordâncias na classificação (BERNARDES, 2006).

O novo mapa gerado, definido como Mapa de Interseção das áreas cafeeiras, é a espacialização dos erros da classificação das áreas cafeeiras, avaliado em três classes, sendo elas: **Áreas classificadas corretamente:** *pixels* de áreas de café classificadas pela RNA e pelo método visual; **Áreas classificadas incorretamente:** *pixels* que a RNA classificou como café, porém não eram áreas cafeeiras e **Áreas não classificadas:** *pixels* que a RNA deixou de classificar como café, classificando como outra classe.

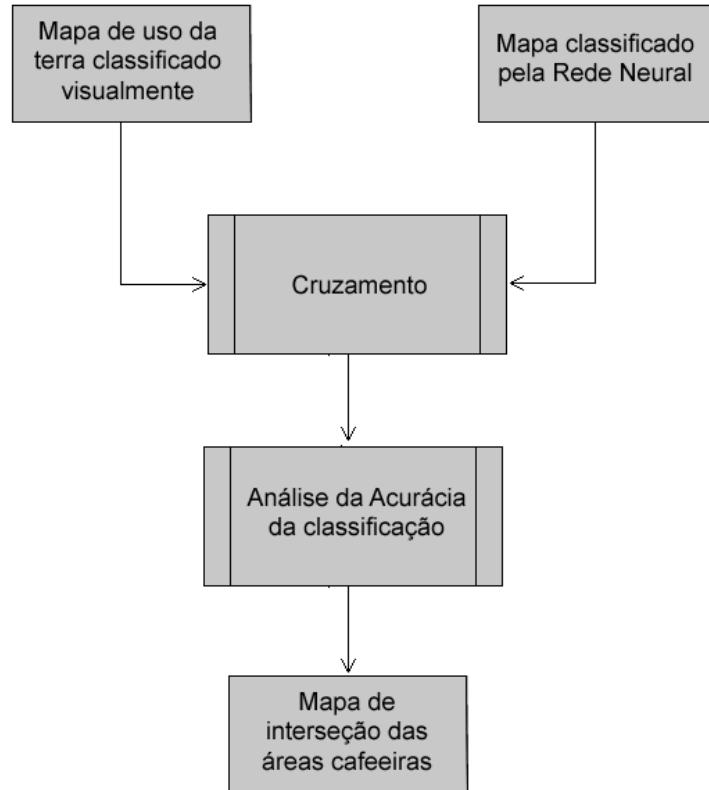


Figura 3-11 – Validação dos resultados.

3.5 Considerações Finais

Neste Capítulo foi descrita a metodologia utilizada para classificação automática de imagens de satélite. Foram apresentadas as áreas de estudo e as ferramentas computacionais utilizadas no processamento e análise dos dados. O procedimento metodológico foi apresentado em três etapas: a etapa inicial constou do pré-processamento dos dados, que foi diferente para cada área de estudo; a segunda e a terceira etapa, classificação da imagem e validação dos resultados, foram iguais para as três áreas de estudo. No próximo capítulo são apresentados os resultados obtidos com a metodologia descrita neste capítulo.

Capítulo 4

Resultados e Discussão

Neste capítulo são apresentados e discutidos os resultados obtidos com o desenvolvimento deste trabalho de dissertação. Os resultados são apresentados de acordo com cada área de estudo. Iniciou-se apresentando os resultados obtidos para a região de Guaxupé, que com a máscara criada, obteve bons resultados. São apresentados, para a região de Machado, dois resultados obtidos, um para cada ambiente, já que a região apresenta ambientes geomorfológicos diferentes. Por fim, são apresentados os resultados obtidos para a região de Três Pontas.

Como explicitado no Capítulo 3, o treinamento da rede foi realizado adotando um modelo de rede neural com estrutura de múltiplas camadas e treinamento supervisionado. A RNA foi treinada com o algoritmo *backpropagation*, disponível no software Idrisi. Foram realizados diversos testes para definição da melhor arquitetura para a classificação, realizando as seguintes alterações na arquitetura da RNA: número do conjunto de *pixels* para o conjunto de treinamento e teste; número de camadas; número de neurônios nas camadas; fator de *momentum* e taxa de aprendizado.

4.1 Resultados obtidos na região de Guaxupé

As imagens da região de Guaxupé utilizadas para classificação pela RNA possuíam uma máscara nas áreas previamente definidas na classe outros usos. Com a criação dessa máscara, foram definidas apenas três classes de saída para a rede, sendo elas: café, mata e outros usos. Para cada classe, foram selecionados entre 5 e 8 polígonos (pequenos pedaços da imagem) de tamanhos variados e espaçados ao acaso para serem utilizados como dados de treinamento da RNA.

A determinação do número de neurônios é, na verdade, o problema mais fundamental em aprendizado de redes neurais, pois não existe na literatura uma regra geral que determine, de forma precisa, qual deve ser o número de neurônios de uma rede neural para a solução de um determinado problema [Braga *et al.*, 2007]. A Tabela 4-1 mostra as configurações utilizadas para teste na tentativa de obter a rede que melhor classificasse a imagem, e em destaque está à arquitetura que apresentou melhor resultado. A execução das classificações possui um tempo de processamento que variava de 4 a 5 minutos.

A arquitetura que apresentou melhor resultado foi a configuração 2, uma rede neural com 14 neurônios em uma única camada escondida. Outros parâmetros definidos foram: um conjunto de 55 pixels por categoria para o conjunto de teste e treinamento, taxa de aprendizado de 0,02; fator de momentum de 0,5 para agilizar na convergência da rede; e constante de sigmóide de 1. Como critério de parada do treinamento da RNA foi estabelecido o limite de 10.000 iterações ou erro médio quadrático (EQM) de 0,0001. A parada do treinamento da RNA aconteceu pelo número de iterações do algoritmo *backpropagation*, resultando em um valor de EQM de 0,006641 para os dados de treinamento, e 0,00779 para os dados de teste.

A configuração 5 alcançou um valor de EMQ de 0,007089, ou seja, menor que a configuração escolhida, porém quando analisado o resultado final da classificação, a arquitetura não teve um bom desempenho na separação das classes café e mata. Este fato pode ser explicado pela utilização de um número maior de camadas do que o necessário, que leva a rede a ter dificuldades para convergir.

Tabela 4-1 - Configurações utilizadas para realização dos testes, região de Guaxupé.

Configuração	Pixel ¹	Camadas escondidas	Neurônios		Taxa de aprendizado	Momentum	Iterações	EMQ	
			1 ^a Camada	2 ^a Camada				Trein.	Teste
1	60	1	10	-	0,02	0,53	10000	0,007076	0,008265
2	55	1	14	-	0,02	0,50	10000	0,006641	0,00779
3	65	1	8	-	0,02	0,53	10000	0,006891	0,007366
4	55	1	16	-	0,02	0,50	10000	0,006284	0,008308
5	60	2	10	8	0,02	0,53	10000	0,008646	0,007089

¹ Número de pixels selecionados para o conjunto de treinamento e teste

A Figura 4-1 mostra o mapa de uso da terra classificado visualmente com máscara. Esse mapa foi utilizado como referência para avaliar a classificação feita pela RNA. O mapa classificado pela rede neural treinada é apresentada na Figura 4-2.

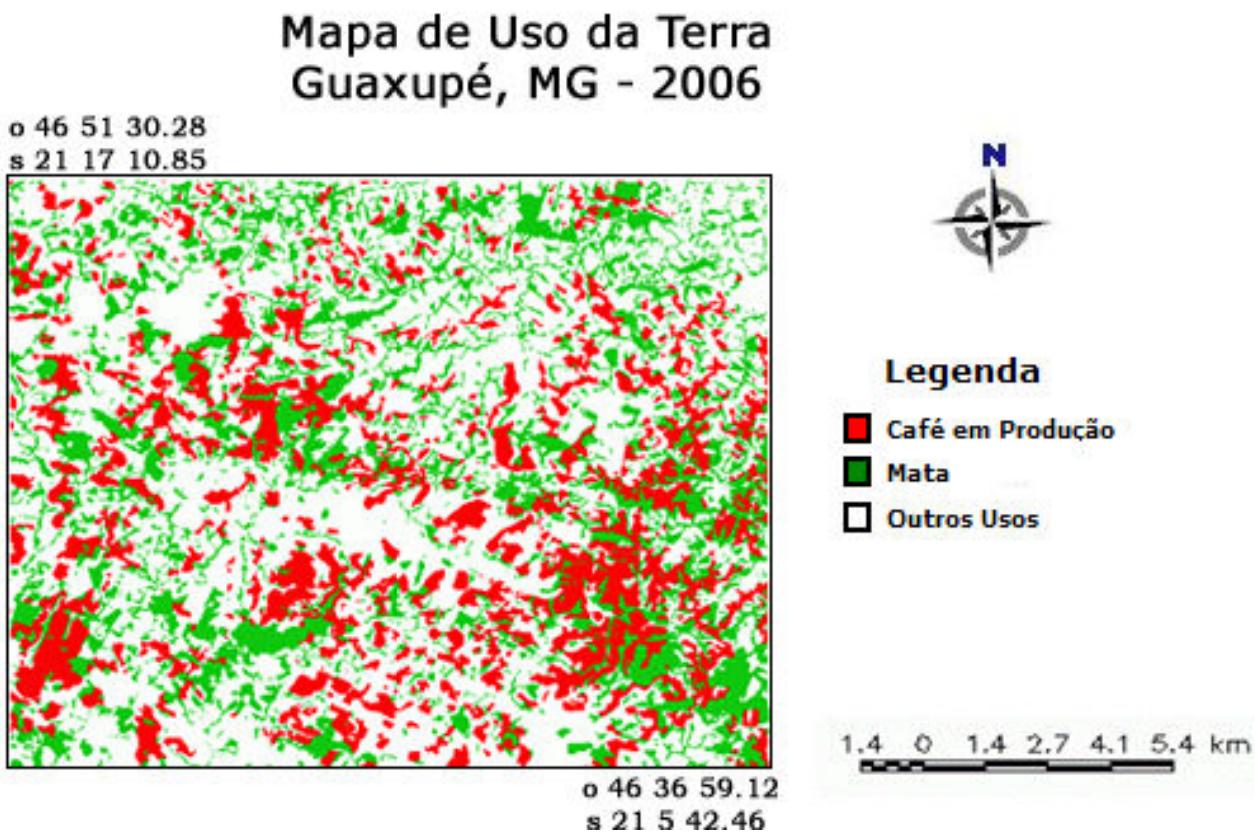


Figura 4-1 – Mapa de uso da terra classificado visualmente da região de Guaxupé, com a máscara de outros usos.

Em relação ao mapa de referência, o índice de acurácia Kappa do mapa classificado pela RNA foi de 71,85% o que, segundo Galparsoro e Fernández [2001], é considerado um índice bom. O índice Kappa obtido na classificação por RNA pode ter sido prejudicado pelos fatores ambientais que interferem no padrão espectral da imagem, tais como variações do estágio fenológico, vigor vegetativo, espaçamento das plantas nas lavouras e tratos culturais utilizados, existência de culturas intercalares e relevo acidentado, causando sombra, conforme [Vieira *et al.*, 2006]. Contudo, se comparados aos resultados obtidos por VIEIRA *et al.* [2009a], a RNA apresentou melhor resultado.

VIEIRA *et al.* [2009b] teve como objetivo comparar o desempenho de técnicas de mapeamento automático de áreas cafeeiras da região de Guaxupé com a interpretação visual, visando a avaliação da viabilidade de aplicação destas técnicas para agilizar o mapeamento do parque cafeeiro na região, alcançaram os seguintes resultados com o índice de acurácia Kappa: 51% com o classificador Battacharya e 58% com o classificador Isoseg.

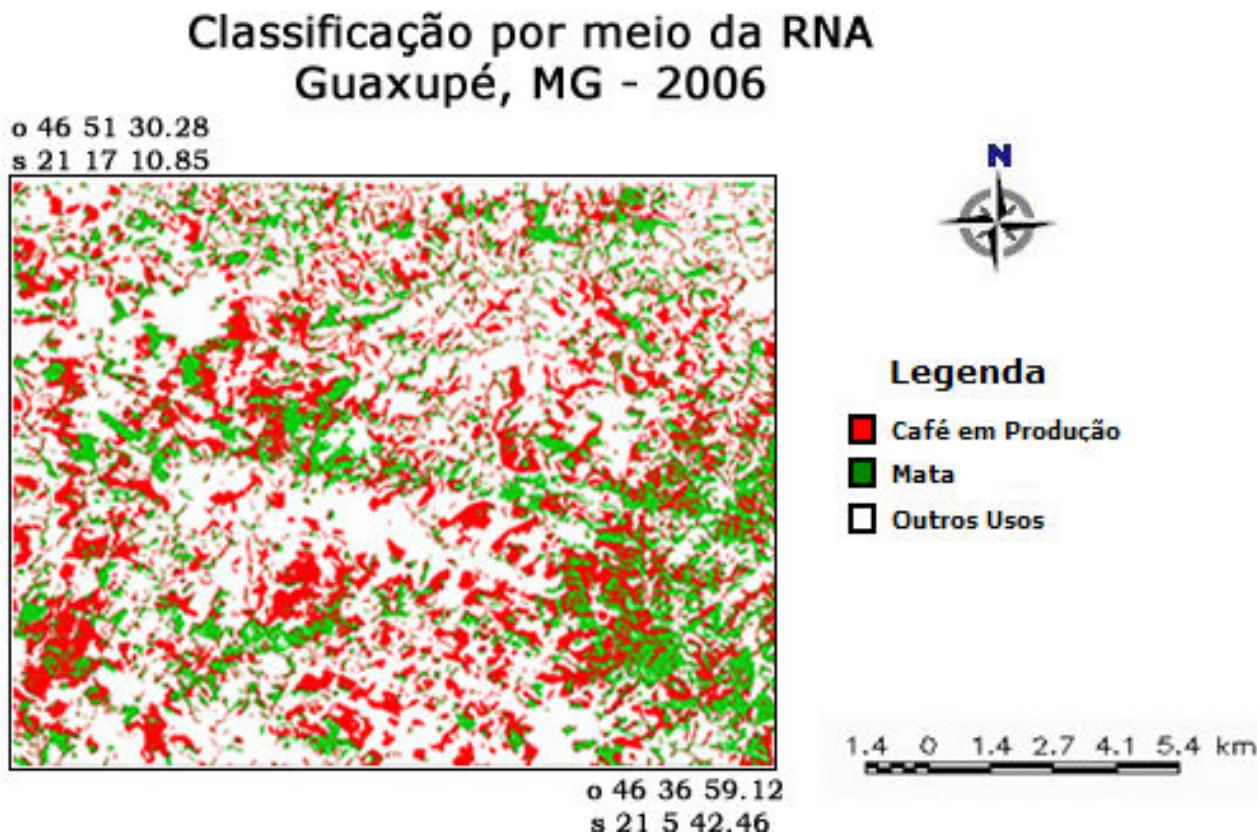


Figura 4-2 – Mapa da região de Guaxupé, classificado pela RNA.

A Tabela 4-2 apresenta a matriz de confusão entre o mapa classificado visualmente e o mapa classificado pela RNA, exibindo a porcentagem dos pixels corretamente classificados na diagonal principal.

Tabela 4-2 - Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %), região de Guaxupé.

Mapa Classificado Visualmente	Mapa Classificado pela RNA			
	Café em produção	Mata	Outros usos	TOTAL
Café em produção	78,72%	16,46%	4,82%	100,00%
Mata	33,48%	55,65%	10,87%	100,00%
Outros usos	1,94%	1,05%	97,01%	100,00%

Numa análise mais detalhada da matriz de confusão, verifica-se que aproximadamente 79% da área de café em produção no mapa de referência, foi corretamente classificada pela RNA na imagem de satélite. Aproximadamente 16% da área classificada como café em produção não correspondia espacialmente a esta classe, pertencendo na verdade a classe mata.

A RNA apresentou grande dificuldade na identificação da classe mata, que obteve como acerto aproximadamente 56% em relação ao mapa de referência. A classificação da mata apresentou confusão com áreas de café, sendo aproximadamente 33% classificado incorretamente como café. Ocorreu também confusão na classificação da mata com áreas de outros usos, classificando aproximadamente 11% de áreas de outros usos como mata. Essa dificuldade em diferenciar áreas de café e mata se deve à complexidade da resposta espectral dos alvos, ao padrão espectral muito próximo entre essas classes, influenciada por parâmetros como variações do estágio fenológico, vigor vegetativo, densidade de plantio, do espaçamento das plantas nas lavouras e dos tratos culturais utilizados, existência de culturas intercalares e sombreamento devido ao relevo [VIEIRA, 2006].

No entanto, apenas as classes café em produção e mata apresentaram dificuldades na identificação das classes, sendo que a classe outros usos apresentou uma exatidão da classificação de 97%.

O mapa de referência classificado visualmente com a máscara e o gerado pela classificação da RNA tiveram as áreas cafeeiras cruzadas no SPRING, utilizando a Linguagem LEGAL. A Figura 4-3 ilustra este cruzamento.

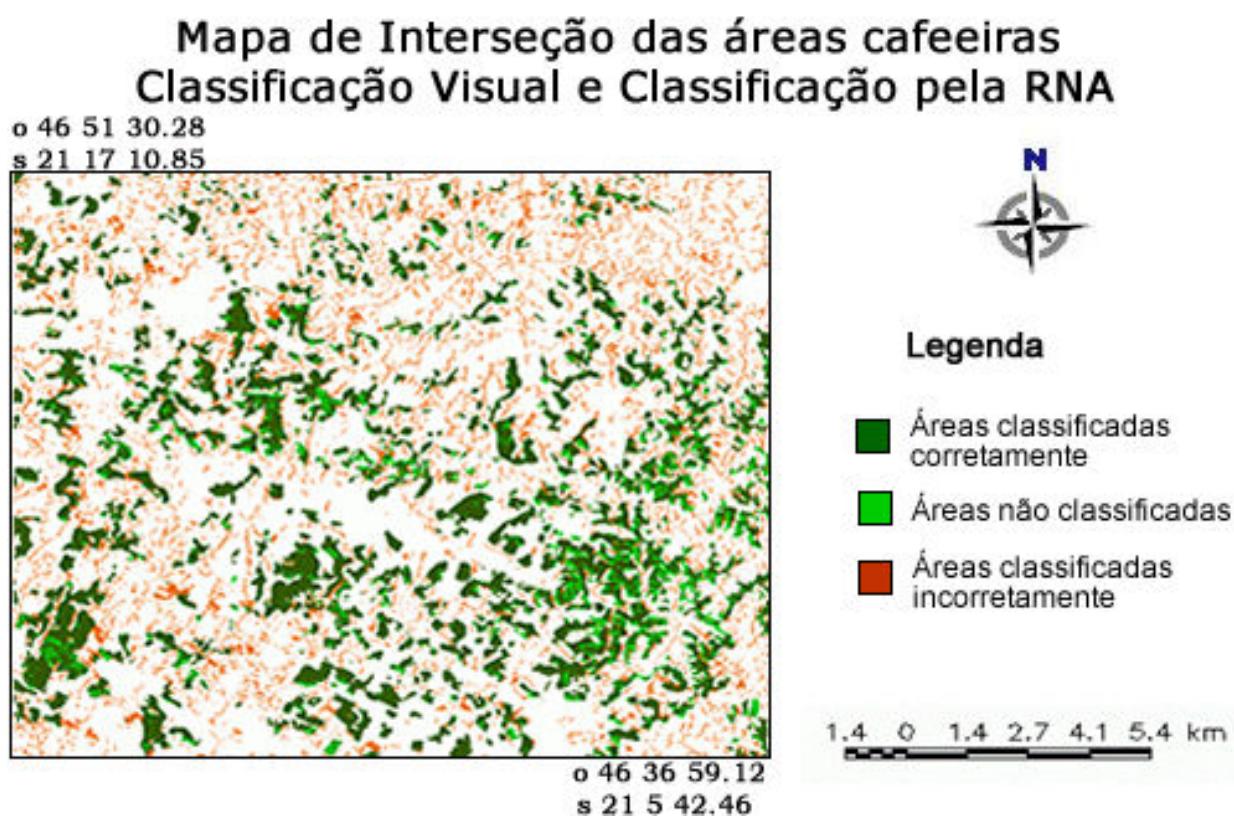


Figura 4-3 – Mapa de interseção das áreas cafeeiras da região de Guaxupé.

O mapa da Figura 4-3 mostra, espacialmente, o desempenho da RNA sobre as áreas cafeeiras, e apresenta as seguintes classes temáticas: áreas corretamente classificadas, áreas classificadas incorretamente, e áreas não classificadas. A área total do mapa é de 520 km², sendo 19,33% ou 100,68 km² do total das áreas são ocupadas pela cultura cafeeira. As áreas de café classificadas corretamente pela RNA, totalizaram 80,9% do total de áreas cafeeiras no mapa de referência, o que equivale a 88,27 km².

A área que a RNA classificou incorretamente como café totalizou 44,09 km². Grande parte dessas áreas classificadas incorretamente corresponde a áreas de vegetação natural, que são áreas de mata que crescem naturalmente às margens das drenagens, denominadas APPs - Áreas de Preservação Permanente. Sendo assim, percebe-se que as APPs prejudicaram a RNA durante a identificação das áreas cafeeiras na imagem.

4.2 Resultados obtidos na região de Machado

As imagens da região de Machado foram divididas em duas partes, pois a área de estudo possui dois diferentes ambientes geomorfológicos, um com relevo mais movimentado e outro com relevo menos movimentado. Após a divisão das imagens, as máscaras de drenagem e área urbana foram criadas, definindo cinco classes de saída para a rede, sendo elas: café, mata, área urbana, água e outros usos. Para cada classe, foram selecionados entre 45 e 50 polígonos na imagem, de tamanhos variados e espaçados ao acaso.

As configurações de teste e treinamento da rede neural utilizadas foram as mesmas tanto para o relevo mais movimentado quanto para o relevo menos movimentado. A Tabela 4-3 exibe as configurações utilizadas, e em destaque as arquiteturas que apresentaram melhores resultados.

A rede que apresentou melhor resultado para o relevo menos movimentado possuía 18 neurônios em uma única camada escondida e 5 neurônios na saída, um conjunto de 70 pixels por categoria para o conjunto de teste e treinamento, taxa de aprendizado de 0.02; fator de momentum de 0.53 para agilizar na convergência da rede; e constante de sigmóide de 1. Para o relevo mais movimentado, a RNA que obteve melhor resultado também possuía apenas uma camada escondida, porém com 14 neurônios, um conjunto de teste e treinamento com 65 pixels, taxa de aprendizado de 0.01 e fator de momentum 0.5. Como critério de parada do treinamento da rede foi estabelecido, para ambas as partes, erro médio quadrático (EMQ) de 0,0001 ou 10.000 iterações. A parada do treinamento da RNA aconteceu pelo número de iterações do algoritmo *backpropagation*, resultando

em um valor de EQM para os dados de treinamento e de teste.

Tabela 4-3. Configurações utilizadas para realização dos testes, região de Machado.

Conf.	Pixel ¹	Nº de cam.	Neurônios		Taxa de aprend.	Mom.	Iterações	EMQ (relevo menos movimentado)		EMQ (relevo mais movimentado)	
			1 ^a Cam	2 ^a Cam				Trein.	Teste	Trein.	Teste
1	60	1	16	-	0.01	0.5	10000	0.005661	0.005841	0.00501	0.005715
2	60	2	20	14	0.01	0.5	10000	0.004914	0.005907	-	-
3	65	1	14	-	0.01	0.5	10000	-	-	0.005491	0.005474
4	65	1	18	-	0.01	0.5	10000	-	-	0.005231	0.005599
5	65	1	18	-	0.01	0.5	10000	0.004861	0.005471	0.005231	0.005599
6	65	2	24	18	0.01	0.53	10000	0.005129	0.005137	-	-
7	70	1	16	-	0.01	0.5	10000	0.005062	0.005216	0.004369	0.005332
8	70	2	16	10	0.01	0.5	10000	0.00497	0.005185	-	-
9	70	1	18	-	0.01	0.5	10000	0.004771	0.005381	0.005116	0.00514
10	70	1	18	-	0.02	0.53	10000	0.00472	0.004984	0.00465	0.005073

¹ Número de pixels selecionados para o conjunto de treinamento e teste.

De acordo com a Tabela 4-3, pode-se relatar que a rede neural teve melhor desempenho com uma camada escondida, variando a quantidade de neurônios na camada e o conjunto de pixels. As camadas intermediárias trabalham com estimativas de erro, as quais em maior quantidade, levaram a problemas de convergência da rede. Observando os resultados obtidos no relevo menos movimentado, percebeu-se que aumentando o número de pixels do conjunto de treinamento e teste, a rede produziu melhores resultados com um número de neurônios da primeira camada variando entre 16 e 18. No relevo mais movimentado, a rede que obteve melhores resultados também possuía um número pequeno de neurônios na camada intermediária. O que justifica este resultado é que quanto maior for o número de neurônios na camada, maior será a complexidade da rede e maior será sua abrangência em termos de soluções possíveis [Braga *et al.*, 2007].

O desempenho da rede neural foi testado gerando-se o índice Kappa entre o mapa classificado pela RNA e o de uso da terra classificado visualmente (mapa de referência). A Figura 4-4 mostra a divisão feita no mapa de referência, separando os dois ambientes geomorfológicos existentes, e a Figura 4-5 a classificação realizada pela RNA nos dois ambientes.

O índice de acurácia Kappa do mapa classificado pela RNA foi de 55,84% para o relevo mais movimentado e 60,29% para o relevo menos movimentado, que segundo Galparsoro & Fernández (2001) são índices moderados. Os índices de acurácia Kappa obtidos na classificação por

RNA podem ter sido prejudicados pelos fatores ambientais que interferem no padrão espectral da imagem, tais como, variações do estágio fenológico, vigor vegetativo, do espaçamento das plantas nas lavouras e dos tratos culturais utilizados, existência de culturas intercalares, maior sombreamento devido ao relevo acidentado e baixa resolução espacial das imagens Landsat utilizadas. Contudo, se comparados aos resultados obtidos por Santos *et al.* (2007) e Marques (2003), que utilizaram os algoritmos de classificação automática Battacharya e Maxver na mesma região cafeeira para mapeamento de uso da terra, a RNA apresentou melhor resultado.

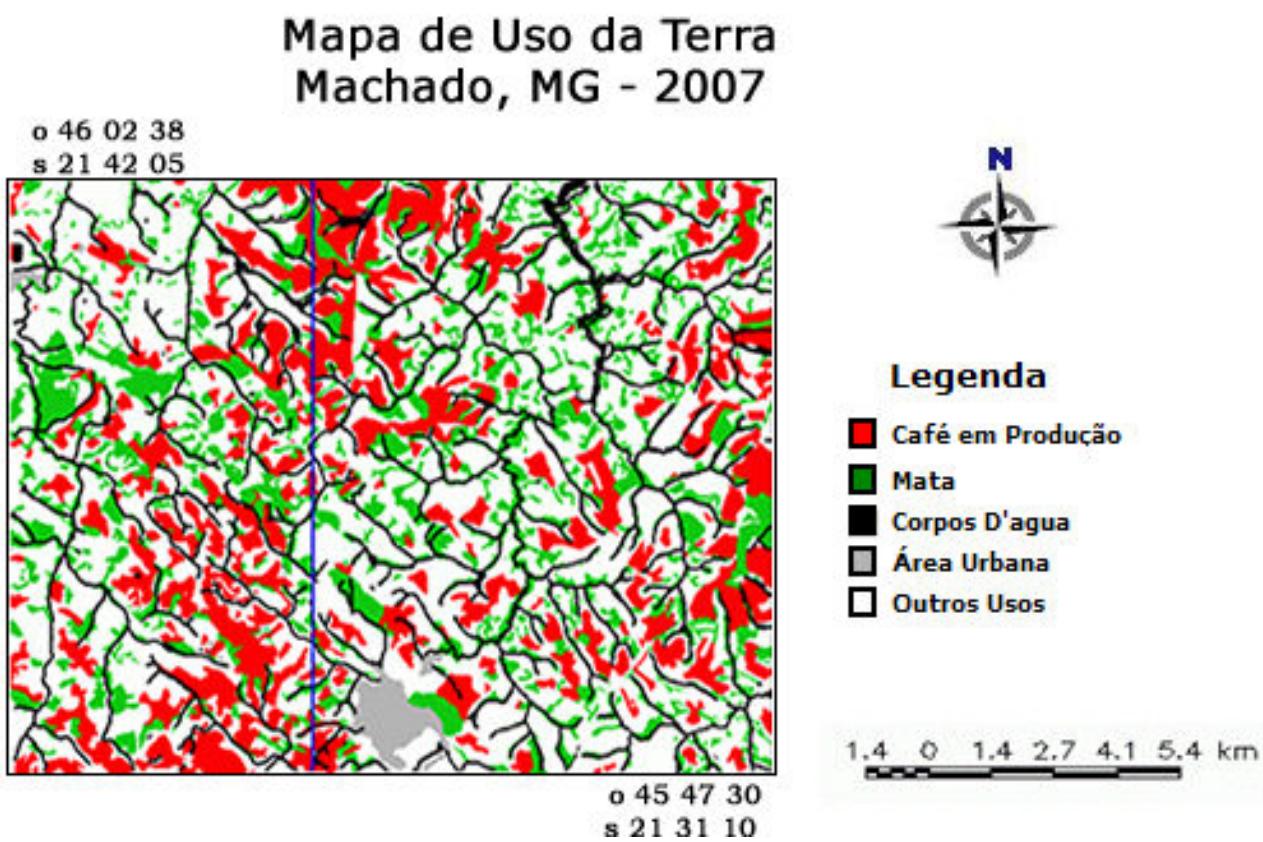


Figura 4-4 – Mapa de uso da terra classificado visualmente da região de Machado, com a máscara de drenagem.

Marques (2003) aplicou os classificadores automáticos Battacharya (classificador por região) e Maxver (classificador pixel a pixel) em imagens Landsat 7 ETM+ do ano 2000 e, apesar dos baixos índices de acurácia Kappa, Maxver com 39% e Battacharya com 42%, o autor concluiu que os classificadores tiveram um desempenho moderado, pois a área possui um relevo que dificulta a classificação. Já Santos *et al.* (2007) utilizou os mesmos classificadores automáticos em imagens

Landsat 5 TM do ano de 2005, na mesma área e obteve baixos índices de acurácia Kappa, sendo 20,2% para o classificador Battacharya e 25,09% para o Maxver. Ele conclui que o baixo desempenho das classificações pode ser explicado por essa região possuir um relevo muito movimentado, proporcionando regiões sombreadas e lavouras cafeeiras contíguas a fragmentos de vegetação nativa, os quais apresentam resposta espectral semelhante à da lavoura de café.

Classificação por meio da RNA Machado, MG - 2007

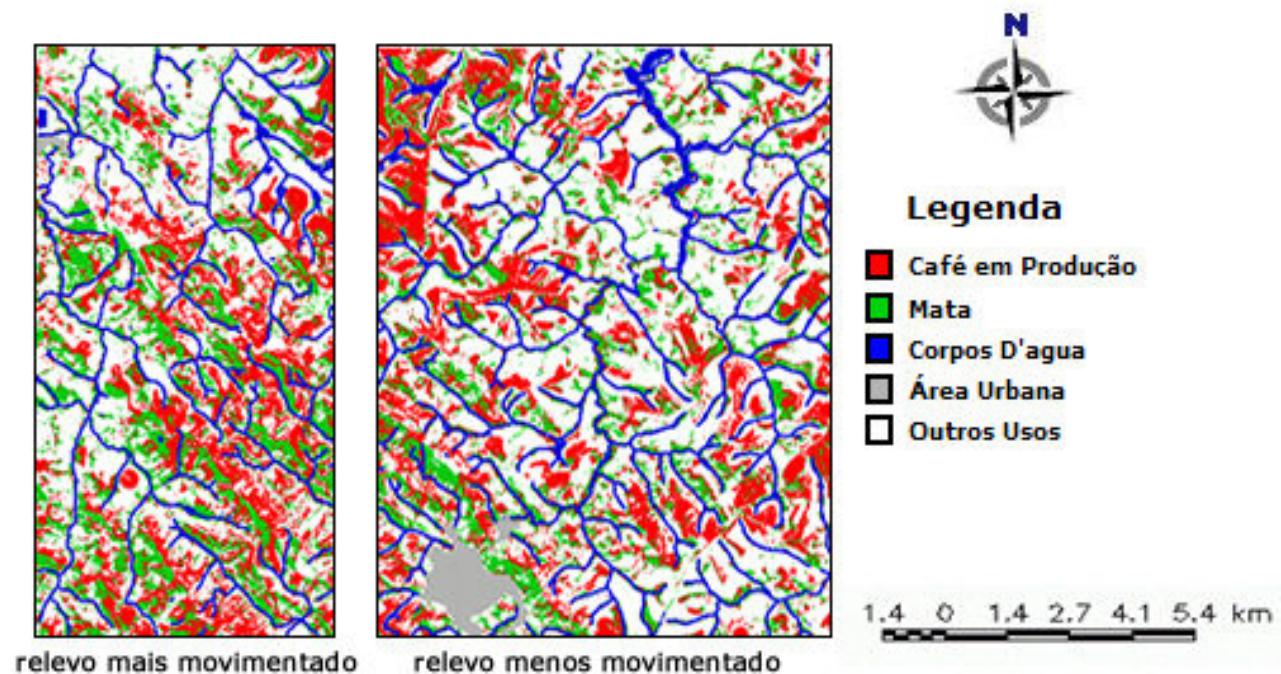


Figura 4-5 – Mapa da região de Machado classificado pela RNA.

Na Tabela 4-4 é apresentada a matriz de confusão entre os mapas de referência e o classificado pela RNA. A matriz contém as taxas de erro e acerto da classificação para cada classe. Os valores marcados de cinza são das áreas com relevo menos movimentado.

Tabela 4-4. Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %), região de Machado.

Mapa Classificado Visualmente	Mapa Classificado pela RNA					
	Café em Produção	Mata	Água	Área Urbana	Outros Usos	TOTAL
Café em Produção	63.60%	14.09%	0.32%	0.02%	21.98%	100%
	59.06%	20.60%	0.00%	0.01%	20.33%	
Mata	28.22%	42.35%	2.31%	0.03%	27.10%	100%
	27.89%	50.34%	0.01%	0.00%	21.75%	
Água	1.30%	2.30%	91.52%	0.61%	4.27%	100%
	0.00%	0.00%	99.99%	0.00%	0.01%	
Área Urbana	0.35%	0.50%	0.11%	97.76%	1.29%	100%
	0.00%	0.00%	0.00%	99.98%	0.02%	
Outros Usos	8.53%	7.72%	1.04%	0.11%	82.60%	100%
	11.98%	12.15%	0.01%	0.01%	75.84%	

Obs.: Cada célula da tabela contém dois valores, referentes as duas áreas classificadas pela rede neural: Relevo menos Movimentado em cinza, e Relevo mais Movimentado.

Analizando a matriz de confusão, pôde-se observar que no relevo menos movimentado a rede classificou melhor as áreas cafeeiras, com uma porcentagem de acerto de 63.60%, enquanto que no relevo mais movimentado a rede conseguiu um acerto um pouco menor, de 59.06%. Como era de se esperar, na área de relevo menos movimentado o índice Kappa apresentou melhor resultado devido a menor interferência da sombra na reflectância do dossel do cafeiro. Outro fator importante foi a criação de máscaras na rede de drenagem, eliminando o erro de classificação entre as classes temáticas mata e café ao longo dos drenos, e, assim, melhorando o resultado da classificação da RNA.

A classe outros usos que engloba café em formação, culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação, também pode ser considerada como uma boa classificação, variando entre 75 e 82%, apresentando pequena confusão com áreas de café e mata. Por englobar diversos tipos de vegetação, a RNA pode ter confundido essa classe com áreas cafeeiras, fato este que justifica as taxas de 21,98 e 20,33% de áreas classificadas incorretamente como café pela rede neural.

Outra dificuldade de classificação apresentada pela RNA pode ser observada na classe mata, que obteve como acerto 42,35 e 50,34% para o relevo menos movimentado e para o relevo mais movimentado, respectivamente. A classificação da mata teve grande confusão com áreas de café, devido ao padrão espectral muito próximo [VIEIRA, 2006], e apresentou também grande confusão com áreas de outros usos, devido a fatores já discutidos anteriormente.

A classe água apresentou taxa de acerto superior a 90%, porque durante a criação da máscara foi atribuído o valor 10 aos pixels que se encontravam nas áreas cobertas pelo *buffer* e nas

áreas de água. A classe área urbana teve uma boa classificação, com índices superiores a 95%, pois também foi criada uma máscara com pixels no valor de 255.

O mapa de referência e o gerado pela classificação da RNA foram cruzados no SPRING, utilizando a linguagem LEGAL. Deste cruzamento obteve-se o mapa temático apresentado na Figura 4-6, que mostra, espacialmente, a desempenho da RNA, e apresenta as seguintes classes temáticas: áreas corretamente classificadas, áreas classificadas incorretamente, e áreas não classificadas.

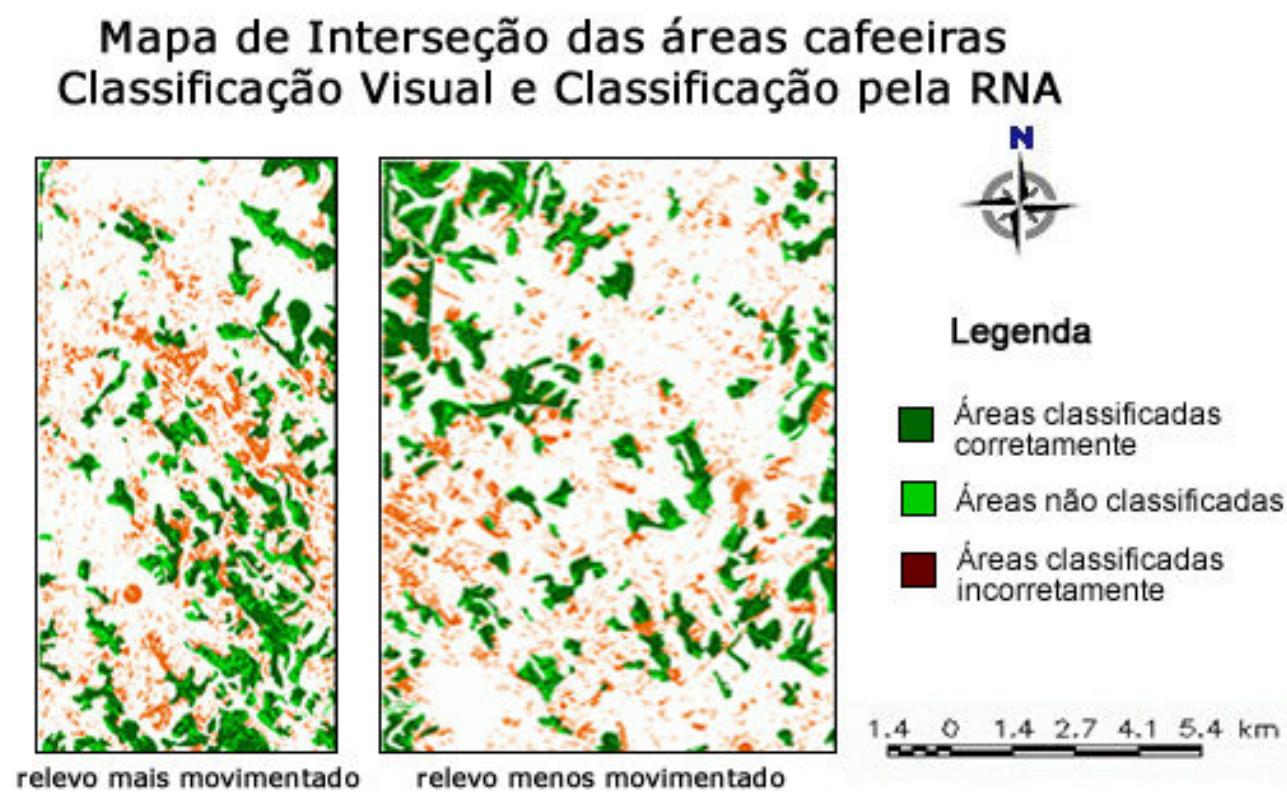


Figura 4-6 – Mapa de interseção das áreas cafeeiras da região de Machado.

A área total do mapa é de 520 km², sendo 110,13 km² de áreas cafeeiras. Os mapas apresentam o desempenho da RNA sobre a classe café, onde o café classificado corretamente equivale a 67,95 km², o classificado incorretamente a 50,58 km² e as áreas de café não classificadas a 42,18 km². Analisando as áreas separadamente, o relevo menos movimentado possui 69,34 km² de áreas cafeeiras, sendo classificadas corretamente pela RNA 40,80 km², e 28,54 km² em áreas classificadas incorretamente. Já o relevo mais movimentado possui 49,20 km² de áreas cafeeiras, sendo 27,15 km² classificadas corretamente e 22,04 km² classificadas incorretamente.

4.3 Resultados obtidos na região de Três Pontas

Na imagem da região de Três Pontas foi criada uma máscara nas áreas de drenagem e área urbana. Após a criação das máscaras, foram definidas cinco classes de saída para a rede, sendo elas: café, mata, área urbana, água e outros usos. Para cada classe, foram selecionados entre 45 e 50 polígonos de tamanhos variados e espaçados ao acaso.

Foram realizados diversos testes para definição da arquitetura que melhor classificasse a imagem, sendo que a arquitetura que apresentou melhor resultado foi uma rede neural com 18 neurônios em uma única camada escondida, conjunto de 55 pixels por categoria para o conjunto de teste e treinamento, taxa de aprendizado de 0,01; fator de momentum de 0,5 para agilizar na convergência da rede; e constante de sigmóide de 1. Como critério de parada do treinamento da RNA foi estabelecido o limite de 10.000 iterações ou erro médio quadrático (EQM) de 0,0001.

A parada do treinamento da RNA aconteceu pelo número de iterações do algoritmo *backpropagation*, resultando em um valor de EQM de 0,005347 para os dados de treinamento, e 0,006135 para os dados de teste. A Tabela 4-5 mostra as configurações utilizadas para teste na tentativa de obter a rede que melhor classificasse a imagem. Em destaque está a arquitetura que apresentou melhor resultado.

Tabela 4-5. Configurações utilizadas para realização dos testes, região de Três Pontas.

Configuração	Pixel1	Camadas escondidas	Neurônios		Taxa de aprend.	Momentum	Iterações	EMQ	
			1 ^a Cam.	2 ^a Cam.				Trein.	Teste
1	70	1	16	-	0.01	0.5	10000	0.005142	0.005578
2	70	2	22	18	0.01	0.5	10000	0.004836	0.004821
3	60	1	16	-	0.01	0.5	10000	0.005066	0.005257
4	60	2	20	14	0.01	0.5	10000	0.005305	0.0057
5	65	2	22	16	0.01	0.53	10000	0.005087	0.005214
6	65	1	16	-	0.01	0.53	10000	0.00562	0.005551
7	55	1	14	-	0.01	0.5	10000	0.005831	0.005676
8	55	1	18	-	0.01	0.5	10000	0.005347	0.006135
9	55	2	18	12	0.01	0.5	10000	0.005432	0.00539

¹ Número de pixels selecionados para o conjunto de treinamento e teste.

De acordo com a Tabela 4-5, pode-se relatar que a rede neural teve melhor desempenho com a configuração 8, com uma única camada escondida, variando a quantidade de neurônios. Nos testes realizados, observou-se que, aumentando o número de camadas, a rede não produziu bons

resultados, mesmo com um número de neurônios da primeira camada superiores aos da segunda camada, como ocorre na configuração 2, que produziu bons resultados, porém o resultado final da classificação não tinha bom desempenho, apresentando grande confusão entre as classes café e mata. A rede também apresentou uma melhor convergência quando reduzida a quantidade de pixels para o conjunto de treinamento e teste.

A Figura 4-7 mostra o mapa de uso da terra obtido por classificação visual e conferido em campo. Esse mapa é utilizado como referência para avaliar a acurácia da classificação da RNA. A cena classificada resultante da aplicação da arquitetura anterior da rede neural treinada é apresentada na Figura 4-8.

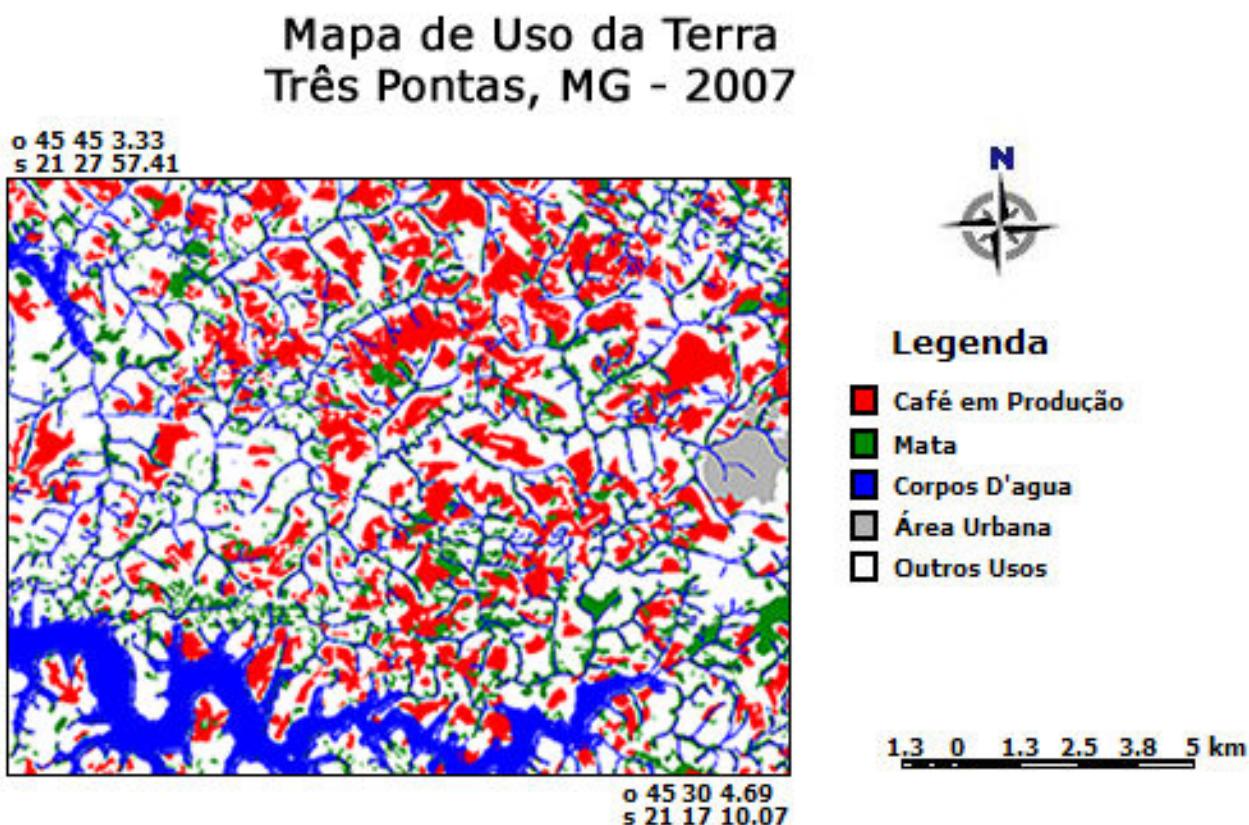


Figura 4-7 – Mapa de uso da terra classificado visualmente da região de Três Pontas, com a máscara de drenagem.

Classificação por meio da RNA Três Pontas, MG - 2007

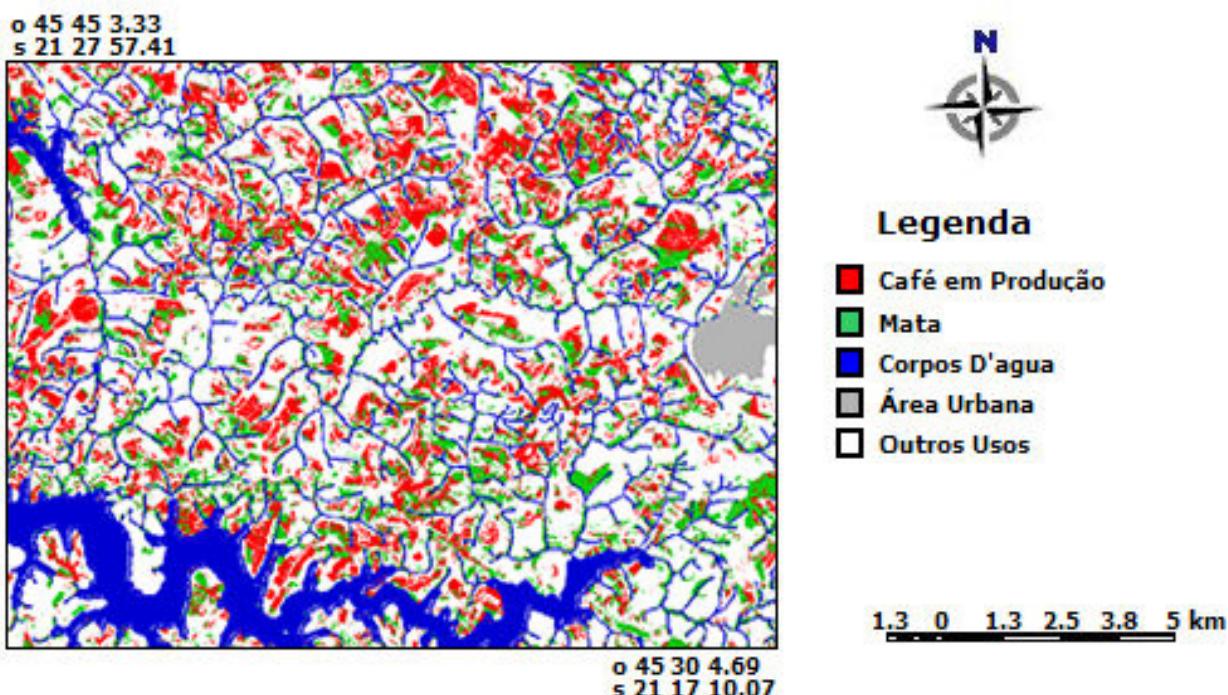


Figura 4-8 – Mapa da região de Três Pontas, classificado pela RNA.

Em relação ao mapa de referência, o índice de acurácia Kappa do mapa classificado pela RNA ficou em 67,61%. Segundo Galparsoro e Fernández (2001) este é considerado um índice bom. O índice Kappa obtido na classificação por RNA pode ter sido prejudicado pelos fatores ambientais que interferem no padrão espectral da imagem, tais como variações do estágio fenológico, vigor vegetativo, espaçamento das plantas nas lavouras e tratos culturais utilizados, existência de culturas intercalares, relevo acidentado causando sombra e baixa resolução espacial das imagens Landsat utilizada. Contudo, se comparados aos resultados obtidos por VIEIRA *et al.* [2009a], a RNA apresentou melhor resultado.

VIEIRA *et al.* [2009a] concluíram que o reconhecimento de padrões da cultura cafeeira por métodos automatizados é dificultado também pela similaridade do padrão espectral café/mata. Apesar do baixo índice de acurácia Kappa obtido na classificação, 46,66%, a RNA conseguiu um bom índice de treinamento.

A matriz de confusão entre o mapa de referência e o classificado pela RNA é apresentada na Tabela 4-6. A matriz contém as taxas de erro e acerto da classificação para cada classe.

Tabela 4-6. Matriz de confusão entre os mapas de referência e o classificado pela RNA (em %), região de Três Pontas.

Mapa de Referência	Mapa Classificado pela RNA					
	Café em Produção	Mata	Corpos D'água	Área Urbana	Outros Usos	Total
Café em Produção	51.99%	21.69%	0.01%	0.00%	26.31%	100.00%
Mata	12.62%	56.97%	0.13%	0.00%	30.28%	100.00%
Corpos D'água	0.00%	0.00%	99.62%	0.38%	0.00%	100.00%
Área Urbana	0.00%	0.00%	0.00%	100.00%	0.00%	100.00%
Outros Usos	8.96%	3.73%	0.07%	0.01%	87.23%	100.00%

Analisando a matriz de confusão, pode-se observar que a RNA não teve um bom desempenho na classificação de áreas cafeeiras, apresentando confusão na classificação do café com áreas de mata e outros usos. O total das áreas de café classificadas corretamente corresponde a 51,99%. A RNA confundiu áreas cafeeiras com áreas de mata, classificando incorretamente 21,69% de áreas de mata como café. Outra confusão feita pela RNA na identificação das áreas cafeeiras foi com as áreas de outros usos, com uma porcentagem de erro de 26,31%. Esta confusão pode ser justificada pelo fato da classe outros usos englobar café em formação, culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação.

A classe “outros usos” obteve uma boa classificação, com uma porcentagem de acerto de 87,23%. Aproximadamente 9% de áreas cafeeiras e 3,73% de áreas de mata, foram classificadas incorretamente como outros usos.

Outra dificuldade de classificação apresentada pela RNA pode ser observada na classe mata, que obteve como acerto 56,97%. A classificação da mata teve grande confusão com áreas de café, devido ao padrão espectral muito próximo [VIEIRA, 2006]. Um fator importante foi a criação de máscaras na rede de drenagem, eliminando o erro de classificação entre as classes temáticas mata e café ao longo dos drenos. A rede apresentou também grande confusão na classificação da mata com áreas de outros usos, devido a fatores já discutidos anteriormente.

As classes água e área urbana apresentaram taxas de acerto superiores a 98%, porque durante a criação da máscara foi atribuído o valor 10 aos pixels que se encontravam nas áreas cobertas pelo *buffer* e nas áreas de água, e atribuído o valor de 255 nas áreas cobertas pela classe área urbana.

O mapa de referência classificado visualmente com a máscara e o gerado pela classificação da RNA foram cruzados no SPRING, utilizando a Linguagem LEGAL do SPRING. Desse cruzamento obteve-se o mapa apresentado na Figura 4-9. A área total do mapa é de 510 km²,

sendo 105,85 km² de áreas cafeeiras. O mapa apresenta o desempenho da RNA sobre a classe café, onde o café classificado corretamente totaliza 51,98%, o que equivale a 55,02 km², e o classificado incorretamente a 30,30 km².

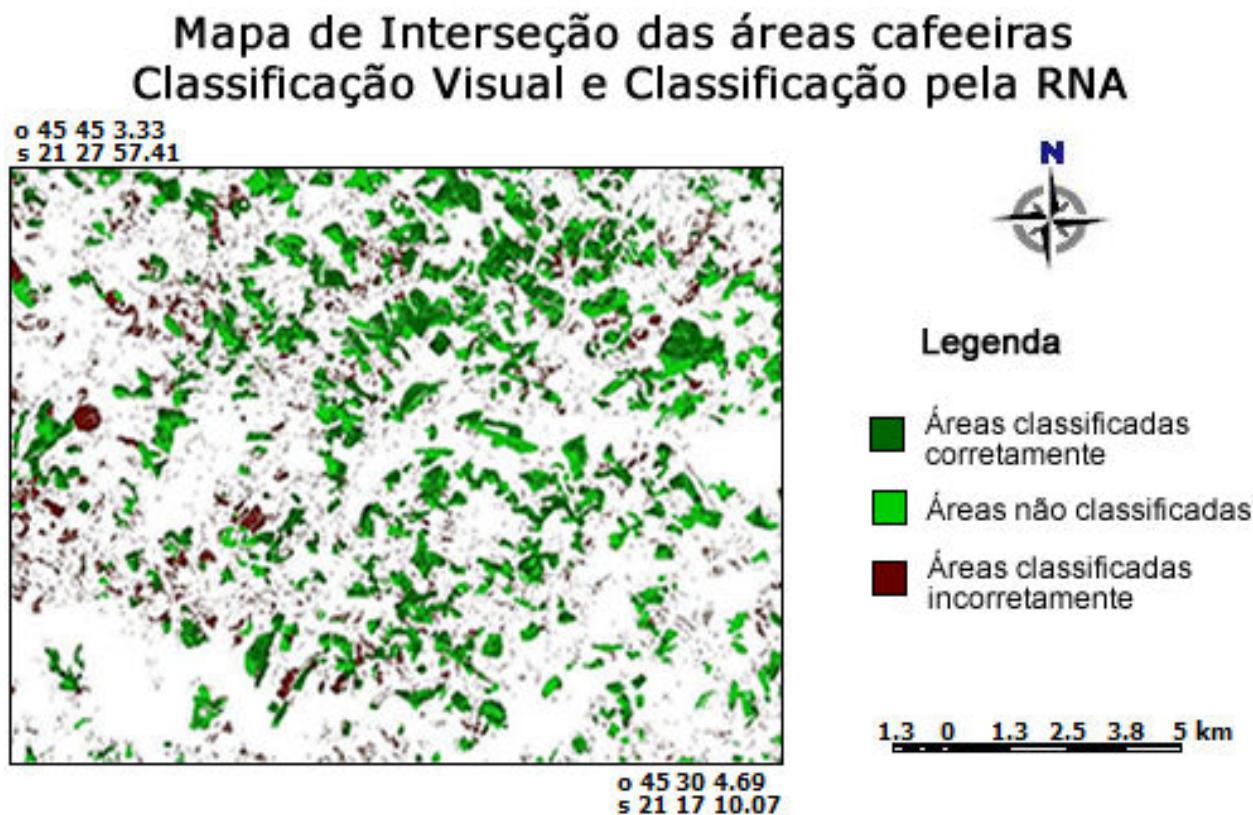


Figura 4-9 – Mapa de interseção das áreas cafeeiras da região de Três Pontas.

4.4 Considerações sobre os resultados obtidos

Como visto neste Capítulo, o treinamento da rede foi realizado adotando um modelo com estrutura de múltiplas camadas e abordagem supervisionada. A RNA foi treinada com o algoritmo *backpropagation*, disponível no software Idrisi. Foram realizados diversos testes para definição da melhor arquitetura para a classificação, e apresentados mapas e matrizes de confusão referentes aos melhores resultados alcançados. Estes resultados foram apresentados de acordo com cada área de

estudo, e comparados com resultados obtidos na literatura utilizando classificadores automáticos, como pode ser observado na Tabela 4-7.

Tabela 4-7. Resultados alcançados (índice Kappa) com a classificação pela RNA e demais classificadores automáticos.

Classificadores	Guaxupé	Áreas		
		Machado	Três Pontas	
RNA	71,85%	Relevo mais movimentado	Relevo menos movimentado	67,61%
		55,84%	60,29%	
Battacharya	51% *	42% **	--	--
Maxver	--	39% **	--	--
Isoseg	58% *	--	--	--
RNA (outros autores)	--	--	--	46,66% ***

* [VIEIRA et al., 2009b]

** [MARQUES, 2003]

*** [VIEIRA et al., 2009a]

Analizando a tabela, percebe-se que os resultados obtidos com a rede neural foram superiores aos obtidos com outros classificadores automáticos. Na região de Guaxupé, enquanto os classificadores Battacharya e Isoseg [VIEIRA *et al.*, 2009b] obtiveram os índices Kappa 51% e 58%, respectivamente, a classificação realizada pela RNA, com pré-processamento, alcançou 71,85%. A criação da máscara na imagem durante a realização do pré-processamento contribuiu para este resultado.

Na região de Machado, os índices obtidos com a RNA foram 55,84% para o relevo mais movimentado e 60,29% para o menos movimentado, enquanto que os classificadores Battacharya e Maxver [MARQUES, 2003] obtiveram 42% e 39%. MARQUES [2003] poderia ter alcançado melhores resultados se tivesse realizado um pre-processamento que separasse os dois ambientes geomorfológicos existentes na imagem.

Na região de Três Pontas, tanto o resultado obtido neste trabalho quanto o obtido por VIEIRA *et al.* [2009a], foram obtidos com a classificação realizada com redes neurais. O que se percebe é que a criação da máscara de drenagem ajudou a rede a melhor identificar as classes propostas, uma vez que a máscara eliminava as áreas de vegetação natural, diminuindo assim a confusão espectral entre as classes café e mata.

Com base nestes resultados, verifica-se que o pré-processamento foi um passo fundamental para os bons resultados alcançados com a classificação pela rede neural. Com a criação das máscaras foi possível diminuir a confusão entre as classes durante a classificação, como a

máscara de drenagem, que eliminou as APPs, onde existiam áreas de vegetação natural que eram confundidas com áreas de café. A máscara na área urbana também contribuiu para melhoria da classificação. Devido a baixa resolução da imagem, as áreas urbanizadas apresentavam uma tonalidade do nível de cinza bem próximo aos níveis de outras classes. Outro pré-processamento relevante para este trabalho, foi a divisão da imagem da região de Machado, que evitou que o sombreamento causado pelo relevo mais movimentado prejudicasse o resultado da classificação no relevo menos movimentado.

Por fim, pode-se considerar que as Redes Neurais Artificiais podem ser consideradas como uma ferramenta promissora para análise de áreas cafeeiras em imagens de satélite.

Capítulo 5

Conclusões

5.1 Considerações Finais

A maioria dos classificadores automáticos de imagens espectrais avalia apenas a resposta espectral dos alvos. Quando o alvo estudado, como a cultura cafeeira, apresenta tamanha complexidade, onde fatores ambientais, fenológicas e de manejo interferem na resposta espectral, tais classificadores não apresentam resultados satisfatórios. Assim, Redes Neurais Artificiais podem ser consideradas como uma alternativa aos classificadores atualmente utilizados para a classificação de imagens espectrais, por permitirem a utilização de outros parâmetros, além do espectral.

Trabalhos futuros visam incorporar à estrutura da RNA, atributos como forma e textura dos alvos, visto que estes são os atributos utilizados pela interpretação visual, em momentos onde a resposta espectral apenas não é suficiente. Outra possível alternativa para a melhoria da classificação pela RNA seria a inserção de outros parâmetros de entrada para o treinamento da RNA, como dados de relevo (altitude, orientação de vertente e declive). No Sul de Minas Gerais, onde o café é cultivado em áreas de altitudes mais elevadas, acima de 700m, a altitude pode ser um parâmetro discriminador a ser incorporado à rede, eliminando a possibilidade da RNA se confundir.

Região cafeeira de Guaxupé

Imagens de sensores remotos foram classificadas por Redes Neurais Artificiais. Para validação dos resultados alcançados pela RNA, o mapa resultante da classificação foi sobreposto a um mapa de referência, obtido por classificação visual. O índice de acurácia Kappa obtido foi de

71,85%, que é um índice considerado bom, pois possibilitaram discriminar todas as classes de saída pré-estabelecidas. O erro na classificação realizada pela rede neural é influenciado pela ambiguidade de áreas de café com áreas de mata, tendo em vista os padrões espectrais muito próximos destas duas classes de uso e cobertura do solo.

Com os resultados alcançados na região cafeeira de Guaxupé, percebeu-se que grande parte das áreas classificadas incorretamente como café pertencia, na verdade, a áreas de vegetação natural, classificadas como mata no mapa verdade. Diante destes resultados, sugeriu-se criar uma máscara ao longo da rede de drenagem, onde existem áreas de vegetação natural.

Região cafeeira de Machado

Os resultados alcançados na região cafeeira de Machado superaram aqueles encontrados na literatura até então, com índices de acurácia Kappa de 55,84% para o relevo mais movimentado e 60,29% para o relevo menos movimentado. Apesar de ainda não ter sido incorporado à rede, nenhum outro parâmetro, a não ser o espectral, a metodologia proposta separou os ambientes geomorfológicos, a fim de permitir uma melhor coleta de amostras; e incluiu máscaras na rede de drenagem e na área urbana, diminuindo assim a quantidade e a variabilidade dos alvos observados nas imagens.

Região cafeeira de Três Pontas

Neste trabalho foram incluídas máscaras na rede de drenagem e na área urbana, diminuindo assim a quantidade e a variabilidade dos alvos observados nas imagens. O índice de acurácia Kappa obtido na região cafeeira de Três Pontas foi de 67,61%, que é um índice considerado bom. Apesar de ainda não ter sido incorporado à RNA, nenhum outro parâmetro, a não ser o espectral, a metodologia proposta possibilitou discriminar todas as classes de saída pré-estabelecidas. O erro na classificação realizada pela rede neural é influenciado pela ambiguidade de áreas de café com áreas de mata, tendo em vista os padrões espectrais muito próximos destas duas classes de uso e cobertura do solo.

Observando o mapa gerado pela RNA, verifica-se a existência de pequenas áreas classificadas incorretamente como café (aparecem como resíduos no mapa), e que na verdade

referem-se a outras classes de uso. Quando sobrepostas as linhas de drenagem do IGAM (Instituto Mineiro de Gestão das Águas) sobre a imagem Landsat, percebe-se que a região estudada possui muitos drenos que não foram digitalizados. Uma sugestão para trabalhos futuros seria fazer a digitalização dos drenos existentes na imagem, e sobre elas refazer a relação de proximidade (*buffer*) e realizar novamente todo o processo de treinamento e classificação pela rede neural.

5.2 Recomendações gerais

Abaixo estão listadas algumas recomendações que devem ser observadas para que a pesquisa desenvolvida neste trabalho de dissertação possa ser repetida sobre outras áreas de mapeamento:

- *Mapa de referência confiável*: o mapa de referência utilizado deve ser um mapa de fonte confiável, pois ele será utilizado tanto na fase de treinamento, que é quando a rede aprende as características de cada classe, como na fase de validação da classificação;
- *Escolha dos dados para treinamento*: a escolha dos dados é uma das fases mais importantes do treinamento, devem ser selecionadas a maior quantidade possível de variações da mesma classe. Deve ser levado em consideração o relevo, época do ano, entre outros fatores que podem alterar a resposta espectral das classes;
- *Escolha apropriada das classes*: mais importante que a escolha dos dados, é a escolha apropriada das classes a serem identificadas pela rede neural durante a classificação;
- *Variação dos atributos da RNA*: a definição de alguns parâmetros da rede, como o algoritmo de treinamento, a quantidade de camadas intermediárias, o número de neurônios em cada camada e o critério de parada para o treinamento são de extrema importância para seu desempenho, principalmente no que se refere à sua capacidade de generalização. Não existe na literatura uma regra que determine, de forma precisa, quais valores devem ser os indicados nesses parâmetros para que uma rede neural solucionar um determinado problema. O ajuste inadequado desses parâmetros da rede pode levar a efeitos indesejáveis na resposta final do modelo. A dica é testar a maior variabilidade possível desses parâmetros,

identificando as mais apropriadas para solução do problema em questão;

- *Mais informações da área de estudo:* deve-se ter conhecimento tanto do ambiente que será estudado como das características das classes a serem identificadas na classificação. O conhecimento prévio da área de estudo proporciona informações relevantes a serem utilizadas no pré-processamento dos dados, por exemplo, se a área de estudo possuir uma determinada característica como declividade ou altitude acentuadas ou uma rede de drenagem muito densa com pequenas áreas de mata ciliar que podem causar alguma confusão na classificação.

5.3 Propostas de continuidade

Sugerem-se como propostas de continuidade do trabalho os seguintes tópicos:

- Digitalizar manualmente a rede de drenagem das áreas estudadas e aplicar novamente a metodologia nas imagens;
- Testar a metodologia utilizada neste trabalho de dissertação em imagens com resoluções espaciais melhores;
- Testar a metodologia em imagens com resolução temporal melhor, devido ao ciclo do café;
- Testar a metodologia em outras áreas cafeeiras do Sul de Minas Gerais;
- Utilizar outros atributos para auxiliar a classificação, tais como textura, forma, relevo, entre outros;
- Desenvolver uma rede neural convolutiva em um ambiente de programação, tipo MATrix LABoratory (Matlab), para classificar as imagens de satélite. Com a implementação da RNA em um nível mais baixo, é possível ter um controle melhor do método, e assim aumentar a taxa de acerto das classificações;

Referências bibliográficas

- [Andrade *et al.*, 2003] ANDRADE, A. F.; BOTELHO, M. F. & CENTENO, J. A. S. 2003. Classificação de imagens de alta resolução integrando variáveis espetrais e forma utilizando redes neurais artificiais. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 11, Belo Horizonte. São José dos Campos: INPE. p. 265-272.
- [Andrade *et al.*, 2010] ANDRADE, L. N.; VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L. & SOUZA, V. C. O. 2010. Aplicação de redes neurais artificiais (rna) na análise e classificação de áreas cafeeiras da região de Machado-MG. In *IX Congreso Latinoamericano y del Caribe de Ingeniería Agrícola - XXXIX Congresso Brasileiro de Engenharia Agrícola (CLIA/CONBEA)*, Vitória/ES.
- [Braga *et al.*, 2007] BRAGA, A. P.; CARVALHO, A. C. P. L. F. & LUDELMIR, T. B. 2007. *Redes neurais artificiais: teoria e aplicações*. 2 Ed. Rio de Janeiro: LTC. 226p.
- [Batista *et al.*, 1990] BATISTA, G. T.; TARDIN, A. T.; CHEN, S. C. & DALLEMAND, J. F. 1990. Avaliação de produtos HRV/SPOT e TM/Landsat na discriminação de culturas. *Pesquisa Agropecuária Brasileira*, volume 25, n.3, p. 379-386.
- [Bernardes, 2006] BERNARDES, T. 2006. *Caracterização do ambiente agrícola do complexo Serra Negra por meio de Sensoriamento Remoto e Sistemas de Informação Geográfica*. 2006. 119p. Dissertação (mestrado em solos e nutrição de plantas), Universidade Federal de Lavras, Lavras.
- [Bernardes *et al.*, 2007] BERNARDES, T.; ALVES, H. M. R.; VIEIRA, T. G. C. & ANDRADE, H. 2007. Avaliação da acurácia do mapeamento do uso da terra no complexo Serra Negra, Patrocínio, MG. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 13, Florianópolis. São José dos Campos: INPE. p. 5587-5594.
- [Bilobrovec *et al.*, 2004] BILOBROVEC, M.; MARÇAL, R. F. M. & PILATTI, L. A. 2004. Aplicações de redes neurais em simulações. In *Simpósio Engenharia de Produção*. volume 11, Bauru/SP. CD-ROM.
- [Boggione, 2004] BOGGIONE, G. A. 2004. *Restauração de imagens do satélite Landsat-7*. 2004. 160p.

Dissertação (mestrado em sensoriamento remoto), Instituto Nacional de Pesquisas Espaciais, São José dos Campos.

[Borges *et al.*, 1993] BORGES, M. H.; PFEIFER, R. M. & DEMATTÊ, J. A. M. 1993. . Evolução e mapeamento do uso da terra, através de imagens aerofotogramétricas e orbitais em Santa Bárbara D’Oeste – São Paulo. *Scientia agrícola*, volume 50, n.3, p. 365-371.

[Burrough & McDonnell, 1998] BURROUGH, P. A. & MCDONNELL, R. A. 1998. *Principles of Geographical Information Systems*. 2 Ed. Oxford, cGraw-Hill Book Company, Cambridge, Massachusetts.

[Carvalho, 2001] CARVALHO, L. M. T. 2001. *Mapping and monitoring forest remnants: a multiscale analysis of spatio-temporal data*. 150p. Tese (doutorado em sensoriamento remoto), Wageningen University, Wageningen.

[Câmara *et al.*, 1996] CÂMARA, G.; SOUZA, R. C. M.; FREITAS, U. M. & GARRIDO, J. 1996. Spring: Integrating remote sensing and gis by object-oriented data modelling. computers graphics. São José dos Campos: INPE.

[CONAB, 2008] COMPANHIA NACIONAL DE ABASTECIMENTO – CONAB, 2008. *Central de informações agropecuárias*. Disponível em: <<http://www.conab.gov.br/>>. Acesso em: 12 out. 2008.

[Congalton, 1991] CONGALTON, R. G. 1991. A review of assessing the accuracy of classifications of remotely sensed data. In. *Remote Sensing of Environment*, volume 49, p. 1671-1678.

[Cruz & Galo, 2003] CRUZ, N. C. & GALO, M. L. B. T. 2003. Aplicação de redes neurais artificiais na classificação de imagens multitemporais e multisensor. In. *Colóquio Brasileiro de Ciências Geodésicas*. volume 3, Curitiba.

[Curran, 1983] CURRAN, J. P. 1983. *Principles of Remote Sensing*. London: Longman. 282p.

[Cybenko, 1988] CYBENKO, G. 1988. *Continuous valued neural networks with two hidden layers are sufficient*. Technical report, Department of Computer Science, Tufts University.

[Dallemand, 1987] DALLEMAND, J. F. 1987. *Identificação de culturas de inverno por interpretação visual de dados SPOT e Landsat/TM no Noroeste do Paraná*. 131p. Dissertação (Mestrado em Sensoriamento Remoto), Instituto Nacional de Pesquisas Espaciais, São José dos Campos.

[Elizondo *et al.*, 1994] ELIZONDO, D. A.; MCCLENDON, R. W. & HOOGENBOOM, G. 1994. Neural network models for predicting flowering and physiological maturity of soybean.

- Transactions of the ASAE*, St. Joseph, volume 37, n.3. p. 981-988.
- [EPAMIG, 2009] EPAMIG, U. R. S. M. 2009. Laboratório de geoprocessamento. *GeoSolos*. Disponível em: <www.epamig.br/geosolos>. Acesso em: 15 jul. 2009.
- [Eastman, 2006] EASTMAN, J. R. 2006. *IDRISI Andes – Tutorial, version 15.0*. Worcester, Clark Labs for Cartographic Technology and Geographic Analysis, Clark University, April 2006. 284p.
- [Florenzano, 2002] FLORENZANO, T. G. 2002. *Imagens de satélite para estudos ambientais*. São Paulo, Oficina de Textos. 78p.
- [Fonseca & Mascarenhas, 1987] FONSECA, L. M. G. & MASCARENHAS, N. D. A. 1987. *Método para Restauração e Reamostragem de Imagens do Sensor TM*. II Simpósio Latino-Americano sobre Sensores Remotos, Bogotá, Colômbia.
- [Galo, 2000] GALO, M. L. B. T. 2000. *Caracterização Ambiental do Parque Estadual Morro do Diabo através de dados e técnicas de Sensoriamento Remoto: Abordagens utilizando redes neurais artificiais*. 205p. Tese (doutorado em ciências da engenharia ambiental), Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2000.
- [Gonzalez & Woods, 2000] GONZALES, R. C. & WOODS, R. E. 2000. *Processamento Digital de Imagens*. 2 Ed. São Paulo: Edgard Blücher. 717p.
- [Han & Hayes, 1990] HAN, Y. J. & HAYES, J. C. 1990. *Soil cover determination using color image analysis*. In. *Transactions of the ASAE*. St. Joseph, volume 33, n.4, p. 1402-1408.
- [Haykin, 1994] HAYKIN, S. 1994. *Neural Networks: A Comprehensive Foundation*. USA: Macmillan Publishing. 696p.
- [Koffer, 1992] KOFFER, N. F. 1992. *Técnicas de sensoriamento remoto orbital aplicadas ao mapeamento da vegetação e uso da terra*. Geografia. volume 17, n.2, p. 14-17.
- [Lacerda *et al.*, 2001] LACERDA, M. P. C.; ALVES, H. M. R.; VIEIRA, T. G. C.; RESENDE, R. J. T. P.; ANDRADE, H.; MACHADO, M. L. & CEREDA, G. J. 2001. Caracterização de agroecossistemas cafeeiros de Minas Gerais por meio do SPRING. Parte II – Agroecossistema de Machado. In *Simpósio de Pesquisas dos Cafés do Brasil*, volume 2, Poços de Caldas. Brasília: Embrapa Café. CD-ROM.
- [Leão *et al.*, 2007] LEÃO, C.; KRUG, L. A.; KAMPEL, M. & FONSECA, L. M. G. 2007. Avaliação de métodos de classificação em imagens TM/Landsat e CCD/CBERS para o mapeamento do uso e cobertura da terra na região costeira do extremo sul da Bahia. In *Simpósio Brasileiro*

- de Sensoriamento Remoto (SBSR)*, volume 13, Florianópolis. São José dos Campos: INPE. p. 939-946.
- [Lobão *et al.*, 2005] LOBÃO, J. S. B.; ROCHA, W. J. S. F. & SILVA, A. B. 2005. Aplicação dos Índices KAPPA & PABAK na validação da classificação automática de imagem de satélite em Feira de Santana-BA. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 12, Goiânia. São José dos Campos: INPE. p. 1207-1214.
- [Liao *et al.*, 1993] LIAO, M. L.; KRAFT, G. T.; MUNRO, S. L. A.; CRAIK, D. J. & BACIC, A. 1993. Beta/kappacarrageenans as evidence for continued separation of the families Dicranemataceae and Sarcadiaceae (Gigartinales, Rhodophyta). *J. Phycol.*, volume 29, p. 833-844.
- [Liu & Goering, 1999] LIU, J. & GOERING, C. E. 1999. *Neural network for setting target corn yields*. St. Joseph: ASAE, Paper No. 99-3040.
- [Luo *et al.*, 1999] LUO, X.; JAYAS, D. S. & SYMONDS, S. J. 1999. Comparison of statistical and neural network methods for classifying general grains using machine vision. *Transactions of the ASAE*, volume 42, n. 2, p. 413-419.
- [Machado, 2002] MACHADO, M. L. 2002. *Caracterização de agroecossistemas cafeeiros da Zona da Mata de Minas Gerais, usando Sensoriamento Remoto e Sistemas de Informações Geográficas*, 137p. Dissertação (mestrado em solos e nutrição de plantas), Universidade Federal de Lavras, Lavras.
- [Marques, 2003] MARQUES, H. S. 2003. *Uso de geotecnologias no estudo das relações entre solos, orientação de vertentes e o comportamento espectral de áreas cafeeiras em Machado, Minas Gerais*. 82p. Dissertação (mestrado em solos e nutrição de plantas), Universidade Federal de Lavras, Lavras.
- [Martins *et al.*, 2007] MARTINS, A. C. G.; SIMÕES, A. S. & PRADO, G. I. 2007. Classificação de texturas usando redes neurais artificiais e o modelo de spot noise. In *Encontro Nacional de Inteligência Artificial (ENIA '2007). Anais...* Rio de Janeiro: Instituto Militar de Engenharia, CD-ROM.
- [Moreira, 2001] MOREIRA, M. A. 2001. *Fundamentos do sensoriamento remoto e metodologias de aplicação*. São José dos Campos: INPE. 249p.
- [Moreira, 2003] MOREIRA, M. A. 2003. *Fundamentos do sensoriamento remoto e metodologias de aplicação*. 2 Ed. Viçosa: UFV. 307p.
- [Moreira *et al.*, 2004] MOREIRA, M. A.; ADAMI, M. & RUDORFF, B. F. T. 2004. Análise espectral e

temporal da cultura do café em imagens Landsat. *Pesquisa Agropecuária Brasileira*, volume 39, n.3, p. 223-231.

[Moreira, 2007] MOREIRA, M. A. 2007. *Uso da geotecnologia para avaliar e monitorar a cafeicultura brasileira: fase I – Estado de Minas Gerais*. São José dos Campos/SP. Disponível em:

<http://marte.dpi.inpe.br/col/sid.inpe.br/deise/1999/02.11.14.26/doc/10_211o.pdf> Acesso em: 3 set. 2010.

[Navares *et al.*, 2009] NAVARES, J. F.; VIEIRA, T. G. C. & LACERDA, W. S. 2009. Classificação de áreas cafeeiras por meio de redes neurais artificiais e os aspectos relacionados à reflectância: um estudo exploratório. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 14. 2009, Natal. São José dos Campos: INPE.

[Novo, 1989] NOVO, E. M. L. M. 1989. *Sensoriamento Remoto: Princípios e Aplicações*. São Paulo: Edgard Blücher. 308p.

[Oliveira *et al.*, 2009] OLIVEIRA, J. A.; DUTRA, L. V.; RENNÓ, C. D. & SANTOS, P. S. 2009. Extração de atributos de forma para classificação de imagens de alta resolução do satélite hrc/cbers-2b. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 14, Natal. São José dos Campos: INPE. p. 7015-7022.

[Patel *et al.*, 1995] PATEL, V. C.; MCCLENDON, R. W. & GOODRUM, J. W. 1995. Detection of cracks in eggs using computer vision and artificial neural networks. *St. Joseph*, ASAE Paper No. 95-3258.

[Picoli, 2006] PICOLI, M. C. A. 2006. *Estimativa da produtividade agrícola da cana: Estudo de caso Usina Catanduva*. 93p. Dissertação (mestrado em sensoriamento remoto), Instituto Nacional de Pesquisas Espaciais - INPE, São José dos Campos.

[Pinto *et al.*, 1999] PINTO, F. A. C.; REID, J. F.; ZHANG, Q. & NOGUCHI, N. 1999. Guidance parameter determination using artificial neural network classifier. *St. Joseph*, ASAE Paper No. 99-3004.

[Rennó *et al.*, 1998] RENNÓ, C. D.; FREITAS, C. D. C. & SANT'ANNA, S. J. S. 1998. A system for region image classification based on textural measures. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 9, Santos/SP. São José dos Campos: INPE. p 1195-1202.

[Ribeiro *et al.*, 2005] RIBEIRO, S. R. A.; TEDESCO, A.; KRUEGER, C. P. & CENTENO, J. A. S. 2005. Extração de profundidade mediante redes neurais artificiais e modelo de regressão usando

- dados de levantamento GPS e de imagens IKONOS II - estudo comparativo. *Engevista*. volume 7, n.1. p. 73-82.
- [Rocha & Leite, 2004] ROCHA, A. R. & LEITE, N. J. 2004. *Classificação de texturas a partir de vetores de atributos e função de distribuição de probabilidades*. Disponível em: <http://www.ic.unicamp.br/rocha/msc/ipdi/texture_classification.pdf>. Acesso em: 10 jul. 2009.
- [Rumelhart & McClelland, 1986] RUMELHART, D. E. & MCCLELLAND, J. L. 1986. *Parallel Distributed Processing: Explorations on the Microstructure of Cognition*, volume 1. Cambridge: MIT Press.
- [Santos *et al.*, 2007] SANTOS, W. J. R.; VIEIRA, T. G. C.; BERNARDES, T.; ALVES, H. M. R. & SILVEIRA, S. P. S. 2007. Exatidão de classificações automáticas de uma imagem Landsat 5 TM para a região cafeeira de Machado. In *Simpósio de Pesquisa dos Cafés do Brasil (SPCB)*, volume 5. CD-ROM.
- [Silva & Francisco, 2002] SILVA, A. L. G. & FRANCISCO, C. N. 2002. Descrição dos Principais Sistemas Sensores Orbitais em Operação. Disponível em: <www.professores.uff.br/cristiane/Documentos/apostilasr.doc>. Acesso em: 13 ago. 2009.
- [Skidmore, 1989] SKIDMORE, A. K. 1989. An expert system classifies eucalypt forest types using thematic mapper data and a digital terrain model. *Photogrammetric Engineering and Remote Sensing*, volume 55, p. 1449-1464.
- [Sousa *et al.*, 2009] SOUSA, R. B.; VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L.; SOUZA, V. C. O.; SANTOS, W. J. R. & SILVA, E. 2009. Mapeamento de áreas cafeeiras do Sul de Minas Gerais - Machado e Três Pontas. In *Simpósio de Pesquisa dos Cafés do Brasil (SPCB)*, volume 6, Vitória. Brasília: Embrapa Café, CD-ROM.
- [Souza *et al.*, 2009] SOUZA, V. C. O.; VIEIRA, T. G. C.; ALVES, H. M. R. & VOLPATO, M. M. L. 2009. Mapeamento de áreas cafeeiras por classificação automática utilizando medidas texturais. In *Simpósio de Pesquisa dos Cafés do Brasil (SPCB)*, volume 6, Vitória. Brasília: Embrapa Café, CD-ROM.
- [SPOT IMAGE, 2010] SPOT IMAGE. 2010. Site *SPOT IMAGE*. Disponível em: <<http://brasil.spotimage.com/web/pt/2005-bandas-espectrais-e-resolucoes.php>>. Acesso em: 15 dez. 2010.
- [SPRING, 2009a] SPRING. 2009a. Site oficial do INPE – Instituto Nacional de Pesquisas Espaciais. *Tutorial de Geoprocessamento*. Disponível em:

<http://www.dpi.inpe.br/spring/portugues/tutorial/introducao_sen.html>. Acesso em: 15 dez. 2009.

[SPRING, 2009b] SPRING. 2009b. Site oficial do INPE – Instituto Nacional de Pesquisas Espaciais. *Tutorial do Spring 4.3.3.* Disponível em: < www.dpi.inpe.br/spring >. Acesso em: 15 dez. 2009.

[Tardin *et al.*, 1992] TARDIN, A. T.; ASSUNÇÃO, G. V. & SOARES, J. V. 1992. Análise preliminar de imagens TM visando a discriminação de café, citrus e cana-de-açúcar na região de Furnas-MG. *Pesquisa Agropecuária Brasileira*, volume 27, p. 1355-1361.

[Varella *et al.*, 2002] VARELLA, C. A. A.; PINTO, F. A. C.; QUEIROZ, D. M. & SENA JR., D. G. 2002. Determinação da cobertura do solo por análise de imagens e redes neurais. *Revista Brasileira de Engenharia Agrícola e Ambiental*, volume 6, n.2, p. 225-229.

[Vieira, 2000] VIEIRA, C. A. O. 2000. *Accuracy of remotaly sensing classification of agricultural crops: a comparative study*. Thesis (doctor of philosophy), University of Nottingham.

[Vieira *et al.*, 2006] VIEIRA, T. G. C.; ALVES, H. M. R.; LACERDA, M. P. C.; VEIGA, R. D. & EPIPHANIO, J. C. N. 2006. Crop parameters and spectral response of coffee (*coffea arábica* l.) areas within the state of Minas Gerais, Brazil. *Coffee Science*, volume 1, n.2, p. 111-118.

[Vieira *et al.*, 2007a] VIEIRA, T. G. C.; ALVES, H. M. R.; BERTOLDO, M. A. & SOUZA, V. C. O. 2007a. Geothecnologies in the assessment of land use changes in coffee regions of the state of Minas Gerais in Brazil. *Coffee Science*, volume 2, p. 142-149.

[Vieira *et al.*, 2007b] VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L.; SOUZA, V. C. O & BERNARDES, T. 2007b. Sistema de geoinformação para a cafeicultura do Sul de Minas. *Informe Agropecuário*, volume 28, n.241, p. 16-26.

[Vieira *et al.*, 2009a] VIEIRA, T. G. C. V.; LACERDA, W. S. & BOTELHO, T. G. 2009b. Mapeamento de áreas cafeeiras utilizando redes neurais artificiais: Estudo de caso na região de Três Pontas, Minas Gerais. In *Simpósio Brasileiro de Sensoriamento Remoto (SBSR)*, volume 14, Natal. São José dos Campos: INPE.

[Vieira *et al.*, 2009b] VIEIRA, T. G. C. V.; ALVES, H. M. R.; VOLPATO, M. M. L.; BERNARDES, T. & SANTOS, E. R. 2009c. Avaliação de classificadores automáticos no mapeamento de áreas cafeeiras da região de Guaxupé, Minas Gerais. In *Simpósio de Pesquisa dos Cafés do Brasil (SPCB)*, volume 6, Vitória. Brasília: Embrapa Café, CD-ROM.

[Vieira *et al.*, 2009c] VIEIRA, T. G. C. V.; ALVES, H. M. R.; VOLPATO, M. M. L.; BOTELHO, T. G. & SANTOS, E. R. 2009c. Avaliação de classificadores automáticos no mapeamento de áreas

cafeeiras da região de Guaxupé, Minas Gerais. In *Simpósio de Pesquisa dos Cafés do Brasil (SPCB)*, volume 6.