



XXXIII

Congresso Brasileiro de Ciência do Solo

Solos nos biomas brasileiros: sustentabilidade e mudanças climáticas
31 de julho à 05 de agosto - Center Convention - Uberlândia/Minas Gerais

REDES NEURAIS ARTIFICIAIS (RNA) APLICADAS À CLASSIFICAÇÃO DE ÁREAS CAFEIEIRAS NA REGIÃO DE TRÊS PONTAS-MG

Lívia Naiara de Andrade¹, Tatiana Grossi Chquilloff Vieira², Wilian Soares Lacerda³, Margarete Marin Lordelo Volpato⁴, Helena Maria Ramos Alves⁵, Elidiane da Silva⁶, Carolina Gusmão Souza⁷

⁽¹⁾ Bolsista, M. Sc., EPAMIG - CBP&D/CAFÉ, Lavras-MG livia.naiara.andrade@gmail.com; ⁽²⁾ Pesquisadora, M. Sc., EPAMIG, Bolsista FAPEMIG, Lavras-MG, tatiana@epamig.ufla.br; ⁽³⁾ Professor, D. Sc., Universidade Federal de Lavras, Departamento de Ciência da Computação, lacerda@dcc.ufla.br; ⁽⁴⁾ Pesquisadora, D. Sc., EPAMIG, Bolsista FAPEMIG, Lavras-MG, margarete@epamig.ufla.br; ⁽⁵⁾ Pesquisadora, D. Sc., EMBRAPA CAFÉ, Brasília-DF, helena@embrapa.br; ⁽⁶⁾ Estudante, Graduanda em Agronomia, Universidade Federal de Lavras, elidianeagroufla@gmail.com; ⁽⁷⁾ Bolsista, M. Sc., EMBRAPA CAFÉ - CBP&D/CAFÉ, Lavras-MG, carolinagusmaosouza@gmail.com

Resumo – A cafeicultura é atividade de fundamental importância na região Sul do estado de Minas Gerais, no Brasil, e técnicas de estimativa da área plantada, visando previsões de safra confiáveis, estão sendo intensamente pesquisadas. Este estudo apresenta uma aplicação de Redes Neurais Artificiais (RNA) para a classificação automática de dados de sensoriamento remoto, com o objetivo de identificar áreas cafeeiras na região de Três Pontas, Sul de Minas Gerais. Um fator complicador é a alta similaridade do padrão espectral do café com áreas de mata nativa. Foram criadas máscaras na drenagem e na área urbana. O resultado da classificação feita pela RNA foi superior aos resultados encontrados na literatura, com um índice kappa de 69%.

Palavras-Chave: sensoriamento remoto, redes neurais artificiais, classificação automática, mapeamento, uso da terra.

INTRODUÇÃO

O uso operacional de imagens para o mapeamento da cafeicultura, especialmente em sistemas agrícolas fragmentados e complexos, implica, inevitavelmente, em novos desafios. A informação espectral propiciada por imagens de satélite não é, muitas vezes, suficiente para distinguir os objetos (alvos) com reflectâncias similares. Em relação ao cafeeiro, os valores digitais que identificam as áreas da cultura na imagem são similares aos de outras classes de ocupação da terra, causando confusão na separação entre as mesmas. Sobreposição espectral ocorre principalmente entre o café e vários tipos de vegetação natural, dificultando o bom desempenho dos algoritmos para interpretação automática de imagens. Esta sobreposição impõe desafios práticos e teóricos para o uso operacional do sensoriamento remoto orbital para o mapeamento de áreas cafeeiras na escala regional (Carvalho, 2001).

A grande variabilidade de padrões da cultura apresentados numa cena de satélite, decorrentes de variados estágios fenológicos e vigor vegetativo, espaçamento, culturas intercalares e tratos culturais, dificulta o reconhecimento de padrões por métodos automatizados. Outros fatores do meio físico, como o relevo, que altera o sombreamento e a geometria de reflexão da radiação, somados a padrões irregulares de

forma, tamanho e estratificação dos talhões, dificultam a definição de regras estatísticas para identificação de intervalos de nível de cinza na imagem referentes à cultura cafeeira com precisão satisfatória (Vieira et al., 2006). De acordo com Carvalho (2001), existe a necessidade de um procedimento de classificação eficiente que: a) seja capaz de distinguir áreas plantadas com café entre outras classes de uso ou cobertura que se sobrepõem espectralmente; b) aproveite ao máximo as características/informações disponíveis para a classificação; e c) requeira menos intervenção humana, caso estimativas confiáveis da ocupação por café precisem ser feitas frequentemente em grandes extensões geográficas.

As imagens de satélite apresentam grande heterogeneidade de objetos, constituindo complexos alvos de análise. Para isso, é necessário desenvolver novas técnicas que possam auxiliar no processo de análise das imagens. A aplicação de Redes Neurais Artificiais (RNAs) tem se mostrado uma abordagem promissora, discriminando classes de maior complexidade.

As RNAs usam elementos de computação não-linear (chamados neurônios) organizados como redes, de maneira análoga à que se acredita que os neurônios estejam interconectados no cérebro (GONZALES & WOODS, 2000). A abordagem de RNA tem sido utilizada por Cruz & Galo (2003), em imagens de sensoriamento remoto de datas e sensores diferentes para discriminar classes de uso e cobertura da terra. Uma imagem TM/Landsat foi adotada como referência para o treinamento e validação da rede e então aplicada tanto à própria imagem quanto a uma cena CCD/Cbers. Os resultados obtidos indicaram que, se os dados multiespectrais e multissensores passarem por um pré-processamento, principalmente quanto à normalização radiométrica das bandas, uma rede treinada com dados de uma data e sensor, pode ser aplicada a uma segunda imagem tomada em outra data e outro sensor, obedecendo as condições de similaridade espectral e radiométrica.

Andrade et al. (2009) utilizaram RNAs para discriminação de áreas cafeeiras em imagens SPOT 5 da região de Guaxupé, MG. Devido ao fato de ocorrer ambiguidade espectral entre áreas de mata e café foi criada uma máscara sobre as três bandas da imagem. A máscara agregou as classes de uso da terra: água, solo exposto e café em formação criando uma nova classe denominada outros usos. A metodologia apresentou um bom resultado,

porém é necessário que se utilize outros dados de entrada para otimizar os resultados. Uma sugestão seria utilizar parâmetros do meio físico, como a relação de proximidade com a rede de drenagem, uma vez que as matas ciliares apresentam-se em pequenas áreas, fazendo com que a RNA as confunda com algum outro uso.

As variáveis do meio físico e fenologia da cultura podem alterar a resposta espectral do café ou mesmo informar sobre prováveis classes de uso da terra. Torna-se desejável a inclusão de dados auxiliares na forma de novas camadas de informação, como topografia do terreno, medidas de textura, forma da área plantada, e redes de drenagem nos procedimentos de classificação. Sendo assim, objetivou-se neste trabalho definir um procedimento de classificação automática utilizando RNA para identificação de áreas cafeeiras em imagens de satélite da região de Três Pontas-MG, utilizando variáveis do meio físico.

MATERIAL E MÉTODOS

A área de estudo encontra-se na Região Sudeste do estado de Minas Gerais, no município de Três Pontas. Posiciona-se geograficamente entre as coordenadas 21° 17' 10.07" a 21° 27' 57.41" de latitude sul e 45° 30' 4.69" a 45° 45' 3.33" de longitude oeste, com uma área total de 510,84 km². A região possui declividade predominantemente suave ondulado, clima ameno e tropical de altitude. Foram utilizadas imagens multiespectrais para classificação automática com RNA, que se referem às bandas 3, 4 e 5 do satélite Landsat 5, sensor TM, com data de passagem de 16/07/2007, sendo estas as bandas mais empregadas no mapeamento da cobertura do solo, e o mapa de uso da terra Três Pontas-MG, classificado visualmente. Neste trabalho foram utilizados os sistemas de informações geográficas SPRING versão 4.3.3 e o software IDRISI, versão 15.0.

Pré-processamentos

Para a realização da classificação, os dados de sensoriamento remoto foram submetidos aos pré-processamentos necessários para que a RNA fosse capaz de reconhecer as mesmas classes nas imagens.

Foi criada uma máscara ao longo da rede de drenagem, em cada uma das três bandas da imagem, utilizando as linhas de drenagem do Instituto Mineiro de Gestão das Águas (IGAM). Quando sobrepostas as linhas de drenagem sobre a imagem Landsat, percebeu-se que a mesma apresentava um pequeno deslocamento em relação à imagem, e que alguns drenos não haviam sido identificados pelo IGAM. Para corrigir o erro, foram digitalizadas, manualmente, as redes de drenagem que estavam faltando e corrigidas as que apresentavam grande deslocamento. Após a correção da drenagem, foi feita uma relação de proximidade (*buffer*) de 50m no entorno da drenagem, e em seguida, foi realizado o cruzamento do *buffer* com o mapa de uso da terra, e atribuído o valor dez aos pixels que se encontravam nestas áreas, utilizando a Linguagem Espacial para Geoprocessamento Algébrico (LEGAL), do SPRING. Esse procedimento foi realizado para tentar eliminar o erro causado pela classificação da

RNA, uma vez que ao longo da drenagem existem pequenas áreas de mata que se confundem com café ou qualquer outra classe de uso. Foi criada uma máscara na área urbana de Três Pontas e atribuído o valor 255 aos seus pixels. O diagrama da Figura 1 mostra as etapas de desenvolvimento do trabalho.

Classificação da imagem pela RNA

Foram realizados diversos testes para definição da arquitetura ideal para a classificação, sendo adotado um modelo de rede neural com estrutura de múltiplas camadas, da abordagem supervisionada. A RNA foi treinada com algoritmo *backpropagation*, realizando as seguintes alterações na arquitetura da RNA: número do conjunto de pixels para o conjunto de treinamento e teste; número de camadas; número de neurônios nas camadas; fator de *momentum* e taxa de aprendizado.

A obtenção de áreas de treinamento e validação da RNA foi realizada por meio da extração de áreas em formato de polígonos da imagem para cada classe a ser classificada. Foram selecionados entre 35 e 40 polígonos de tamanhos variados e espaçados ao acaso para cada classe, compostos da seguinte forma: **café em produção**: lavouras com idade superior a três anos; **mata**: formações florestais densas e florestas de galeria às margens dos córregos; **área urbana**: área com grande concentração de construções; **água**: lagoas, represas e a máscara de drenagem; e **outros usos**: áreas com café em formação (menos de três anos), áreas com culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação.

Foi utilizado o módulo *Makesig* do IDRISI para realizar a extração da assinatura espectral do conjunto de amostras. Para a definição da arquitetura da RNA para classificação da imagem, foi executado o módulo de classificação por redes neurais do tipo *multi-layer perceptron*, do software IDRISI. O número de elementos da camada de saída foi definido com base no número de classes a serem classificadas na imagem, sendo cinco nós com valores identificados na criação das amostras.

Validação dos resultados

Para validação das classificações realizadas pela RNA, foi realizado um cruzamento entre o mapa classificado visualmente com o classificado pela Rede Neural Artificial utilizando a linguagem LEGAL. A Figura 1 mostra o mapa de uso da terra classificado visualmente com a máscara de drenagem. Para avaliar o desempenho da RNA, utilizou-se o índice Kappa que é baseado na construção de matrizes de erro ou de contingência. A análise do desempenho da RNA foi avaliada em três classes, sendo elas: Áreas classificadas corretamente: pixels de áreas de café classificadas pela RNA e pelo método visual; Áreas classificadas incorretamente: pixels que a RNA classificou como café, porém não eram áreas cafeeiras e Áreas não classificadas: pixels que a RNA deixou de classificar como café, classificando como outra classe.

RESULTADOS E DISCUSSÃO

Foram realizados diversos testes para definição da arquitetura que melhor classificasse a imagem, sendo que a arquitetura que apresentou melhor resultado foi uma rede neural com 16 neurônios em uma única camada escondida, conjunto de 70 pixels por categoria para o conjunto de teste

e treinamento, taxa de aprendizado de 0,02; fator de momentum de 0,53 para agilizar na convergência da rede; e constante de sigmóide de 1. Como critério de parada do treinamento da RNA foi estabelecido o limite de 10.000 iterações ou erro médio quadrático (EQM) de 0,0001.

A parada do treinamento da RNA aconteceu pelo número de iterações do algoritmo *backpropagation*, resultando em um valor de EQM de 0,004948 para os dados de treinamento, e 0,004763 para os dados de teste. A Tabela 1 mostra as configurações utilizadas para teste, e em destaque está a arquitetura que apresentou melhor resultado.

De acordo com a Tabela 1, pode-se relatar que a rede neural teve melhor desempenho com a configuração 6, com uma única camada escondida, variando a quantidade de neurônios. Nos testes realizados, observou-se que, aumentando o número de camadas, a rede não produziu bons resultados, mesmo com um número de neurônios da primeira camada superior aos da segunda camada, como ocorre na configuração 5, que produziu bons resultados, porém o resultado final da classificação não teve bom desempenho, apresentando grande confusão entre as classes café e mata. A rede também apresentou melhor convergência quando adicionada maior quantidade de pixels para o conjunto de treinamento e teste.

A Figura 1 mostra o mapa de uso da terra obtido por classificação visual e conferido em campo. A Figura 2 apresenta a cena classificada resultante da aplicação da arquitetura anterior da rede neural treinada

Em relação ao mapa de referência, o índice de acurácia Kappa do mapa classificado pela RNA ficou em 69%. Segundo Galparsoro e Fernández (2001) este é considerado um índice bom. O índice Kappa obtido na classificação por RNA pode ter sido prejudicado pelos fatores ambientais que interferem no padrão espectral da imagem, tais como variações do estágio fenológico, vigor vegetativo, espaçamento das plantas nas lavouras e tratos culturais utilizados, existência de culturas intercalares, relevo acidentado causando sombra e baixa resolução espacial das imagens Landsat utilizada. Contudo, se comparados aos resultados obtidos por Andrade (2010), a RNA apresentou melhor resultado.

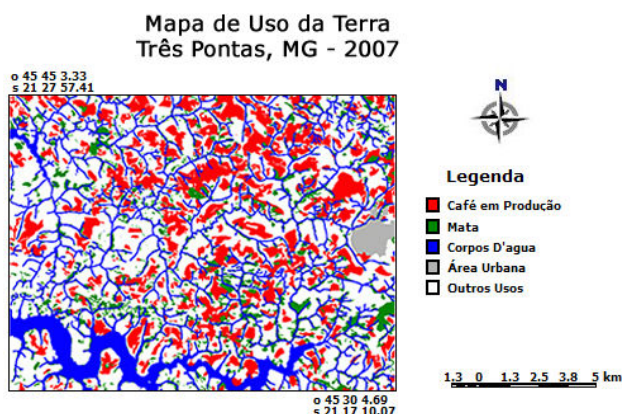


Figura 1. Mapa de uso da terra classificado visualmente com a máscara de drenagem

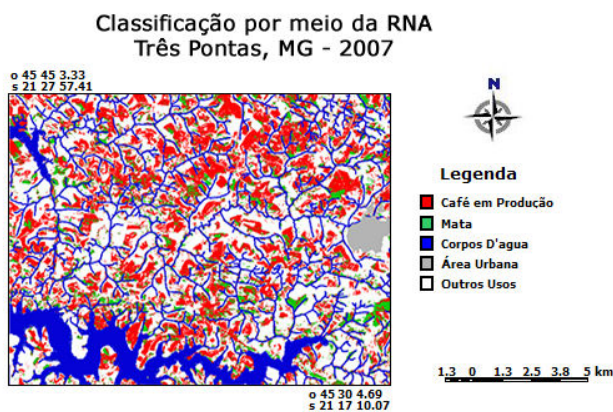


Figura 2. Mapa de uso da terra classificado pela RNA.

Andrade (2010), utilizou RNA para identificar áreas cafeeiras em imagens de satélite na região de Machado-MG. As imagens foram submetidas a pré-processamentos para que a RNA fosse capaz de identificar as mesmas classes nas imagens. Inicialmente, a área foi dividida entre os relevos plano e acidentado, e em seguida, foram criadas máscaras na drenagem e na área urbana. O resultado da classificação feita pela RNA foi de 55.84% para o relevo mais movimentado e 60.29% para o relevo menos movimentado.

A matriz de confusão entre o mapa de referência e o classificado pela RNA é apresentada na Tabela 2. A matriz contém as taxas de erro e acerto da classificação para cada classe.

Analisando a matriz de confusão, pode-se observar que a RNA teve um bom desempenho na classificação de áreas cafeeiras, com um acerto de 73%. A RNA confundiu áreas de café com áreas de mata, classificando incorretamente 11,99% de áreas de mata como café. Outra confusão feita pela RNA na identificação das áreas cafeeiras foi com as áreas de outros usos, com uma porcentagem de erro de 14,13%. Esta confusão pode ser justificada pelo fato da classe outros usos englobar café em formação, culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação.

Outra dificuldade de classificação apresentada pela RNA pode ser observada na classe mata, que obteve como acerto 46,95%. A classificação da mata apresentou confusão com áreas de café, classificando incorretamente 27,52% de áreas cafeeiras como mata. As confusões ocorridas durante a classificação se devem ao fato do padrão espectral entre o café a mata serem muito próximos (VIEIRA, 2006), e também pelo fato da classe outros usos englobar várias culturas e diferente tipos de vegetação, como discutido anteriormente.

As classes corpos d'água e área urbana apresentaram taxas de acerto superiores a 99% e a classe "outros usos" obteve uma porcentagem de acerto de 78,54%. Aproximadamente 15% de áreas cafeeiras, 3% de áreas de mata e 3,78% de corpos d'água, foram classificadas incorretamente como outros usos.

O mapa de referência classificado visualmente com a máscara e o gerado pela classificação da RNA foram cruzados no SPRING, utilizando a Linguagem LEGAL do SPRING. Desse cruzamento obteve-se o mapa apresentado na Figura 3, que mostra, especialmente, o desempenho da RNA sobre as áreas cafeeiras.




Figura 3. Mapa de cruzamento das áreas de café entre o mapa de referência e o classificado pela RNA.

A área total do mapa é de 510 km², sendo 105,85 km² do total das áreas são ocupadas pela cultura cafeeira. O mapa apresenta o desempenho da RNA sobre a classe café, onde o café classificado corretamente totaliza 36,15%, o que equivale a 38,04 km², e o classificado incorretamente a 21,36 km².

CONCLUSÕES

Com base nos resultados, conclui-se que o pré-processamento foi um passo fundamental para os bons resultados alcançados com a classificação pela RNA. Com a criação das máscaras foi possível diminuir a confusão entre as classes durante a classificação, como a máscara de drenagem, que eliminou as APPs, onde existiam áreas de vegetação natural que eram confundidas com áreas de café. A máscara na área urbana também contribuiu para melhoria da classificação. O erro na classificação realizada pela RNA é influenciado pela ambiguidade de áreas de café com áreas de mata, tendo em vista os padrões espectrais muito próximos destas duas classes de uso e cobertura do solo.

AGRADECIMENTOS

Os autores agradecem ao apoio da Fundação de Amparo à Pesquisa de Minas Gerais (FAPEMIG) e ao CBP&D/Café pelos recursos financeiros para o desenvolvimento do projeto e bolsas.

REFERÊNCIAS BIBLIOGRÁFICAS

- ANDRADE, L. N.; VIEIRA, T. G. C.; ALVES, H. M. R.; VOLPATO, M. M. L.; SOUZA, V. C. O. **Aplicação de redes neurais artificiais (rna) na análise e classificação de áreas cafeeiras da região de Machado-MG.** In: IX Congresso Latinoamericano y del Caribe de Ingeniería Agrícola - XXXIX Congresso Brasileiro de Engenharia Agrícola (CLIA/CONBEA), Vitória/ES, 2010.
- ANDRADE, L. N.; VIEIRA, T. G. C.; LACERDA, W. S.; ALVES, H. M. R.; VOLPATO, M. M. L.; BRAGA, R. C. A.; SOUZA, V. C. O. **Redes Neurais Artificiais na classificação de áreas cafeeiras da região de Guaxupé.** In: Simpósio de Pesquisa dos Cafés do Brasil, 6., 2009, Vitória. Brasília: Embrapa Café, 2009. CD-ROM.
- CARVALHO, L. M. T. **Mapping and monitoring forest remnants: a multiscale analysis of spatio-temporal data.** 2001, 150f. Tese (Doutorado em Sensoriamento Remoto) – Wageningen University, Wageningen, 2001.
- CRUZ, N. C.; GALO, M. L. B. T. Aplicação de redes neurais artificiais na classificação de imagens multitemporais e multisensor. In: Colóquio Brasileiro de Ciências Geodésicas, 3., 2003, Curitiba. **Anais...** Curitiba: UFPR, 2003. CD-ROM.
- GALPARSORO, L. U. FERNÁNDEZ, S. P. **Medidas de concordância: el índice Kappa.** 2001. Disponível em: <<http://www.fisterra.com/mbe/investiga/kappa/kappa.htm>>. Acesso em: 01 nov. 2008
- GONZALES, R. C.; WOODS, R. E. **Processamento de Imagens Digitais.** São Paulo: Edgard Blücher Ltda., 2000. 527 p.
- VIEIRA, T. G. C.; ALVES, H. M. R.; LACERDA, M. P. C.; VEIGA, R. D.; EPIPHANIO, J. C. N. Crop parameters and spectral response of coffee (*Coffea arabica* L.) areas within the state of Minas Gerais, Brazil. **Coffee Science**, v.1, n.2, p.111-118. 2006.

Tabela 1. Configurações utilizadas para realização dos testes.

Configuração	Pixel ¹	Camadas escondidas	Neurônios		Taxa de aprend.	Momentum	Iterações	EMQ	
			1ª Cam.	2ª Cam.				Trein.	Teste
1	55	2	18	12	0.01	0.5	10000	0.005542	0.00647
2	60	1	16	-	0.01	0.53	10000	0.004953	0.005507
3	60	2	16	10	0.01	0.5	10000	0.005073	0.005135
4	65	2	22	16	0.01	0.5	10000	0.005312	0.005113
5	70	2	16	12	0.01	0.5	10000	0.00504	0.005103
6	70	1	16	-	0.02	0.53	10000	0.004948	0.004763
7	70	1	16	-	0.01	0.5	10000	0.005123	0.004956

(¹ Número de pixels selecionados para o conjunto de treinamento e teste.)

Tabela 2. Matriz de confusão entre os mapas de referência e o classificado pela RNA.

Mapa de Referência	Mapa Classificado pela RNA					
	Café em Produção	Mata	Corpos D'água	Área Urbana	Outros Usos	Total
Café em Produção	73.05%	11.99%	0.83%	0.00%	14.13%	100.00%
Mata	27.52%	46.95%	3.24%	0.00%	22.28%	100.00%
Corpos D'água	0.00%	0.00%	99.93%	0.07%	0.00%	100.00%
Área Urbana	0.00%	0.00%	0.16%	99.83%	0.00%	100.00%
Outros Usos	15.08%	2.59%	3.78%	0.02%	78.54%	100.00%